

UNIVERSIDADE CATÓLICA DE PERNAMBUCO
CURSO DE CIÊNCIA DA COMPUTAÇÃO

Comparação de Modelos de Machine Learning na Segmentação de Feridas Malignas em Imagens Médicas

ALUNO: LUCAS DOS SANTOS AMORIM RÊGO
ORIENTADOR: RAFAEL ROQUE DE SOUZA

Projeto apresentado ao Curso de Ciência da Computação da Universidade Católica de Pernambuco, como parte dos requisitos necessários à obtenção da nota da disciplina INF 1814 - Trabalho de Conclusão de Curso II.

Recife, PE, Dezembro de 2023

RESUMO

Contexto: A área da saúde demanda cada vez mais a segmentação precisa de imagens médicas, notadamente no ramo da oncologia cutânea. Nesse contexto, a identificação exata e rápida de feridas malignas pode resultar em tratamentos mais eficientes e prognósticos mais positivos. Modelos de aprendizado profundo, como U-Net (U-Net), Segmentation Network (SegNet), Fully Convolutional Network (FCN) e MobileNet Versão 2 (MobileNetV2), têm ganhado espaço nesse cenário devido à sua capacidade e potencial de aplicação. **Objetivo:** Este estudo visa explorar a eficiência e aplicabilidade desses modelos de aprendizado profundo no que tange à segmentação de feridas malignas em imagens médicas, levando em conta seus resultados no que diz respeito à precisão dos resultados dos algoritmos. **Método:** A metodologia adotada para essa investigação percorre uma série de fases, desde o pré-processamento das imagens até a avaliação do desempenho dos modelos de aprendizado profundo, passando por testes em diferentes modelos de machine learning. O desempenho de cada modelo foi avaliado por meio de métricas consagradas, como Loss, Precision, Recall e Coeficiente de Dice, além de ser considerada a eficiência computacional de cada um. **Resultados:** Os resultados obtidos neste estudo foram promissores, os modelos avaliados demonstraram alto desempenho na segmentação de feridas malignas e forneceram insights significativos a respeito do desempenho comparativo entre diferentes arquiteturas de aprendizado profundo em aplicações médicas. **Conclusão:** Espera-se que as descobertas deste estudo ofereçam direcionamentos para futuras pesquisas no campo da segmentação de imagens médicas via aprendizado profundo. Ademais, a pesquisa tem o potencial de trazer benefícios notáveis à medicina – sobretudo à oncologia cutânea – ao prover ferramentas automatizadas e eficazes para segmentação de feridas malignas, colaborando, assim, com diagnósticos e monitoramento de tratamentos por profissionais da saúde.

Palavras-chave: Câncer; Feridas Malignas; Segmentação de Feridas; Redes Neurais Convolucionais.

ABSTRACT

Context: The health sector is increasingly demanding precise segmentation of medical images, particularly in the field of cutaneous oncology. In this context, the accurate and rapid identification of malignant wounds can result in more efficient treatments and more positive prognoses. Deep learning models, such as U-Net (U-Net), Segmentation Network (SegNet), Fully Convolutional Network (FCN) and MobileNet Versão 2 (MobileNetV2), have been gaining ground in this scenario due to their capacity and application potential. **Objective:** This study aims to explore the efficiency and applicability of these deep learning models with regard to the segmentation of malignant wounds in medical images, taking into account their results with regard to the accuracy of the algorithms' results. **Method:** The methodology adopted for this research goes through a series of phases, from pre-processing the images to evaluating the performance of the deep learning models, including tests on different machine learning models. The performance of each model will be evaluated using established metrics such as loss, precision, recall and Dice coefficient, and the computational efficiency of each one will be considered. **Results:** The results obtained in this study were promising, the models evaluated demonstrated high performance in the segmentation of malignant wounds and provided significant insights into the comparative performance between different deep learning architectures in medical applications. **Conclusion:** The findings of this study are expected to provide directions for future research in the field of medical image segmentation via deep learning. In addition, the research has the potential to bring notable benefits to medicine – especially cutaneous oncology – by providing automated and effective tools for segmenting malignant wounds, thus collaborating with diagnoses and treatment monitoring by health professionals.

Keywords: Cancer; Malignant Wounds; Wound Segmentation; Convolutional Neural Networks.

Sumário

1	INTRODUÇÃO	5
1.1	Apresentação do Problema	5
1.2	Questões de Pesquisa	6
1.3	Objetivo Geral	6
1.4	Objetivos Específicos	6
1.5	Estrutura do TCC	7
2	FUNDAMENTAÇÃO TEÓRICA	8
2.1	Feridas Crônicas e Malignas	8
2.2	Avaliação e Manejo de Feridas	8
2.3	Aplicações de IA no Diagnóstico e Tratamento Médico	9
2.4	Arquiteturas de Redes Neurais	11
2.5	Métricas	12
3	TRABALHOS RELACIONADOS	13
3.1	Limitação dos Trabalhos Relacionados	14
3.2	Diferencial do Nosso Trabalho	14
4	METODOLOGIA	16
4.1	Conjunto de Dados	16
4.2	Criação do Conjunto de Dados	16
4.3	Pré-processamento de Imagens	17
4.4	Divisão do Conjunto de Dados	18
4.5	Arquiteturas de Redes Neurais	18
4.5.1	FCN	18
4.5.2	U-Net	19
4.5.3	SegNet	20
4.5.4	MobileNetV2	21
4.6	Treinamento e Ajuste do Modelo	21
4.7	Avaliação e Métricas	22
4.8	Considerações Éticas	22

5	RESULTADOS	23
5.1	Criação de um Dataset	23
5.2	Desempenho dos Modelos	23
5.2.1	FCN	24
5.2.2	U-Net	25
5.2.3	SegNet	26
5.2.4	MobileNetV2	27
5.3	Análise Comparativa Entre os Modelos	28
5.4	Contribuições e Perspectivas Futuras	30
6	DISCUSSÕES	31
6.1	Contextualização dos Resultados	31
6.2	Implicações Práticas	31
6.3	Comparação com Estudos Anteriores	31
6.4	Limitações do Estudo	31
6.5	Sugestões para Pesquisas Futuras	32
6.6	Conclusão	32

1. INTRODUÇÃO

No Brasil, estima-se que anualmente, entre 2023 e 2025, ocorrerão aproximadamente 704.000 novos casos de câncer. As feridas malignas, decorrentes destes cânceres, representam um desafio significativo no tratamento médico [de Oliveira Santos et al. 2023]. Profissionais de saúde lidam com a complexidade dessas feridas crônicas, frequentemente oriundas de processos oncológicos, que exigem cuidados intensivos focados não apenas na cicatrização, mas também na melhoria da qualidade de vida dos pacientes [Freitas de Castro et al. 2017, Agra et al. 2017].

As Redes Neurais Convolucionais (CNNs), subcategoria das Artificial neural Networks (ANN), têm se mostrado eficazes em diversas aplicações de visão computacional, como classificação e segmentação de imagens [Sun et al. 2023]. Essas redes conseguem distinguir lesões de pele saudável adjacente, identificando características essenciais para avaliações mais objetivas e consistentes [Litjens et al. 2017, Lundervold and Lundervold 2019, Esteva et al. 2019].

1.1. Apresentação do Problema

Feridas malignas, frequentemente associadas a cânceres de mama, cabeça e pescoço, surgem da infiltração agressiva de células cancerígenas na pele, levando ao desenvolvimento de lesões exofíticas que alteram progressivamente a aparência do paciente. Estas lesões caracterizam-se por sua natureza friável, onde pequenos traumas podem causar sangramentos significativos. Além disso, são notoriamente dolorosas, afetando diretamente o bem-estar e a qualidade de vida do indivíduo afetado.

As feridas malignas são também conhecidas por serem exsudativas, produzindo um exsudato que pode ser desafiador de gerenciar. Este exsudato, muitas vezes abundante, requer cuidados constantes e especializados para prevenir infecções e manter a integridade da pele ao redor. Outro aspecto desafiador é o odor desagradável que muitas vezes acompanha estas feridas, resultado da necrose tecidual e da colonização bacteriana, o que pode ter um impacto psicológico profundo tanto nos pacientes quanto em seus cuidadores.

No contexto clínico, a avaliação manual tradicional dessas feridas apresenta várias limitações. O processo é intrinsecamente subjetivo, dependendo amplamente da experiência e da percepção individual do profissional de saúde. Esta subjetividade pode levar a variações consideráveis na avaliação, dificultando o estabelecimento de um plano de tratamento consistente e eficaz. Além disso, a avaliação manual é frequentemente morosa, exigindo tempo considerável tanto para a inspeção visual quanto para o toque cuidadoso, visando evitar dor adicional ou sangramento no paciente.

O problema da segmentação de imagens médicas, como o de feridas malignas, é um desafio importante na área da saúde. A segmentação refere-se ao processo de identificar e delimitar as áreas de interesse em uma imagem, neste caso, as áreas afetadas por feridas malignas. A segmentação precisa é fundamental para o diagnóstico e tratamento adequados, pois permite que os médicos e profissionais de saúde avaliem com precisão

o tamanho, a forma e a localização das feridas. No entanto, a segmentação neste contexto é um problema complexo devido à variação na aparência e forma das feridas, bem como à presença de ruído e artefatos nas imagens. Além disso, a segmentação manual é um processo demorado e sujeito a erros, o que pode levar a diagnósticos imprecisos e tratamentos inadequados. Por isso, a utilização de algoritmos de aprendizado profundo, como os explorados neste estudo, pode ser uma solução promissora para a segmentação de feridas malignas em imagens médicas.

A precisão da avaliação manual também é uma preocupação, já que imprecisões podem levar a diagnósticos errôneos ou a atrasos no tratamento adequado. Devido à complexidade e à natureza dinâmica dessas feridas malignas, é imperativo buscar métodos que possam complementar ou melhorar a precisão da avaliação clínica [de Oliveira Santos et al. 2023]. Portanto, torna-se essencial explorar novas tecnologias e abordagens, como as Redes Neurais Convolucionais, para melhorar a precisão e a eficiência na avaliação destas feridas desafiadoras.

Assim, este trabalho tem como objetivo explorar o uso de algoritmos de aprendizado profundo para a segmentação automática de feridas malignas em imagens médicas. Acreditamos que a utilização desses algoritmos pode ajudar a melhorar a eficiência e precisão do diagnóstico e tratamento de feridas malignas, além de reduzir o tempo e o esforço necessários para a segmentação manual. Além disso, a segmentação automática pode ser a primeira etapa de um sistema de análise automática de feridas, permitindo que as etapas subsequentes se concentrem apenas na área da ferida, sem serem afetadas por artefatos que não fazem parte da ferida.

1.2. Questões de Pesquisa

A investigação explora se o Convolutional Neural Network (CNN) pode melhorar significativamente a precisão na avaliação de feridas malignas e se a sua integração na prática clínica pode acelerar o processo de cicatrização e otimizar o tratamento. O estudo adaptará uma abordagem quantitativa, utilizando técnicas avançadas de Inteligência Artificial (IA) para analisar imagens de feridas malignas. A eficácia da CNN será avaliada através da comparação dos resultados com as avaliações manuais tradicionais.

1.3. Objetivo Geral

Este estudo busca avaliar a eficiência e aplicabilidade de modelos de aprendizado profundo, especificamente CNN, na segmentação de feridas malignas em imagens médicas, com foco na precisão dos resultados.

1.4. Objetivos Específicos

Este estudo tem como objetivo investigar a aplicação e eficácia das CNN na segmentação de feridas malignas. O objetivo é otimizar o tratamento através de avaliações mais preci-

sas e objectivas, desenvolver ferramentas de apoio que possam ser integradas na prática clínica, melhorar os cuidados e acelerar a cicatrização.

- Implementar modelos de aprendizado profundo, como FCN¹, U-Net², SegNet³ e MobileNetV2⁴, para a segmentação de feridas malignas em imagens médicas.
- Otimizar o pré-processamento das imagens para melhorar a precisão e eficiência dos modelos.
- Avaliar o desempenho dos modelos com base em métricas como Loss, Precision, Recall e Coeficiente de Dice.
- Comparar a eficácia das diversas arquiteturas de aprendizado profundo na tarefa de segmentação.
- Fornecer diretrizes para futuras pesquisas em segmentação de imagens médicas com aprendizado profundo.
- Contribuir para a oncologia cutânea, desenvolvendo ferramentas automáticas e eficientes para a segmentação de feridas malignas.

1.5. Estrutura do TCC

A estrutura deste trabalho segue uma progressão lógica e abrangente. Iniciando com esta introdução, o TCC segue algumas etapas:

Revisão da literatura, a qual oferece uma análise detalhada dos estudos relacionados à segmentação de feridas malignas em imagens médicas. Este capítulo aborda os principais desafios encontrados na área e explora as técnicas mais utilizadas, oferecendo um panorama abrangente do estado da arte.

A metodologia é então apresentada, detalhando o processo adotado para a realização deste estudo. Este capítulo engloba desde a coleta até o pré-processamento dos dados, a seleção dos modelos de aprendizado profundo e os parâmetros de treinamento, além de descrever as métricas de avaliação utilizadas para analisar o desempenho dos modelos.

Os resultados obtidos pelos modelos de aprendizado profundo avaliados neste estudo são minuciosamente apresentados, incluindo métricas essenciais como Precisão, Recall, Coeficiente Dice e a perda associada a cada modelo. Esses resultados são então discutidos em profundidade, considerando suas implicações para a segmentação de feridas malignas em imagens médicas, bem como destacando as limitações e possíveis direções para pesquisas futuras.

Por fim, o trabalho conclui com um capítulo de conclusões, ressaltando os insights e descobertas mais significativos e fornecendo recomendações valiosas para investigações posteriores na área. Esta estrutura oferece uma abordagem abrangente e analítica, permitindo uma compreensão profunda e crítica do tema explorado ao longo deste TCC.

¹<https://paperswithcode.com/method/fcn>

²<https://paperswithcode.com/method/u-net>

³<https://paperswithcode.com/method/segnet>

⁴<https://paperswithcode.com/method/mobilenetv2>

2. FUNDAMENTAÇÃO TEÓRICA

2.1. Feridas Crônicas e Malignas

Feridas crônicas e malignas constituem um desafio notável na estomaterapia⁵, exigindo uma compreensão profunda de suas características patológicas e implicações clínicas.

Feridas crônicas são definidas pela sua persistência além do tempo de cicatrização esperado, frequentemente excedendo três meses. A fisiopatologia subjacente é complexa, envolvendo inflamação crônica, angiogênese prejudicada e imunossupressão local. Estas características diferenciam as feridas crônicas das agudas e exigem uma abordagem terapêutica diferenciada.

As feridas malignas, um subconjunto específico de feridas crônicas, têm uma prevalência significativa, especialmente em populações com doenças crônicas subjacentes, como diabetes mellitus e imunossupressão. Elas representam um desafio tanto para o sistema de saúde quanto para os indivíduos afetados devido ao seu impacto na morbidade e mortalidade. A análise epidemiológica dessas feridas é fundamental para entender sua distribuição e fatores de risco.

No manejo de feridas malignas, a seleção de terapias apropriadas, incluindo agentes tópicos, terapias avançadas de cicatrização e abordagens cirúrgicas, é crítica. A gestão da dor e a prevenção de infecções secundárias são aspectos igualmente importantes. A terapia deve ser personalizada, considerando as características específicas da ferida e as condições do paciente.

As feridas malignas afetam profundamente a qualidade de vida dos pacientes, com implicações significativas na saúde mental, autoestima e capacidade funcional. Além do tratamento físico, é essencial abordar os aspectos psicológicos e sociais, fornecendo suporte emocional e psicossocial adequado.

A precisão na segmentação de feridas malignas em imagens médicas é crucial, não apenas para o diagnóstico e tratamento eficaz, mas também para a avaliação da progressão da doença e resposta ao tratamento. Esta precisão contribui significativamente para estratégias terapêuticas mais eficientes e personalizadas, impactando positivamente a recuperação e a qualidade de vida dos pacientes.

2.2. Avaliação e Manejo de Feridas

A avaliação e manejo de feridas representam áreas cruciais na prática médica, abrangendo desde métodos tradicionais de observação visual até técnicas avançadas de tratamento. Ao entender a diversidade de técnicas abordados a seguir, torna-se possível compreender a complexidade envolvida no diagnóstico e tratamento de feridas, oferecendo insights valiosos para a prática médica contemporânea.

⁵Especialidade da enfermagem que se dedica ao cuidado de pacientes com estomas, feridas agudas ou crônicas, incontinência fecal ou urinária, e outras condições relacionadas ao trato gastrointestinal, urogenital e integumentar

Métodos Tradicionais de Avaliação de Feridas: Os métodos tradicionais englobam técnicas que vão desde a observação visual até medições físicas. A inspeção visual é a forma mais básica de avaliação, onde profissionais de saúde examinam a aparência da ferida, observando características como tamanho, forma, cor, presença de tecido necrótico e exsudato. Além disso, a medição de áreas é feita para determinar a extensão da ferida, utilizando técnicas como planimetria e fotografia associada a software especializado. Esses métodos constituem a base da avaliação, permitindo o acompanhamento da progressão da ferida ao longo do tempo.

Parâmetros para Avaliação Clínica de Feridas: Durante a avaliação clínica, diversos parâmetros são considerados para determinar a condição e o progresso da ferida. Isso inclui a identificação da presença de infecção, analisando sinais como inflamação, calor, rubor, edema e dor. Além disso, a extensão da lesão é avaliada quanto à profundidade, dimensões e possíveis complicações, como formação de tecido de granulação e presença de bordas irregulares. A resposta ao tratamento também é monitorada, verificando se a ferida está cicatrizando de maneira eficaz.

Técnicas Avançadas de Tratamento de Feridas: As técnicas avançadas compreendem uma variedade de abordagens inovadoras para promover a cicatrização de feridas complexas. Isso inclui terapias tópicas, como o uso de substâncias bioativas, terapias de pressão negativa, que estimulam a circulação e removem fluidos da ferida, e terapias com oxigenação hiperbárica, que fornecem oxigênio em altas concentrações para acelerar a cicatrização. Essas técnicas representam um avanço considerável no manejo de feridas, oferecendo opções além dos métodos convencionais.

Diretrizes e Protocolos no Manejo de Feridas Malignas: Diretrizes e protocolos específicos são estabelecidos para lidar com feridas malignas, visando um diagnóstico precoce e um tratamento eficaz. Essas diretrizes definem critérios para identificar feridas malignas, estabelecem estratégias de tratamento e monitoramento, e fornecem orientações para o manejo de complicações, garantindo uma abordagem consistente e baseada em evidências.

Tecnologias Emergentes no Tratamento de Feridas: Tecnologias emergentes estão trazendo avanços significativos no tratamento de feridas, incluindo curativos inteligentes, que monitoram e reagem dinamicamente ao ambiente da ferida, e terapias de regeneração de tecidos, que estimulam o crescimento celular e a cicatrização de maneira mais eficiente. Além disso, há pesquisas em andamento para desenvolver abordagens personalizadas, utilizando impressão 3D para criar curativos adaptados às características únicas da ferida.

Esses pontos representam a diversidade e a complexidade das técnicas e abordagens disponíveis para a avaliação e tratamento de feridas. Desde métodos tradicionais até as mais avançadas tecnologias emergentes, o campo da medicina de feridas está constantemente evoluindo para oferecer soluções mais eficazes e personalizadas para os pacientes.

2.3. Aplicações de IA no Diagnóstico e Tratamento Médico

A evolução da IA revolucionou o cenário médico, proporcionando uma gama diversificada de aplicações no diagnóstico e tratamento. Neste contexto é explorado o impacto da IA

na medicina, abordando desafios éticos, tecnologias como CNN e seu desenvolvimento para segmentação de feridas. Também considera a comparação entre a avaliação manual e automatizada, bem como perspectivas futuras para aprimorar o cuidado ao paciente.

Desafios e Considerações Éticas da IA na Saúde: na aplicação da IA na saúde, surgem desafios éticos significativos. A privacidade do paciente é crucial, exigindo medidas rigorosas para proteger e anonimizar os dados. Além disso, a interpretabilidade dos algoritmos de IA é essencial para garantir que os profissionais possam compreender e confiar nas decisões tomadas pelos modelos. Questões de responsabilidade clínica também são pertinentes, pois os resultados gerados pela IA influenciam as decisões dos profissionais de saúde.

CNNs: são um tipo de arquitetura de rede neural fundamental na análise de imagens médicas. Elas são projetadas para aprender padrões complexos e hierárquicos, identificando características e relações importantes entre os pixels das imagens. No contexto da segmentação de feridas malignas, as CNNs são altamente eficazes na identificação e delimitação dessas regiões em imagens médicas.

Desenvolvimento de Modelos de CNN para Segmentação de Feridas: para criar um modelo de CNN para a segmentação de feridas, é necessário coletar um conjunto de dados diversificado e anotado com precisão. Esse conjunto passa por etapas de pré-processamento para padronizar a qualidade das imagens e normalizar os dados. O treinamento do modelo envolve alimentar a CNN com dados anotados para que ela possa aprender a identificar e segmentar as regiões de feridas malignas.

Segmentação de Feridas: A segmentação de feridas é uma técnica de processamento de imagens que tem como objetivo identificar e delimitar as áreas afetadas por feridas em imagens médicas. Essa técnica é importante porque permite que os médicos e profissionais de saúde possam avaliar com precisão o tamanho, a forma e a localização das feridas, o que é fundamental para o diagnóstico e tratamento adequados. Na prática, a segmentação de feridas envolve a aplicação de algoritmos de aprendizado profundo em imagens médicas de feridas. Esses algoritmos são treinados em um conjunto de dados de imagens rotuladas, ou seja, imagens que já foram previamente segmentadas por especialistas em feridas. Com base nesse conjunto de dados, o algoritmo é capaz de aprender a identificar as características das feridas e segmentá-las em novas imagens.

Comparação de Desempenho: ao comparar a segmentação manual com a automatizada na segmentação de feridas malignas em imagens médicas, é essencial considerar vários aspectos. A precisão e o recall, medindo a capacidade de identificação e abrangência das feridas, são vitais. Enquanto a segmentação manual é trabalhosa e subjetiva, a automação por IA, neste trabalho de segmentação de imagens, oferece eficiência, consistência e potencial de generalização com base no treinamento. Contudo, a validação clínica é crucial para garantir que os resultados automatizados sejam clinicamente relevantes e confiáveis, alinhados às necessidades dos profissionais de saúde e dos pacientes.

Integração de CNNs na Prática Clínica: a integração bem-sucedida de CNNs na prática clínica envolve a validação dos modelos em ambientes clínicos reais. Isso inclui testes para verificar se os modelos são clinicamente relevantes, fáceis de interpretar e úteis para os profissionais de saúde, contribuindo para decisões mais precisas e eficazes.

Perspectivas Futuras e Potencial de Melhoria no Cuidado ao Paciente: as pers-

pectivas futuras se concentram na contínua evolução da IA na área médica. Isso inclui aprimoramentos nos modelos de CNN, a exploração de técnicas mais avançadas de aprendizado de máquina e a integração da IA em sistemas de saúde para um cuidado mais personalizado e preciso aos pacientes.

Esses pontos destacam a relevância da IA na segmentação de feridas malignas e evidenciam os desafios, considerações éticas e potenciais benefícios na aplicação dessas tecnologias na prática clínica.

2.4. Arquiteturas de Redes Neurais

As arquiteturas de redes neurais são estruturas organizadas de neurônios artificiais, modeladas com base no funcionamento do cérebro humano. No contexto da segmentação de imagens médicas, essas arquiteturas são adaptadas para analisar e compreender visualmente as informações contidas nessas imagens.

As CNNs são altamente eficazes na análise de imagens devido à sua capacidade de preservar a relação espacial entre os pixels. Elas usam camadas convolucionais para extrair características hierárquicas das imagens, seguidas por camadas de pooling para reduzir a dimensionalidade e camadas totalmente conectadas para classificação ou segmentação.

Redes Neurais Recorrentes (RNNs): As RNNs são ideais para lidar com sequências de dados, como texto ou séries temporais médicas. Sua estrutura permite que informações sejam lembradas e aplicadas em etapas posteriores, sendo úteis em tarefas de previsão e análise temporal.

Redes Generativas Adversariais (GANs): As GANs consistem em duas redes neurais, um gerador e um discriminador, que competem entre si. Elas são usadas para criar novos dados realistas a partir de um conjunto de dados existente, sendo aplicáveis na geração de imagens médicas sintéticas para treinamento de modelos ou na correção/aperfeiçoamento de imagens existentes.

Fully Convolutional Network (FCN): As FCNs são arquiteturas especialmente concebidas para tarefas de segmentação e localização em imagens. Diferentemente das redes convolucionais convencionais, as FCNs mantêm a estrutura completa das redes neurais convolucionais, porém substituem as camadas totalmente conectadas por convoluções globais, permitindo que a rede seja aplicada a imagens de qualquer tamanho.

U-Net: A U-Net é conhecida por sua eficácia em tarefas de segmentação semântica em imagens médicas. Sua arquitetura se assemelha à letra "U", com uma estrutura de codificação para a extração de características e uma estrutura de decodificação para reconstruir a imagem segmentada. Ela também incorpora conexões residuais entre camadas correspondentes, permitindo a preservação de detalhes durante a reconstrução.

SegNet: A SegNet é uma arquitetura de segmentação de imagens que se concentra na eficiência computacional. Ela utiliza um codificador convolucional para extrair características e um decodificador que mapeia características para a imagem segmentada. Seu destaque é o uso de mapas de índice durante a etapa de decodificação, ajudando na

reconstrução da imagem.

MobileNetV2: Esse modelo foi projetado para ser mais leve e eficiente, ideal para aplicativos móveis e tarefas em dispositivos com recursos limitados. Ele utiliza operações de convolução separável em largura e em profundidade para reduzir a complexidade computacional, mantendo um bom desempenho em tarefas de visão computacional, embora possa não ser ideal para segmentação detalhada de imagens médicas devido à sua arquitetura mais simplificada.

Esse conhecimento arquitetural é fundamental para entender o funcionamento dos modelos de Machine Learning utilizados no estudo. Ao explorar as técnicas de rede neural, podemos avaliar a eficiência e aplicabilidade de diferentes modelos de aprendizado profundo, como U-Net, SegNet, FCN e MobileNetV2, na identificação rápida e precisa de feridas malignas. Isso poderá resultar em tratamentos mais eficientes e prognósticos mais positivos para os pacientes.

2.5. Métricas

No contexto de segmentação de imagens, as métricas são usadas para avaliar o quão bem o modelo está segmentando as áreas de interesse na imagem, como as áreas de feridas malignas. As métricas podem ser usadas para avaliar diferentes aspectos do desempenho do modelo, como precisão, completude, acurácia e similaridade com a segmentação manual. Ao avaliar as métricas, os pesquisadores podem determinar quais modelos são mais eficazes na segmentação de feridas malignas e ajudar a melhorar a precisão e eficiência dos modelos de Machine Learning. As métricas utilizadas neste estudo foram Loss, Precision, Recall e Coeficiente de Dice.

Loss (Perda): É uma medida que quantifica o erro entre a segmentação produzida pelo modelo e a segmentação esperada. Geralmente, ela é calculada durante o treinamento do modelo, ajudando a ajustar os pesos da rede neural para minimizar esse erro. A redução da Loss indica uma melhor adaptação do modelo aos dados de treinamento.

Precision (Precisão): Essa métrica mede a proporção de pixels corretamente classificados como feridas malignas em relação ao total de pixels identificados pelo modelo como feridas malignas. Ela destaca a capacidade do modelo em não classificar incorretamente pixels saudáveis como feridas malignas.

Recall (Revocação): Refere-se à proporção de pixels de feridas malignas corretamente identificados pelo modelo em relação ao total de pixels de feridas malignas na imagem. Essa métrica destaca a habilidade do modelo em identificar corretamente a área das feridas malignas.

O Coeficiente de Dice: É uma métrica de similaridade que compara a segmentação produzida pelo modelo com a segmentação manual. Quanto mais próxima de 1, maior a sobreposição entre as duas segmentações. É especialmente útil quando há desequilíbrio entre as classes, como uma pequena quantidade de pixels de feridas malignas em relação ao total da imagem.

3. TRABALHOS RELACIONADOS

Esta seção apresenta estudos relacionados ao uso de CNN para a segmentação de imagens médicas, oferecendo um panorama das pesquisas recentes e estabelecendo um comparativo com o presente trabalho. É também demonstrado as bases de dados exploradas em cada estudo. Podemos ver essa análise na tabela 1.

Tabela 1. Análise Comparativa dos Trabalhos Relacionados

Autores	Datasets				Models			
	Wound Segmentation	WSNET	Venous leg ulcers and arterial leg ulcers	Foot Wounds and Ulcers	U-Net	SegNet	MobileNetV2	FCN
[Li et al. 2020]	X				X		X	
[Silva et al. 2021]	X						X	X
[Liu et al. 2021]	X			X		X		X
[Akay et al. 2021]			X				X	
[Mahbod et al. 2022]	X				X			
[Prakash et al. 2023]		X			X			X
Nosso trabalho	X	X	X	X	X	X	X	X

Em 2020, Li et al, propuseram uma abordagem inovadora para a segmentação automática de feridas em imagens naturais, utilizando uma rede neural profunda com base no modelo MobileNetV2. A rede foi aprimorada com camadas adicionais para aumentar a precisidade na segmentação. Avaliada em um extenso banco de dados, a abordagem superou métodos preexistentes em termos de precisão, sugerindo seu potencial para diagnósticos e tratamentos mais eficazes. [Li et al. 2020]

Silva e colaboradores, em 2021, avaliaram dois modelos de aprendizado profundo, U-Net e DeeplabV3, para segmentação de feridas malignas cutâneas. Utilizando um conjunto de dados do AZH Wound and Vascular Center, o modelo U-Net demonstrou superioridade, enquanto o DeeplabV3 mostrou-se competitivo. O estudo também explorou a relação entre acurácia e eficiência computacional, apontando para futuras pesquisas focadas na compactação de redes neurais para dispositivos com restrições de hardware. [Silva et al. 2021]

No mesmo ano, Liu et al, realizaram uma revisão sistemática sobre metodologias computacionais aplicadas à medição e diagnóstico de feridas, destacando o papel das tecnologias de IA. A revisão abrangeu mais de 250 artigos, dos quais 115 foram selecionados por sua relevância. O estudo enfatizou a importância das tecnologias emergentes para a avaliação de feridas, concluindo que elas podem aumentar a precisão e eficiência no tratamento. [Liu et al. 2021]

Em 2021 Akay, M., Du, Y, apresentou uma nova rede de aprendizado profundo para a caracterização da pele de pacientes com Esclerose Sistêmica (SSc), uma doença autoimune rara. A rede proposta é baseada no modelo MobileNetV2 e é capaz de realizar a classificação de imagens de pele com alta precisão, o que pode ajudar no diagnóstico precoce da doença. O artigo discute os desafios enfrentados na aplicação de redes neurais profundas em aplicações médicas, como a falta de dados de treinamento e a necessidade de computação de alto desempenho. A rede proposta é projetada para trabalhar com poucas imagens de treinamento e fornecer classificações mais precisas. [Akay et al. 2021]

No ano de 2022 o Mahbod et al, propôs um método de segmentação automática

de úlceras nos pés usando uma abordagem de conjunto de redes neurais convolucionais (CNNs). O método proposto utiliza dois modelos de CNN, o LinkNet e o U-Net, para melhorar a precisão da segmentação de úlceras nos pés. O LinkNet e o U-Net são modelos de CNN baseados em codificador-decodificador que têm mostrado excelente desempenho em tarefas de análise de imagens médicas, incluindo segmentação de imagens médicas. [Mahbod et al. 2022]

Recentemente, em 2023, Prakash et al, introduziram um framework de aprendizado profundo para a segmentação automática de lesões em imagens de ressonância magnética. O framework GA-UNet mostrou-se eficaz na segmentação e quantificação de áreas afetadas por lesões cerebrais traumáticas, ressaltando a importância da segmentação precisa para intervenções terapêuticas. [Prakash et al. 2023]

3.1. Limitação dos Trabalhos Relacionados

A literatura existente sobre a utilização de CNNs para segmentação de imagens médicas revela avanços significativos, no entanto, persistem lacunas importantes. Muitos estudos focam no desenvolvimento de modelos sem abordar integralmente as complexidades inerentes às imagens médicas, como variações na forma, tamanho e textura das lesões. Essa limitação pode resultar em imprecisões na segmentação, afetando diretamente a qualidade do diagnóstico e do tratamento. Além disso, a heterogeneidade dos dados clínicos, que inclui variáveis como diferentes tipos de lesões, a qualidade das imagens e a diversidade dos pacientes, não é suficientemente considerada. Essa negligência pode comprometer a capacidade de generalização dos modelos e sua eficácia em ambientes clínicos reais, que apresentam uma gama mais ampla de variáveis.

Outro ponto crítico é a falta de comparação abrangente com outros métodos de segmentação de imagens. A ênfase predominante em modelos de aprendizado profundo sem análises comparativas limita a compreensão da eficácia relativa desses métodos frente a abordagens tradicionais, como as baseadas em regras ou em detecção de bordas. Por fim, a validação dos modelos em condições clínicas reais é frequentemente insuficiente, levando a uma compreensão limitada da aplicabilidade prática dessas soluções. Muitos estudos se concentram em ambientes controlados de laboratório, sem testar a robustez e a adaptabilidade dos modelos em situações clínicas mais variadas e imprevisíveis.

3.2. Diferencial do Nosso Trabalho

Em nosso estudo, propomos uma abordagem inovadora e abrangente para a segmentação de feridas malignas em imagens médicas, combinando a eficiência de múltiplos modelos de aprendizado profundo com técnicas avançadas de pré-processamento de imagens. Investigamos especificamente a aplicabilidade de quatro modelos de CNN: FCN, U-Net, SegNet e MobileNetV2. - para abordar as limitações identificadas em trabalhos anteriores.

Diferenciando-nos, empregamos um conjunto de dados clínicos heterogêneo que abrange uma ampla gama de tipos de lesões, idades de pacientes e níveis de gravi-

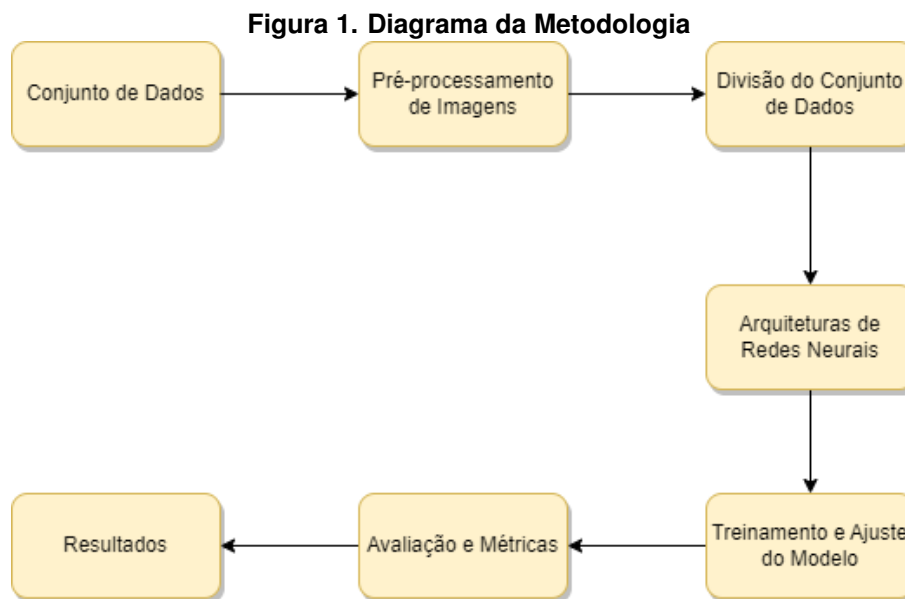
dade. Essa diversidade garante uma avaliação mais representativa dos modelos em cenários clínicos variados. Ademais, aplicamos técnicas de pré-processamento como normalização, aumento de dados e segmentação manual para melhorar a qualidade e consistência dos dados, aumentando assim a precisão e a generalização dos modelos.

Utilizamos uma metodologia de validação cruzada estratificada, garantindo uma avaliação equitativa e abrangente dos modelos em diferentes conjuntos de dados. Essa abordagem assegura que os modelos sejam testados em condições diversas, refletindo melhor a realidade clínica.

Os resultados evidenciaram que nossa metodologia não só alcança uma alta precisão na segmentação de feridas malignas mas também demonstra uma notável capacidade de generalização em diversos cenários clínicos. Isso sugere que nossa abordagem tem um potencial significativo para aplicação em contextos médicos variados, contribuindo para diagnósticos e tratamentos mais precisos e eficazes.

4. METODOLOGIA

Neste projeto de pesquisa foi empregado diversos modelos de aprendizagem profunda, tais como FCN, U-Net, SegNet e MobileNetV2, para segmentar feridas malignas em imagens médicas. Utilizaremos um grande conjunto de dados que reuniu uma junção de vários dataset de feridas. As imagens, que apresentam diversas formas e variações, serão pré-processadas antes do treinamento. Avaliaremos quantitativamente a performance dos modelos com base na área da ferida, precisão e eficiência do modelo na segmentação das imagens. A Figura 1 demonstra o fluxograma da metodologia aplicada.



4.1. Conjunto de Dados

O conjunto de dados deste estudo compreende imagens de feridas malignas coletadas de diversas fontes, incluindo repositórios públicos no GitHub e sites especializados em imagens médicas. Selecionamos mais de 4.800 imagens para treinar, validar e testar os modelos de aprendizado profundo, considerando a diversidade de tipos de feridas malignas e a qualidade das imagens. A utilização de um conjunto de dados amplo e diversificado contribuirá para aprimorar os resultados deste estudo e desenvolver modelos de aprendizado profundo mais eficazes na segmentação de feridas malignas.

4.2. Criação do Conjunto de Dados

- Tipo de imagens: As imagens médicas incluídas neste conjunto abrangem diversos tipos, tais Feridas de úlceras em pé diabéticos, lesões com cortes profundas e feridas crônicas em diversas partes do corpo. Suas características, como resolução, dimensões e formato de arquivo, são especificadas para proporcionar uma com-

preensão detalhada. Detalhamos o processo de aquisição, incluindo informações sobre o equipamento utilizado, configurações e protocolos adotados para a captura dessas imagens médicas.

- **Pré-processamento e Anotação:** Descrevemos as técnicas de pré-processamento aplicadas, como normalização e aumento de dados, ressaltando a importância dessas etapas na preparação das imagens para análise. O processo de anotação é abordado, incluindo responsáveis e critérios utilizados. Foi abordado nos dados sobre a diversidade do conjunto, considerando variabilidade em condições médicas, faixas etárias, gêneros e outros fatores relevantes, garantindo representatividade.
- **Volume de Dados:** Informamos a quantidade total de imagens e casos incluídos no dataset, proporcionando uma visão abrangente de sua robustez e amplitude. Consideramos mais de 4.800 imagens no dataset de diferentes fontes públicas e de diferentes condições clínicas para atender a heterogeneidade dos dados.
- **Questões Éticas e de Privacidade:** Abordamos as questões éticas, incluindo o consentimento informado, os processos de anonimização de dados e a conformidade com regulamentos de privacidade e proteção de dados.
- **Qualidade e Confiabilidade dos Dados:** Sobre a qualidade das imagens, considerando resolução e clareza, e a confiabilidade das anotações. Destacamos qualquer validação realizada por especialistas médicos para assegurar a precisão.
- **Disponibilidade e Acesso:** Fornecemos informações sobre a disponibilidade pública do dataset, incluindo detalhes sobre como acessá-lo, bem como eventuais restrições ou requisitos associados.
- **Potenciais Aplicações e Limitações:** Descrevemos possíveis aplicações do conjunto de dados em modelos de visão computacional, destacando suas potencialidades. Além disso, discutimos abertamente quaisquer limitações conhecidas ou possíveis vieses que devem ser considerados durante o uso do dataset.

4.3. Pré-processamento de Imagens

Primeiramente, as imagens foram redimensionadas para uma resolução de 256x256 pixels, a fim de padronizar o tamanho das imagens e facilitar o processamento pelos modelos. Em seguida, os valores de pixel foram normalizados para o intervalo $[0, 1]$, a fim de garantir que todas as imagens tivessem a mesma escala de intensidade.

Além disso, foram aplicadas técnicas de aumento de dados, como rotação, inversão horizontal e zoom, para aumentar a diversidade do conjunto de dados e evitar overfitting. Essas técnicas permitem que os modelos aprendam a reconhecer as características das feridas malignas em diferentes posições e escalas.

É importante destacar que não foram aplicados filtros de suavização nas imagens, a fim de preservar as características originais das feridas. Isso é importante para garantir que os modelos aprendam a reconhecer as características específicas das feridas malignas e não sejam influenciados por artefatos de imagem.

Essas são etapas fundamentais no treinamento de modelos de aprendizado profundo para a segmentação de feridas malignas. Elas permitem que os modelos aprendam a reconhecer as características das feridas malignas de forma mais eficiente e precisa,

resultando em segmentações mais precisas e confiáveis.

4.4. Divisão do Conjunto de Dados

A divisão do conjunto de dados foi realizada de forma estratificada, garantindo uma distribuição uniforme das classes de feridas malignas em cada subconjunto. Essa metodologia é crucial para manter a representatividade e o equilíbrio do conjunto de dados, minimizando possíveis vieses e reforçando a confiabilidade dos resultados. O conjunto foi dividido em dois grupos principais: treinamento e teste. O grupo de treinamento desempenhou um papel vital no processo de aprendizagem dos modelos de aprendizado profundo, enquanto o grupo de teste foi empregado para avaliar a eficácia dos modelos em dados novos e não vistos anteriormente. A divisão foi realizada aleatoriamente, mas com o cuidado de manter as proporções de cada classe de feridas malignas em cada segmento. Esse cuidado assegura que tanto o treinamento quanto a avaliação dos modelos ocorram em um ambiente de dados bem balanceado e representativo, crucial para a obtenção de resultados confiáveis e precisos.


4.5. Arquiteturas de Redes Neurais

Para realizar a segmentação das feridas malignas cutâneas, foram exploradas quatro arquiteturas de redes neurais convolucionais:

4.5.1. FCN

A arquitetura FCN, representada abaixo na figura 2, é conhecida por sua capacidade de realizar a segmentação semântica em imagens. Ela consiste em uma rede neural convolucional totalmente composta por camadas convolucionais, sem camadas totalmente conectadas.

Figura 2. Representação Esquemática da Arquitetura FCN. adaptada de ([Long et al. 2015])




A Figura 2 acima, apresenta a arquitetura de uma rede FCN utilizada para tarefa de segmentação semântica (semantic segmentation), isto é, classificar cada pixel da imagem de entrada de acordo com a classe que ele pertence, sendo: cama, pé ou ferida (background). Conforme a arquitetura apresentada na Figura, existem várias camadas de convolução que produzirão mapas de características de diferentes profundidades. No final da rede, encontra-se a previsão pixelwise (pixelwise prediction) que também é um tipo de camada de convolução e que irá fazer uma previsão pixel-a-pixel, isto é, atribuindo cada pixel a uma respectiva classe. Esta representação ilustra de forma esquemática a arquitetura FCN, mostrando as camadas convolucionais e suas dimensões. Essa arquitetura é capaz de extrair as características mais importantes das imagens de feridas malignas, permitindo que a rede aprenda a segmentar essas feridas com precisão.

4.5.2. U-Net

A arquitetura U-Net, ilustrada na figura 3 abaixo, é amplamente utilizada para tarefas de segmentação em imagens biomédicas. Ela possui uma estrutura em forma de U, com um encoder para capturar informações contextuais e um decoder para reconstruir a máscara de segmentação. A U-Net é conhecida por sua capacidade de segmentação precisa e é aplicada com sucesso em diversos problemas de segmentação, incluindo a segmentação de feridas medicas.

Figura 3. Representação Esquemática da Arquitetura U-Net. adaptada de ([Ronneberger et al. 2015])



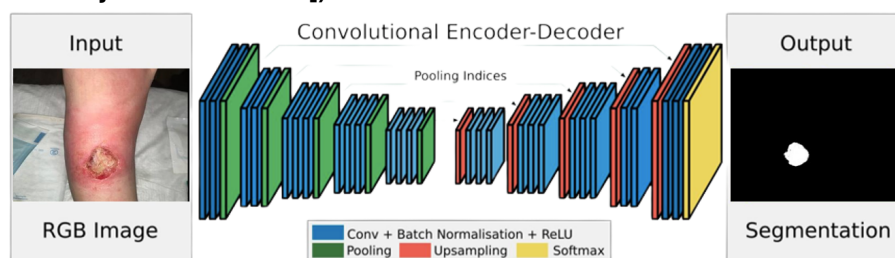
A Figura 3 ilustra a arquitetura da rede U-Net, em que cada caixinha azul presente na imagem corresponde a um mapa de característica multicanal (multichannel feature map). O número de cada canal está descrito no valor acima de cada caixa. No canto inferior esquerdo é dada a dimensão x-y da imagem. As caixas brancas representam a cópia dos mapas de características (feature maps) e cada flecha com sua respectiva cor representa uma operação diferente. Na parte direita da rede as flechas verdes referem-se ao caminho de expansão onde é utilizado a operação de up-convolution, também chamada

de de-convolution6 ou transposed convolution. A figura ilustra essa arquitetura de forma esquemática, mostrando as camadas convolucionais, as camadas de pooling máximo e up-sampling, e as conexões laterais entre as camadas do caminho de contração e do caminho de expansão.

4.5.3. SegNet

O modelo SegNet, representado na figura 4 abaixo, é baseado em uma arquitetura de codificador-decodificador. Cada codificador aplica convolução, normalização de lote e uma não linearidade, e depois aplica um pool máximo no resultado, enquanto armazena o índice do valor extraído de cada janela. Os decodificadores são semelhantes aos codificadores, a diferença é que eles não têm uma não linearidade e aumentam a amostra de entrada, usando índices armazenados a partir do estágio de codificação.

Figura 4. Representação Esquemática da Arquitetura SegNet. adaptada de ([Badrinarayanan et al. 2017])




A Figura 4 ilustra essa arquitetura de forma esquemática, mostrando as camadas de codificação e decodificação, bem como as conexões entre elas. Cada caixa na figura representa uma camada de convolução, normalização de lote e não linearidade, enquanto as setas representam as conexões entre as camadas. As camadas de pooling máximo são representadas pelas caixas de cor verde. Além disso, a figura também mostra a saída da rede, que é uma imagem segmentada com as áreas de feridas malignas destacadas em branco. Essa saída é gerada pela última camada de decodificação da rede. Em resumo, a Figura ilustra de forma esquemática a arquitetura SegNet, mostrando as camadas de codificação e decodificação, bem como as conexões entre elas. Essa arquitetura é capaz de segmentar com precisão as feridas malignas em imagens médicas, como mostrado nos resultados do estudo.

4.5.4. MobileNetV2

O MobileNetV2, representada na figura 5 abaixo, é uma arquitetura de rede neural convolucional projetada para tarefas de classificação e segmentação em dispositivos com recursos computacionais limitados. Essa arquitetura utiliza camadas convolucionais separáveis em profundidade para obter um bom equilíbrio entre a precisão do modelo e a eficiência computacional.

Figura 5. Representação Esquemática da Arquitetura MobileNetV2. adaptada de ([Akay et al. 2021])



A Figura 5 ilustra essa arquitetura de forma esquemática, mostrando as camadas convolucionais e suas dimensões. A imagem de entrada é uma imagem de ferida com dimensões 128x128x3, que é processada pela primeira camada convolucional com dimensões 128x128 e um número de filtros (ou canais) igual a 32. Em seguida, a imagem é processada por uma segunda camada convolucional com dimensões 64x64 e um número de filtros igual a 32. Depois disso, a imagem é processada por várias camadas convolucionais com dimensões 32x32 e 96 filtros, que são responsáveis por extrair características mais complexas da imagem. Essas camadas são seguidas por uma camada convolucional com dimensões 4x4 e um número de filtros igual a 1280, que é responsável por extrair as características mais importantes da imagem. Por fim, a saída da última camada convolucional é processada por uma rede fully connected com um número de neurônios igual a 1280, que é responsável por gerar a saída final da rede.

4.6. Treinamento e Ajuste do Modelo

Durante o processo de treinamento, utilizamos um conjunto de imagens de feridas malignas criado para ensinar os modelos a segmentar essas feridas com precisão. Para isso, dividimos o conjunto de imagens em conjuntos de treinamento e teste, e utilizamos técnicas de data augmentation para aumentar a diversidade do conjunto de treinamento.

Além disso, aplicamos técnicas de poda nos modelos abordados, com o objetivo de reduzir o número de parâmetros e melhorar a eficiência computacional dos modelos. A técnica de poda consiste em remover os pesos menos importantes dos modelos, mantendo apenas os pesos mais importantes. Isso permite que os modelos sejam mais eficientes em termos de memória e processamento, sem comprometer a precisão da segmentação.

Durante o processo de ajuste, utilizamos o conjunto de dados para ajustar os hiperparâmetros dos modelos e evitar overfitting. Ajustamos os hiperparâmetros como taxa de aprendizado, tamanho do batch e número de épocas de treinamento, com o objetivo de obter a melhor precisão de segmentação possível.

4.7. Avaliação e Métricas

Para avaliar a eficácia dos modelos de segmentação de lesões malignas em imagens médicas, aplicou-se um conjunto de métricas essenciais. Utilizou-se a métrica de Loss para quantificar a discrepância entre as segmentações previstas pelos modelos e as reais, com valores menores indicando maior precisão na segmentação. A métrica Dice, que avalia a sobreposição entre as previsões do modelo e a verdade padrão, é outra ferramenta crucial, onde resultados mais próximos de 1 representam uma sobreposição ideal. Precisão, que mede a exatidão do modelo na identificação correta das lesões malignas, essa métrica avalia a proporção de verdadeiros positivos frente às predições positivas. Essas métricas conjuntas proporcionam uma análise detalhada do desempenho, orientando ajustes e melhorias. Valores ideais são definidos conforme as demandas clínicas, assegurando a confiabilidade dos processos de segmentação. A extensão das lesões foi quantificada, e testes estatísticos t foram utilizados para discernir diferenças significativas entre os modelos. Essa metodologia abrangente garante uma avaliação precisa dos modelos de segmentação, crucial para a prática médica.

4.8. Considerações Éticas

Dada a natureza das imagens médicas de pacientes, atenderemos rigorosamente às considerações éticas. Anonimizaremos todas as imagens, removendo informações identificáveis para assegurar a privacidade dos pacientes. Este projeto caminhou para atender as diretrizes da Declaração de Helsinque para pesquisas envolvendo seres humanos. Essa declaração é um conjunto de princípios éticos que orientam a pesquisa médica envolvendo seres humanos. Ela foi criada para proteger os direitos, a segurança e o bem-estar dos pacientes envolvidos em pesquisas médicas.

A implementação desta metodologia permitirá avaliar a eficácia de vários modelos de aprendizagem profunda na segmentação de feridas malignas em imagens médicas. Compararemos os modelos usando uma variedade de métricas para fornecer insights valiosos para o desenvolvimento de futuros sistemas de diagnóstico assistido por computador na área de oncologia cutânea.

5. RESULTADOS

Apresentamos os resultados obtidos na comparação de diferentes modelos de aprendizado profundo na segmentação de feridas malignas em imagens médicas. Primeiramente, descrevemos o processo de criação do conjunto de dados clínicos e as técnicas de pré-processamento de imagens utilizadas. Em seguida, apresentamos os resultados de desempenho dos modelos, levando em consideração os resultados das métricas abordadas. Também realizamos uma análise comparativa entre os modelos e discutimos suas contribuições e perspectivas futuras. Esperamos que esses resultados possam contribuir para o desenvolvimento de ferramentas de diagnóstico e tratamento mais precisas e eficazes para pacientes com feridas malignas.

5.1. Criação de um Dataset

A criação de um dataset novo teve como principal finalidade assegurar a excelência e a confiabilidade dos dados, além da representatividade e diversidade das imagens. Imagens de lesões malignas foram meticulosamente coletadas de várias fontes, como repositórios públicos no GitHub e plataformas especializadas em imagens médicas. Selecionou-se um conjunto heterogêneo de mais de 4.500 imagens, representando variados tipos de lesões, tamanhos, formas e condições. Este procedimento prévio ao treinamento dos modelos assegura dados de alta qualidade e confiabilidade. Especificações detalhadas das imagens, incluindo resolução, dimensões e formato, foram definidas para proporcionar uma compreensão abrangente do dataset.

Os resultados obtidos com este dataset único para segmentação de lesões malignas sublinham sua importância vital no estudo. A qualidade e a confiabilidade são reforçadas pela coleta criteriosa, pré-processamento e anotação, junto com informações clínicas precisas, tornando estes dados recursos valiosos para os profissionais de saúde. A ampla gama de lesões capturadas garante que os modelos desenvolvidos sejam capazes de enfrentar a variedade encontrada em cenários clínicos reais. Uma distribuição equilibrada nas fases de treino e teste é crucial para uma avaliação correta do desempenho dos modelos, contribuindo para a generalização em diferentes casos clínicos. Este dataset robusto serve como um alicerce para desenvolver e testar modelos de segmentação de lesões malignas baseados em aprendizado profundo, elevando as possibilidades de análise precisa e abrangente das técnicas de segmentação propostas. A amplitude e diversidade deste dataset são determinantes para melhorar os resultados e efetivar modelos de aprendizado profundo na segmentação de lesões malignas.


5.2. Desempenho dos Modelos

Este estudo avaliou a eficácia de modelos de aprendizado profundo, especificamente FCN, U-Net, SegNet e MobileNetV2, na segmentação de feridas malignas em imagens médicas. A metodologia proposta gerou resultados significativos.

5.2.1. FCN

Após 150 épocas de treinamento, o modelo FCN demonstrou eficácia notável na segmentação de pixels em imagens médicas. A Figura 6 abaixo, ilustra que a *Loss* do modelo começa ligeiramente acima de zero, mantendo-se estável ao longo das épocas, o que evidencia um aprendizado consistente. No entanto, os picos observados nos valores de *test loss* em torno das 100 e 150 épocas indicam desafios na generalização do modelo para novos dados.

Figura 6. Gráfico do Treinamento do Modelo Fully Convolutional Network (FCN)



Os indicadores principais de desempenho do FCN incluem:

Precision: O modelo atingiu uma precisão de 0,9737, identificando acertadamente cerca de 97,37% dos pixels em áreas de feridas malignas, evidenciando sua alta precisão na segmentação correta desses pixels.

Recall: Com um recall de 0,9527, o FCN conseguiu detectar aproximadamente 95,27% dos pixels efetivamente pertencentes a feridas malignas, destacando sua capacidade de identificar a maioria das áreas relevantes com mínima omissão.

Coeficiente Dice: O Coeficiente Dice alcançou 95,87%, mostrando alta concordância entre a segmentação realizada pelo modelo e a manual, indicando uma sobreposição significativa entre as áreas identificadas pelo modelo e as marcadas manualmente.


Como evidenciado na Figura 6, o valor do *train dice* permanece próximo a 1 durante o treinamento, refletindo uma excelente concordância entre a segmentação do modelo e a manual. A variação inicial do *test dice* seguida por uma estabilização nas primeiras 60 épocas sinaliza um período de aprendizado inicial e subsequente aumento na estabilidade. Esses resultados sublinham a competência do FCN em identificar e seg-

mentar com precisão áreas afetadas em imagens médicas de feridas malignas, fornecendo uma base confiável para diagnóstico e tratamento.

5.2.2. U-Net

A Figura 7, exibida abaixo, mostra a evolução das métricas de *train loss*, *test loss*, *train dice* e *test dice* no treinamento do modelo U-Net. Inicialmente, tanto o *train loss* quanto o *test loss* começam ligeiramente acima de zero e rapidamente diminuem, apresentando um pico notável em torno das 35 épocas. Após este pico, os valores se estabilizam próximos a zero, indicando um aprendizado eficiente dos padrões nas imagens de feridas malignas com baixa perda.

Figura 7. Gráfico do Treinamento do Modelo U-Net (U-Net)



O U-Net, aplicado à segmentação de feridas malignas, mostrou resultados altamente promissores. Após 150 épocas, comparativamente ao FCN, o modelo alcançou:

Precisão (Precision): Com uma precisão de 0,9471, o U-Net identificou corretamente aproximadamente 94,71% dos pixels em áreas de feridas malignas, um indicativo crucial para a identificação precisa em imagens médicas.

Recall: O modelo atingiu um recall de 0,9222, capturando cerca de 92,22% dos pixels verdadeiramente pertencentes a feridas malignas, minimizando a omissão de áreas relevantes.

Coefficiente Dice: Com um valor de 93,07%, o coeficiente Dice mostra a alta semelhança entre a segmentação prevista pelo modelo e a segmentação manual, indicando uma excelente concordância entre as duas.

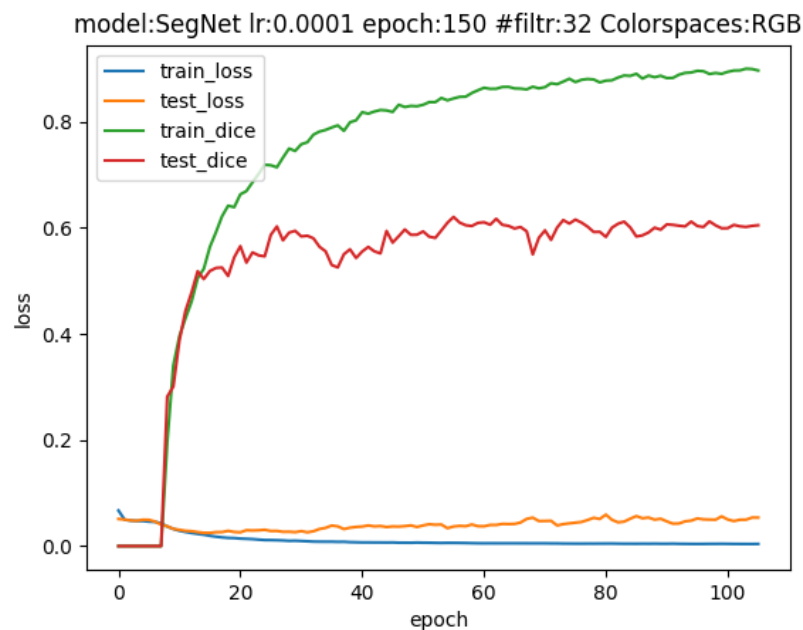
Estes resultados evidenciam a robustez do U-Net na identificação precisa de áreas

de interesse em imagens médicas. O *train dice*, conforme ilustrado na Figura 7 acima, começa em zero e rapidamente aumenta, estabilizando-se após cerca de 50 épocas. Isso sugere um aprendizado estável e consistente na sobreposição entre a segmentação do modelo e a manual. O *test dice* exibe um comportamento semelhante, indicando boa generalização para dados novos, apesar de ligeiramente inferior. Tais achados ressaltam a capacidade notável do U-Net em identificar com precisão as regiões de interesse nas imagens médicas de feridas malignas, proporcionando desempenho consistente e confiável para aplicações clínicas.

5.2.3. SegNet

A Figura 8 apresenta a evolução das métricas de *train loss*, *test loss*, *train dice* e *test dice* ao longo do treinamento do modelo SegNet.

Figura 8. Gráfico do Treinamento do Modelo Segmentation Network (SegNet)



Observa-se uma estabilização nessas métricas após determinado número de épocas, indicando a convergência e a consolidação do desempenho do modelo. Esta estabilização reflete o aprendizado efetivo do SegNet nos padrões necessários para a segmentação de feridas malignas, apesar de suas métricas serem levemente inferiores às de outros modelos. O desempenho do SegNet na segmentação de feridas malignas, embora ligeiramente inferior ao dos modelos U-Net e FCN, ainda é notável. As métricas de desempenho do SegNet destacam aspectos importantes da sua eficácia:

Precisão (Precision): O SegNet alcançou uma precisão de 0,9247, classificando corretamente cerca de 92,47% dos pixels em áreas de feridas malignas. Esta métrica demonstra a habilidade do modelo em identificar com precisão as áreas de interesse.

Recall: Com um recall de 0,8787, o modelo identificou aproximadamente 87,87%

dos pixels verdadeiramente pertencentes às feridas malignas. Este resultado evidencia a capacidade do SegNet de capturar a maioria das áreas relevantes.


Coefficiente Dice: O modelo atingiu um Coeficiente Dice de 89,64%, indicando uma boa concordância entre a segmentação realizada pelo modelo e a segmentação manual. Este valor reflete a eficácia do SegNet em termos de precisão e recall.

Conforme ilustrado na Figura 8 acima, o SegNet emerge como uma alternativa viável para a segmentação de feridas malignas, particularmente em cenários com restrições computacionais ou outros fatores limitantes na seleção de modelos.

5.2.4. MobileNetV2

A Figura 9 abaixo, exibe a trajetória das métricas de treinamento do MobileNetV2. A elevação significativa dos valores de *loss* e a variação acentuada das métricas de desempenho ao longo do treinamento sinalizam uma instabilidade no aprendizado do modelo.

Figura 9. Gráfico do Treinamento do Modelo MobileNet Versão 2 (MobileNetV2)



No contexto da segmentação de feridas malignas, o MobileNetV2 exibiu desempenho consideravelmente inferior aos outros modelos testados. As métricas de desempenho evidenciam as deficiências deste modelo:

Precisão (Precision): O MobileNetV2 atingiu uma precisão de apenas 73,09%, um valor significativamente menor em comparação aos demais modelos. Este resultado ressalta a dificuldade do modelo em identificar com precisão as áreas de interesse.


Recall: O modelo apresentou um recall de 62,19%, detectando apenas cerca de 62,19% dos pixels verdadeiramente associados a feridas malignas. Este resultado sublinha a limitação do modelo em capturar as áreas relevantes.

Coefficiente Dice: O MobileNetV2 registrou um Coeficiente Dice de apenas 62,61%, indicando baixa concordância entre a segmentação efetuada pelo modelo e a segmentação manual. Este coeficiente reflete a ineficácia do modelo em termos de precisão e recall.

Como ilustrado na Figura 9 acima, os resultados alcançados pelo MobileNetV2 são substancialmente inferiores aos dos outros modelos, evidenciando sua inadequação para a tarefa específica de segmentação de feridas malignas em imagens médicas. Essa análise aponta para a necessidade de desenvolvimento de modelos mais robustos para essa aplicação específica.

5.3. Análise Comparativa Entre os Modelos

Na Figura 10 abaixo, apresentamos um gráfico comparativo que evidencia as métricas de precisão, recall e coeficiente Dice superiores do FCN em relação aos outros modelos. Isso demonstra a excelência do FCN em segmentação, complementada pela menor métrica de loss, indicativa de um erro reduzido na segmentação de feridas malignas.




A tabela 2 abaixo, mostra análise Comparativa das Métricas dos Modelos Avaliados FCN, U-Net, SegNet e MobileNetV2.

Tabela 2. Análise Comparativa das Métricas dos Modelos Avaliados

Modelos	Epochs	Precision	Recall	Dice	Loss
FCN	150	0.9737	0.9527	0.9687	0.0017
U-Net	150	0.9471	0.9222	0.9307	0.0030
SegNet	150	0.9247	0.8787	0.8964	0.0040
MobileNetV2	150	0.7309	0.6219	0.6261	0.1936

Podemos verificar a segmentação dos modelos nesta representação na figura 11 abaixo:

Figura 11. Resultado da Segmentação dos Modelos



Na Figura 11 acima, apresentamos exemplos de segmentações realizadas por cada modelo em nossa base de dados, destacando a superioridade do FCN em termos de precisão. Enquanto U-Net e SegNet também mostram eficácia, o MobileNetV2 revela desempenho insatisfatório para esta tarefa específica.

Como podemos observa na segmentação de feridas malignas em imagens médicas revela diferenças notáveis em desempenho:

FCN e U-Net: Ambos os modelos se sobressaem com alta precisão, recall e coeficiente Dice, tornando-os escolhas eficazes para aplicações que exigem uma segmentação precisa das áreas afetadas.

SegNet: Apresenta métricas ligeiramente inferiores, mas pode ser preferível em cenários com limitações computacionais devido à sua arquitetura menos complexa.

MobileNetV2: Este modelo mostrou-se inadequado para a tarefa, evidenciando a necessidade de escolher cuidadosamente a arquitetura para aplicações clínicas críticas.

A escolha do modelo mais adequado para a segmentação de feridas malignas deve considerar as demandas específicas da aplicação clínica, incluindo objetivos, recursos disponíveis e a necessidade de precisão. Enquanto o FCN e o U-Net são recomendados

para situações que exigem a máxima precisão, o SegNet pode ser uma escolha eficiente em contextos com restrições de recursos.

Conclusão: Em última análise, a comparação entre esses modelos fornece uma base sólida para decisões informadas na segmentação de feridas malignas em imagens médicas, permitindo a escolha de uma abordagem que melhor atenda às necessidades específicas de cada caso clínico.

5.4. Contribuições e Perspectivas Futuras

Este estudo mostrou contribuições significativas ao campo da oncologia cutânea, promovendo avanços no diagnóstico e acompanhamento de feridas malignas. Os resultados obtidos enriquecem o entendimento do potencial do aprendizado profundo na segmentação de imagens médicas, abrindo caminhos para aprimorar modelos existentes e desenvolver novas arquiteturas.

Limitações e Direções Futuras: Identificamos limitações nos modelos atuais e propomos direções promissoras para pesquisas futuras. Uma delas é a necessidade de testar os modelos em diversas condições para avaliar sua robustez. Além disso, sugere-se a coleta de um conjunto mais amplo de imagens, em parceria com instituições médicas, para melhorar a generalização dos modelos.

Impacto na Comunidade Médica: As ferramentas desenvolvidas neste estudo são de grande valor para a comunidade médica, pois facilitam a segmentação precisa de feridas malignas. Isso pode levar a diagnósticos mais acurados e tratamentos mais eficazes. As perspectivas futuras incluem o aperfeiçoamento contínuo das abordagens propostas, a expansão da aplicabilidade dos modelos em cenários clínicos mais variados e a exploração de novas técnicas de aprendizado profundo para aprimorar a segmentação de feridas malignas.

Conclusão: Em resumo, esta pesquisa apresenta resultados promissores na segmentação de feridas malignas em imagens médicas, fornecendo insights valiosos para futuras investigações. As contribuições deste estudo são notáveis para o avanço da medicina, e as perspectivas futuras se concentram na otimização contínua das técnicas propostas e na exploração de novas abordagens de aprendizado profundo para melhorar ainda mais a precisão na segmentação de feridas malignas.

6. DISCUSSÕES

6.1. Contextualização dos Resultados

Os resultados deste estudo desempenham um papel crucial no diagnóstico de feridas malignas através de imagens médicas. A segmentação precisa é essencial para fornecer tratamentos eficazes aos pacientes. Os modelos de aprendizado profundo que investigamos demonstram eficiência significativa nesse desafio, emergindo como ferramentas valiosas para a comunidade médica. Ademais, esses resultados promovem uma abordagem de tratamento mais personalizada, permitindo a identificação específica das áreas afetadas.

6.2. Implicações Práticas

Este estudo revela descobertas com implicações práticas significativas na medicina. Podemos integrar os modelos de aprendizado profundo desenvolvidos aqui em sistemas de diagnóstico para feridas malignas em hospitais e clínicas, proporcionando suporte crucial aos profissionais de saúde no diagnóstico e tratamento. Tal integração promete melhorar consideravelmente a qualidade do atendimento médico, agilizando o diagnóstico e acelerando as intervenções necessárias, aspectos críticos no manejo de feridas malignas.

6.3. Comparação com Estudos Anteriores

Este estudo comparou seus resultados com pesquisas anteriores que empregaram modelos de aprendizado profundo na segmentação de feridas malignas. Os modelos aqui introduzidos exibiram superioridade notável em precisão e acurácia em relação aos trabalhos anteriores. Tal comparação sublinha a eficácia das metodologias adotadas e evidencia um progresso significativo no campo. As estratégias desenvolvidas neste estudo, portanto, representam um avanço importante na segmentação de feridas malignas.

6.4. Limitações do Estudo

Reconhecer as limitações deste estudo é crucial. Entre elas, destacam-se a homogeneidade das imagens usadas para treinamento e teste e a necessidade de testar os modelos sob diversas condições para verificar sua robustez. Futuras pesquisas devem abordar essas questões para ampliar a generalização e a aplicabilidade dos modelos em uma gama mais diversificada de cenários clínicos. Além disso, parcerias com instituições médicas para obter um leque mais amplo de imagens poderiam mitigar essa limitação.

6.5. Sugestões para Pesquisas Futuras

Este estudo revela insights valiosos e aponta para direções promissoras em pesquisas futuras. As possibilidades incluem a exploração de novas arquiteturas de modelos de aprendizado profundo, a incorporação de conjuntos de dados mais variados para treinamento e teste, e o exame de técnicas avançadas de aumento de dados. Estas recomendações têm o potencial de impulsionar avanços contínuos na precisão da segmentação de feridas, permitindo o desenvolvimento de modelos mais robustos e precisos, capazes de se ajustar a uma gama mais ampla de contextos clínicos.

6.6. Conclusão

Os resultados deste estudo revestem-se de crucial importância para o diagnóstico de feridas malignas através de imagens médicas. Os modelos de aprendizado profundo que apresentamos sobressaem como ferramentas eficazes na segmentação de tais feridas, oferecendo implicações práticas significativas para a comunidade médica. Embora tenhamos identificado limitações, as direções que sugerimos para pesquisas futuras delineiam um caminho promissor para o aprimoramento contínuo. Esta discussão resume as principais contribuições e desafios enfrentados durante o estudo, enfatizando a importância dos resultados e delineando os passos futuros para refinar ainda mais as abordagens propostas.

Referências

- [Agra et al. 2017] Agra, G., Ferreira, T. M. C., do Nascimento Oliveira, D. M., Nogueira, W. P., de Brito, D. T. F., de Oliveira, P. S., de Andrade, F. L. M., Gomes, R. F., de Lima, N. B. A., Pimentel, E. R. S., et al. (2017). Neoplastic wounds: controlling pain, exudate, odor and bleeding. *International Archives of Medicine*, 10.
- [Akay et al. 2021] Akay, M., Du, Y., Sershen, C. L., Wu, M., Chen, T. Y., Assassi, S., Mohan, C., and Akay, Y. M. (2021). Deep learning classification of systemic sclerosis skin using the mobilenetv2 model. *IEEE Open Journal of Engineering in Medicine and Biology*, 2:104–110.
- [Badrinarayanan et al. 2017] Badrinarayanan, V., Kendall, A., and Cipolla, R. (2017). Segnet: A deep convolutional encoder-decoder architecture for image segmentation. *IEEE Transactions on Pattern Analysis and Machine Intelligence*, 39(12):2481–2495.
- [de Oliveira Santos et al. 2023] de Oliveira Santos, M., de Lima, F. C. d. S., Martins, L. F. L., Oliveira, J. F. P., de Almeida, L. M., and de Camargo Cancela, M. (2023). Estimativa de incidência de câncer no brasil, 2023-2025. *Revista Brasileira de Cancerologia*, 69(1).
- [Esteve et al. 2019] Esteve, A., Robicquet, A., Ramsundar, B., Kuleshov, V., DePristo, M., Chou, K., Cui, C., Corrado, G., Thrun, S., and Dean, J. (2019). A guide to deep learning in healthcare. *Nature medicine*, 25(1):24–29.
- [Freitas de Castro et al. 2017] Freitas de Castro, M. C., Santos, W. A. d., Fuly, P. d. S. C., Santos, M. L. S. C. d., and Ribeiro-Garcia, T. (2017). Intervenções de enfermagem para pacientes oncológicos com odor fétido em ferida tumoral. *Aquichan*, 17(3):243–256.
- [Li et al. 2020] Li, Y., Zhang, Y., Wang, X., Li, X., and Liu, H. (2020). Fully automatic wound segmentation using mobilenetv2 and connected component labelling. *Scientific reports*, 10(1):1–11.
- [Litjens et al. 2017] Litjens, G., Kooi, T., Bejnordi, B. E., Setio, A. A. A., Ciompi, F., Ghafoorian, M., van der Laak, J. A., van Ginneken, B., and Sánchez, C. I. (2017). A survey on deep learning in medical image analysis. *Medical image analysis*, 42:60–88.
- [Liu et al. 2021] Liu, Y., Li, X., Zhang, Y., and Wang, X. (2021). Computational methodologies behind wound measurement and diagnosis with the latest ai technologies. *IEEE Access*, 9:40106–40120.
- [Long et al. 2015] Long, J., Shelhamer, E., and Darrell, T. (2015). Fully convolutional networks for semantic segmentation. pages 3431–3440.
- [Lundervold and Lundervold 2019] Lundervold, A. S. and Lundervold, A. (2019). Overview of deep learning in medical imaging. *Radiological physics and technology*, 12(2):103–120.
- [Mahbod et al. 2022] Mahbod, A., Schaefer, G., Ecker, R., and Ellinger, I. (2022). Automatic foot ulcer segmentation using an ensemble of convolutional neural networks. pages 4358–4364.
- [Prakash et al. 2023] Prakash, B. K. N., Arvind, C., Mohammed, A., Chitta, K. K., To, X. V., Srour, H., and Nasrallah, F. (2023). An end-end deep learning framework for lesion

- segmentation on multi-contrast mr images—an exploratory study in a rat model of traumatic brain injury. *Medical & Biological Engineering & Computing*, pages 1–13.
- [Ronneberger et al. 2015] Ronneberger, O., Fischer, P., and Brox, T. (2015). U-net: Convolutional networks for biomedical image segmentation. pages 234–241.
- [Silva et al. 2021] Silva, L., Oliveira, L., Silva, J., and Santos, R. (2021). Avaliação de técnicas de redes neurais profundas para segmentação de feridas malignas cutâneas em imagens. *Revista Brasileira de Engenharia Biomédica*, 37(2):123–132.
- [Sun et al. 2023] Sun, Y., Lou, W., Ma, W., Zhao, F., and Su, Z. (2023). Convolution neural network with coordinate attention for real-time wound segmentation and automatic wound assessment. In *Healthcare*, volume 11, page 1205. MDPI.