

UNIVERSIDADE CATÓLICA DE PERNAMBUCO
CURSO DE CIÊNCIA DA COMPUTAÇÃO

Comparação de Modelos de Machine Learning na Segmentação de Feridas Malignas em Imagens Médicas

ALUNO: LUCAS DOS SANTOS AMORIM RÊGO
ORIENTADOR: RAFAEL ROQUE DE SOUZA

Projeto apresentado ao Curso de Ciência da Computação da Universidade Católica de Pernambuco, como parte dos requisitos necessários à obtenção da nota da disciplina INF 1814 - Trabalho de Conclusão de Curso II.

Recife, PE, Dezembro de 2023

RESUMO

Contexto: A área da saúde demanda cada vez mais a segmentação precisa de imagens médicas, notadamente no ramo da oncologia cutânea. Nesse contexto, a identificação exata e rápida de feridas malignas pode resultar em tratamentos mais eficientes e prognósticos mais positivos. Modelos de aprendizado profundo, como U-Net (U-Net), Segmentation Network (SegNet), Fully Convolutional Network (FCN) e MobileNet Versão 2 (MobileNetV2), têm ganhado espaço nesse cenário devido à sua capacidade e potencial de aplicação. **Objetivo:** Este estudo visa explorar a eficiência e aplicabilidade desses modelos de aprendizado profundo no que tange à segmentação de feridas malignas em imagens médicas, levando em conta seus resultados no que diz respeito à precisão dos resultados dos algoritmos. **Método:** A metodologia adotada para essa investigação percorre uma série de fases, desde o pré-processamento das imagens até a avaliação do desempenho dos modelos de aprendizado profundo, passando por testes em diferentes modelos de machine learning. O desempenho de cada modelo foi avaliado por meio de métricas consagradas, como Loss, Precision, Recall e Coeficiente de Dice, além de ser considerada a eficiência computacional de cada um. **Resultados:** Os resultados obtidos neste estudo foram promissores, os modelos avaliados demonstraram alto desempenho na segmentação de feridas malignas e forneceram insights significativos a respeito do desempenho comparativo entre diferentes arquiteturas de aprendizado profundo em aplicações médicas. **Conclusão:** Espera-se que as descobertas deste estudo ofereçam direcionamentos para futuras pesquisas no campo da segmentação de imagens médicas via aprendizado profundo. Ademais, a pesquisa tem o potencial de trazer benefícios notáveis à medicina – sobretudo à oncologia cutânea – ao prover ferramentas automatizadas e eficazes para segmentação de feridas malignas, colaborando, assim, com diagnósticos e monitoramento de tratamentos por profissionais da saúde.

Palavras-chave: Câncer; Feridas Malignas; Segmentação de Feridas; Redes Neurais Convolucionais.

ABSTRACT

Context: The health sector increasingly demands precise segmentation of medical images, particularly in cutaneous oncology. In this context, the accurate and rapid identification of malignant wounds can result in more efficient treatments and favourable prognoses. Deep learning models, such as U-Net (U-Net), Segmentation Network (SegNet), Fully Convolutional Network (FCN) and MobileNet Versão 2 (MobileNetV2), have been gaining ground in this scenario due to their capacity and application potential. **Objective:** This study aims to explore the efficiency and applicability of these deep learning models in the segmentation of malignant wounds in medical images, taking into account their results about the accuracy of the algorithms' results. **Method:** The methodology adopted for this research goes through a series of phases, from pre-processing the images to evaluating the performance of the deep learning models, including tests on different machine learning models. The performance of each model will be evaluated using established metrics such as loss, precision, recall and Dice coefficient, and the computational efficiency of each will be considered. **Results:** The results obtained in this study were promising; the models evaluated demonstrated high performance in the segmentation of malignant wounds and provided significant insights into the comparative performance between different deep learning architectures in medical applications. **Conclusion:** The findings of this study are expected to provide directions for future research in the field of medical image segmentation via deep learning. In addition, the research has the potential to bring notable benefits to medicine – especially cutaneous oncology – by providing automated and practical tools for segmenting malignant wounds, thus collaborating with diagnoses and treatment monitoring by health professionals.

Keywords: Cancer; Malignant Wounds; Wound Segmentation; Convolutional Neural Networks.

Sumário

1	INTRODUÇÃO	5
1.1	Apresentação do Problema	5
1.2	Questões de Pesquisa	6
1.3	Objetivo Geral	6
1.4	Objetivos Específicos	7
1.5	Estrutura do TCC	7
2	FUNDAMENTAÇÃO TEÓRICA	9
2.1	Feridas Crônicas e Malignas	9
2.2	Avaliação e Manejo de Feridas	9
2.3	Aplicações de IA no Tratamento Médico	10
2.4	Arquiteturas de Redes Neurais	12
2.5	Métricas	13
3	TRABALHOS RELACIONADOS	15
3.1	Limitação de trabalhos relacionados	16
3.2	Diferenciação do nosso trabalho	16
4	METODOLOGIA	18
4.1	Conjunto de Dados	18
4.2	Criação do Conjunto de Dados	18
4.3	Pré-processamento de Imagens	19
4.4	Divisão do Conjunto de Dados	20
4.5	Arquiteturas de Redes Neurais	20
4.5.1	FCN	20
4.5.2	U-Net	21
4.5.3	SegNet	22
4.5.4	MobileNetV2	24
4.6	Treinamento e Ajuste do Modelo	24
4.7	Avaliação e Métricas	25
4.8	Considerações Éticas	25

5	RESULTADOS	26
5.1	Criação de um Dataset	26
5.2	Desempenho dos Modelos	26
5.2.1	FCN	27
5.2.2	U-Net	28
5.2.3	SegNet	29
5.2.4	MobileNetV2	30
5.3	Análise Comparativa Entre os Modelos	31
5.4	Contribuições e Perspectivas Futuras	33
6	DISCUSSÕES	35
6.1	Contextualização dos Resultados	35
6.2	Implicações Práticas	35
6.3	Comparação com Estudos Anteriores	35
6.4	Limitações do Estudo	35
6.5	Sugestões para Pesquisas Futuras	36
6.6	Conclusão	36

1. INTRODUÇÃO

No Brasil, estima-se que anualmente, entre 2023 e 2025, ocorrerão aproximadamente 704.000 novos casos de câncer. As feridas malignas, decorrentes destes cânceres, representam um desafio significativo no tratamento médico [de Oliveira Santos et al. 2023]. Profissionais de saúde lidam com a complexidade dessas feridas crônicas, frequentemente oriundas de processos oncológicos, que exigem cuidados intensivos focados não apenas na cicatrização, mas também na melhoria da qualidade de vida dos pacientes [Freitas de Castro et al. 2017, Agra et al. 2017].

As Redes Neurais Convolucionais (CNNs), subcategoria das Artificial neural Networks (ANN), têm se mostrado eficazes em diversas aplicações de visão computacional, como classificação e segmentação de imagens [Sun et al. 2023]. Essas redes conseguem distinguir lesões de pele saudável adjacente, identificando características essenciais para avaliações mais objetivas e consistentes [Litjens et al. 2017, Lundervold and Lundervold 2019, Esteva et al. 2019].

1.1. Apresentação do Problema

A necrose da ferida frequentemente associada ao câncer da mama cabeça e pescoço, resulta da infiltração agressiva de células cancerígenas na pele. Isso resulta em uma lesão exofítica, que altera gradativamente a aparência do paciente. Essas lesões são de natureza frágil: ferimentos leves podem causar sangramento abundante. Além disso, são notoriamente dolorosos e afetam diretamente o bem-estar e a qualidade de vida do indivíduo afetado.

As feridas malignas também são conhecidas por serem exsudativas, produzindo exsudato que pode ser difícil de controlar. Este exsudado, muitas vezes abundante, requer cuidados constantes e especializados para prevenir infecções e manter a integridade da pele circundante. Outro aspecto desafiador é o odor desagradável que muitas vezes acompanha essas feridas, resultado da necrose tecidual e da colonização bacteriana, que pode ter um profundo impacto psicológico tanto nos pacientes quanto nos seus cuidadores.

No contexto clínico A autoavaliação tradicional destas feridas tem diversas limitações. Este processo é subjetivo. Isto depende muito da experiência e percepção de cada profissional de saúde. Esta subjetividade pode levar a uma variabilidade significativa na avaliação, dificultando a criação de um plano de tratamento consistente e eficaz. Além disso, a avaliação manual costuma ser demorada, demandando um tempo significativo tanto para inspeção visual quanto para toque suave para evitar mais dor ou sangramento ao paciente.

A dificuldade de segmentar imagens médicas, como as de feridas dolorosas, tornou-se um grande obstáculo na área da saúde. Segmentação é o processo de categorizar e isolar partes de uma imagem que se relacionam com interesses específicos. Neste caso, as regiões de interesse são as partes do quadro afetadas por lesões cancerígenas. A segmentação eficaz é fundamental para uma diagnose e tratamento precisos porque permite que médicos e outros profissionais médicos determinam com acurácia o tama-

nho a forma e a localização das feridas. No entanto, a segmentação neste contexto é um problema desafiador devido à variedade de aparências e formas do trauma, bem como à presença de ruídos e artefatos nas imagens. Além disso, a segmentação manual é demorada e sujeita a enganos. Esse processo pode levar a diagnósticos incorretos e tratamento inadequado. Como resultado, a implementação de algoritmos de aprendizagem profunda como o descrito neste estudo pode ser considerada uma abordagem promissora para segmentar cicatrizes prejudiciais em imagens médicas.

A precisão da autoavaliação também é uma preocupação. Isso ocorre porque a imprecisão pode levar a enganos de diagnose ou atraso no tratamento adequado. Isto se deve à complexidade e à natureza dinâmica dessas feridas necróticas. Consequentemente, é imperativo buscar técnicos que possam aprimorar ou melhorar a precisão da avaliação clínica. Consequentemente, é imperativo explorar novas tecnologias e métodos, como redes neurais artificiais, para melhorar a precisão e a eficiência da avaliação dessas feridas complexas.

Consequentemente, este trabalho tem como objetivo explorar o uso de algoritmos de aprendizagem profunda para segmentação automática de feridas malignas em imagens médicas. Acreditamos que o uso desses algoritmos pode ajudar a melhorar a eficiência e a acurácia da diagnose e tratamento de feridas malignas, bem como reduzir o tempo e o esforço necessários para a segmentação manual. Além disso, a segmentação automática pode ser o primeiro passo em um sistema automatizado de análise de feridas, permitindo que as etapas subsequentes se concentrem apenas na área da ferida sem serem afetadas por artefatos que não fazem parte da ferida.

1.2. Questões de Pesquisa

Neste estudo, propomos investigar questões científicas detalhadas sobre a aplicação de Convolutional Neural Network (CNN) na segmentação de feridas malignas em imagens médicas:

1. **QP1:** *“Até que ponto as Redes Neurais Convolucionais avançadas melhoram a precisão na segmentação de feridas malignas em comparação com técnicas tradicionais de análise de imagens médicas, e quais fatores contribuem para sua eficácia em diferentes contextos clínicos e tipos de feridas?”*

A abordagem será quantitativa, empregando técnicas avançadas de Inteligência Artificial para analisar e interpretar imagens médicas. Além disso, a eficácia das CNNs será mensurada e validada por meio da comparação com métodos de avaliação manual convencionais realizados por profissionais da saúde. Essas questões de pesquisa podem ser melhor respondidas ao longo do trabalho, podemos ver uma explicação mais detalhada no final do subtópico 5.3 da seção de Resultados.

1.3. Objetivo Geral

Este estudo busca avaliar a eficiência e aplicabilidade de modelos de aprendizado profundo, especificamente CNN, na segmentação de feridas malignas em imagens médicas,

com foco na precisão dos resultados.

1.4. Objetivos Específicos

Este estudo tem como objetivo investigar a aplicação e eficácia das CNN na segmentação de feridas malignas. O objetivo é otimizar o tratamento através de avaliações mais precisas e objectivas, desenvolver ferramentas de apoio que possam ser integradas na prática clínica, melhorar os cuidados e acelerar a cicatrização.

- Implementar modelos de aprendizado profundo, como FCN¹, U-Net², SegNet³ e MobileNetV2⁴, para a segmentação de feridas malignas em imagens médicas.
- Otimizar o pré-processamento das imagens para melhorar a precisão e eficiência dos modelos.
- Avaliar o desempenho dos modelos com base em métricas como Loss, Precision, Recall e Coeficiente de Dice.
- Comparar a eficácia das diversas arquiteturas de aprendizado profundo na tarefa de segmentação.
- Fornecer diretrizes para futuras pesquisas em segmentação de imagens médicas com aprendizado profundo.
- Contribuir para a oncologia cutânea, desenvolvendo ferramentas automáticas e eficientes para a segmentação de feridas malignas.

1.5. Estrutura do TCC

A estrutura deste trabalho segue uma progressão lógica e abrangente. Iniciando com esta introdução, o TCC segue algumas etapas:

Revisão da literatura, a qual oferece uma análise detalhada dos estudos relacionados à segmentação de feridas malignas em imagens médicas. Este capítulo aborda os principais desafios encontrados na área e explora as técnicas mais utilizadas, oferecendo um panorama abrangente do estado da arte.

A metodologia é então apresentada, detalhando o processo adotado para a realização deste estudo. Este capítulo engloba desde a coleta até o pré-processamento dos dados, a seleção dos modelos de aprendizado profundo e os parâmetros de treinamento, além de descrever as métricas de avaliação utilizadas para analisar o desempenho dos modelos.

Os resultados obtidos pelos modelos de aprendizado profundo avaliados neste estudo são minuciosamente apresentados, incluindo métricas essenciais como Precisão, Recall, Coeficiente Dice e a perda associada a cada modelo. Esses resultados são então discutidos em profundidade, considerando suas implicações para a segmentação de feridas

¹<https://paperswithcode.com/method/fcn>

²<https://paperswithcode.com/method/u-net>

³<https://paperswithcode.com/method/segnet>

⁴<https://paperswithcode.com/method/mobilenetv2>

malignas em imagens médicas, bem como destacando as limitações e possíveis direções para pesquisas futuras.

Por fim, o trabalho conclui com um capítulo de conclusões, ressaltando os insights e descobertas mais significativos e fornecendo recomendações valiosas para investigações posteriores na área. Esta estrutura oferece uma abordagem abrangente e analítica, permitindo uma compreensão profunda e crítica do tema explorado ao longo deste TCC.

2. FUNDAMENTAÇÃO TEÓRICA

2.1. Feridas Crônicas e Malignas

Feridas crônicas e malignas constituem um desafio notável na estomaterapia⁵, exigindo uma compreensão profunda de suas características patológicas e implicações clínicas.

As feridas crônicas são caracterizadas pela sua presença contínua para além do período típico de cicatrização, que muitas vezes é superior a três meses. A causa subjacente é multifacetada e envolve inflamação crônica, vasos sanguíneos prejudicados e supressão imunológica local. Esses atributos distinguem feridas crônicas de lesões agudas e necessitam de uma abordagem diferente para o tratamento.

As feridas malignas, um tipo específico de ferida crônica que é particularmente prevalente em populações com diabetes ou com incapacidade de produzir anticorpos, são particularmente afetadas por esta doença. Representam uma ameaça tanto para o sistema de saúde como para os próprios indivíduos devido ao impacto que têm na doença e na morte. A investigação epidemiológica dessas lesões é crucial para a compreensão de sua prevalência e causas.

A escolha de um regime de tratamento apropriado, incluindo agentes tópicos, terapias avançadas de cicatrização de feridas e técnicas cirúrgicas, é importante no tratamento de feridas malignas. O alívio da dor e a prevenção de infecções secundárias são igualmente importantes. O tratamento deve ser individualizado, levando em consideração as características específicas da ferida e o estado do paciente.

Lesões violentas têm um impacto significativo na qualidade de vida do paciente, impactando significativamente sua saúde mental, autoestima e capacidade funcional. Além do tratamento físico, é importante abordar os aspectos psicológicos e sociais, fornecendo apoio emocional e psicossocial adequado.

A precisão da segmentação de lesões malignas em imagens médicas é importante não apenas para diagnóstico e tratamento eficazes, mas também para avaliar a progressão da doença e a resposta ao tratamento. Essa precisão contribui muito para estratégias de tratamento mais eficazes e personalizadas, impactando positivamente na recuperação e na qualidade de vida do paciente.

2.2. Avaliação e Manejo de Feridas

A avaliação e manejo de feridas representam áreas cruciais na prática médica, abrangendo desde métodos tradicionais de observação visual até técnicas avançadas de tratamento. Ao entender a diversidade de técnicas abordados a seguir, torna-se possível compreender a complexidade envolvida no diagnóstico e tratamento de feridas, oferecendo insights valiosos para a prática médica contemporânea.

⁵Especialidade da enfermagem que se dedica ao cuidado de pacientes com estomas, feridas agudas ou crônicas, incontinência fecal ou urinária, e outras condições relacionadas ao trato gastrointestinal, urogenital e integumentar

Métodos tradicionais de avaliação de feridas: Os métodos tradicionais incluem métodos que vão desde a observação visual até medições físicas. O exame visual é a forma mais simples de avaliação, no qual um profissional médico examina a ferida em busca de características como tamanho, formato, cor, presença de tecido necrótico e exsudato. Além disso, métodos como planimetria e fotografia usando ferramentas de software específicas são utilizados para medir a área e determinar a extensão da ferida. Este método é a base para uma avaliação que permite acompanhar a evolução da ferida ao longo do tempo.

Parâmetros para Avaliação Clínica de Feridas: Durante a avaliação clínica, diversos parâmetros são considerados para determinar a condição e o progresso da ferida. Isso inclui a identificação da presença de infecção, analisando sinais como inflamação, calor, rubor, edema e dor. Além disso, a extensão da lesão é avaliada quanto à profundidade, dimensões e possíveis complicações, como formação de tecido de granulação e presença de bordas irregulares. A resposta ao tratamento também é monitorada, verificando se a ferida está cicatrizando de maneira eficaz.

Técnicas avançadas de tratamento de feridas Os técnicos avançadas incluem uma variedade de abordagens inovadoras para promover a cicatrização de feridas complexas. Isto inclui tratamentos tópicos, como substâncias biologicamente ativas, terapia de pressão negativa, que estimula a circulação e remove fluido das feridas e oxigenoterapia hiperbárica que fornece uma alta concentração de oxigênio para promover a cura. Essas técnicas representam um avanço significativo no tratamento de feridas. Ele fornece recursos superiores aos métodos tradicionais.

Diretrizes e Protocolos no Manejo de Feridas Malignas: Diretrizes e protocolos específicos são estabelecidos para lidar com feridas malignas, visando um diagnóstico precoce e um tratamento eficaz. Essas diretrizes definem critérios para identificar feridas malignas, estabelecem estratégias de tratamento e monitoramento, e fornecem orientações para o manejo de complicações, garantindo uma abordagem consistente e baseada em evidências.

Tecnologias Emergentes no Tratamento de Feridas: Tecnologias emergentes estão trazendo avanços significativos no tratamento de feridas, incluindo curativos inteligentes, que monitoram e reagem dinamicamente ao ambiente da ferida, e terapias de regeneração de tecidos, que estimulam o crescimento celular e a cicatrização de maneira mais eficiente. Além disso, há pesquisas em andamento para desenvolver abordagens personalizadas, utilizando impressão 3D para criar curativos adaptados às características únicas da ferida.

Esses pontos representam a diversidade e a complexidade das técnicas e abordagens disponíveis para a avaliação e tratamento de feridas. Desde métodos tradicionais até as mais avançadas tecnologias emergentes, o campo da medicina de feridas está constantemente evoluindo para oferecer soluções mais eficazes e personalizadas para os pacientes.

2.3. Aplicações de IA no Tratamento Médico

Os progressos no campo da **IA** ! (**IA** !) revolucionaram os cenários médicos, oferecendo diversas utilizações em diagnose e tratamento. Neste contexto, o impacto da **IA** ! na me-

dicina é explorado, abordando desafios éticos, tecnologias como a **CNN ! (CNN !)** e o seu desenvolvimento para segmentação de traumas. Também considera a comparação entre avaliação manual e automatizada e as perspectivas futuras para melhorar o atendimento ao paciente.

desafios e considerações éticas relativas à Inteligência Artificial (IA) nos cuidados de saúde: Sérias questões éticas emergem quando se aplica a IA nos cuidados de saúde. A privacidade do paciente é tão importante que são necessários medidas rigorosas para proteger e anonimizar os dados. Além disso, a interpretabilidade dos algoritmos **AI! (AI!)** é crucial para garantir que os especialistas possam compreender e confiar nas decisões do modelo. As questões de responsabilidade clínica também são relevantes, pois os resultados gerados pela **IA !** influenciarão as decisões dos profissionais de saúde.

CNNs ! (CNNs !): Este é um tipo de arquitetura de rede neural que é a base da análise de imagens médicas. Ele foi projetado para aprender padrões hierárquicos complexos, identificando características e relacionamentos importantes entre os pixels da imagem. No contexto da segmentação de feridas malignas, as CNNs são extremamente eficazes na identificação e delineamento dessas regiões em imagens médicas.

desenvolvendo modelos CNN para segmentação de feridas: Para criar um modelo **CNN !** para segmentação de feridas, você precisa coletar um conjunto de dados diversificado e cuidadosamente anotado. Este conjunto trespassa por uma etapa de pré-processamento para padronizar a qualidade da imagem e normalizar os dados. Treinar o modelo envolve alimentar CNN com dados anotados para aprender a identificar e segmentar regiões de lesões malignas.

Segmentação de feridas. A segmentação de feridas é uma técnica de processamento de imagens que visa identificar e rastrear a área afetada por uma ferida em imagens médicas. Essa técnica é importante porque permite que médicos e profissionais de saúde avaliar com acurácia o tamanho formato e localização das feridas, o que é fundamental para o correto diagnóstico e tratamento. Na prática a segmentação de feridas envolve a aplicação de algoritmos de aprendizagem profunda o imagens médicas de feridas. Esses algoritmos são treinados em um conjunto de dados de imagens rotuladas. Aqui está uma olhada no que os especialistas em trauma explicaram. Com base neste conjunto de dados, o algoritmo pode aprender a reconhecer características da ferida e segmentá-las em novas imagens.

Comparação de desempenho Comparando segmentação manual e automática na segmentação de feridas cancerígenas em imagens médicas. É importante considerar vários aspectos. Exatidão e precisão, que medem a capacitância de identificar e cercar uma ferida são importantes. Embora a segmentação manual seja trabalhosa e subjetiva, a automatização de **CORRIA** nesta tarefa de segmentação de imagens oferece eficiência, consistência e recursos de generalização baseados em treinamento. No entanto, a validação clínica é crucial para garantir que os resultados automatizados sejam clinicamente relevantes e confiáveis, alinhados com as necessidades dos profissionais de saúde e dos pacientes.

Integração da **CNN !** na prática clínica: A integração bem-sucedida da **CNNs !** na prática clínica requer a validação de modelos em ambientes clínicos reais. Isto envolve testar se os modelos são clinicamente significativos, fáceis de interpretar e úteis para os

profissionais de saúde, contribuindo assim para decisões mais precisos e eficazes.

Perspectivas futuras e potencial para melhorar o atendimento ao paciente: As perspectivas futuras concentram-se na evolução contínua da IA na área médica. Isso inclui melhorias nos modelos CNN, exploração de técnicas mais avançadas de aprendizado de máquina e integração de IA em sistemas de saúde para um atendimento ao paciente mais personalizado e preciso.

Perspectivas futuras e potencial para melhorar o atendimento ao paciente: As perspectivas futuras concentram-se na evolução contínua da IA na área médica. Isso inclui melhorias nos modelos CNN, exploração de técnicas mais avançadas de aprendizado de máquina e integração de IA em sistemas de saúde para um atendimento ao paciente mais personalizado e preciso.

Estes pontos destacam a importância da inteligência artificial na segmentação de feridas malignas e destacam os desafios, as considerações éticas e os benefícios potenciais da aplicação destas tecnologias à prática clínica.

2.4. Arquiteturas de Redes Neurais

As arquiteturas de redes neurais são estruturas organizadas de neurônios artificiais, modeladas com base no funcionamento do cérebro humano. No contexto da segmentação de imagens médicas, essas arquiteturas são adaptadas para analisar e compreender visualmente as informações contidas nessas imagens.

As CNNs são altamente eficazes na análise de imagens devido à sua capacidade de preservar a relação espacial entre os pixels. Elas usam camadas convolucionais para extrair características hierárquicas das imagens, seguidas por camadas de pooling para reduzir a dimensionalidade e camadas totalmente conectadas para classificação ou segmentação.

Redes Neurais Recorrentes (RNNs): As RNNs são ideais para lidar com sequências de dados, como texto ou séries temporais médicas. Sua estrutura permite que informações sejam lembradas e aplicadas em etapas posteriores, sendo úteis em tarefas de previsão e análise temporal.

Redes Generativas Adversariais (GANs): As GANs consistem em duas redes neurais, um gerador e um discriminador, que competem entre si. Elas são usadas para criar novos dados realistas a partir de um conjunto de dados existente, sendo aplicáveis na geração de imagens médicas sintéticas para treinamento de modelos ou na correção/aperfeiçoamento de imagens existentes.

Fully Convolutional Network (FCN): As FCNs são arquiteturas especialmente concebidas para tarefas de segmentação e localização em imagens. Diferentemente das redes convolucionais convencionais, as FCNs mantêm a estrutura completa das redes neurais convolucionais, porém substituem as camadas totalmente conectadas por convoluções globais, permitindo que a rede seja aplicada a imagens de qualquer tamanho.

U-Net: A U-Net é conhecida por sua eficácia em tarefas de segmentação semântica em imagens médicas. Sua arquitetura se assemelha à letra "U", com uma es-

estrutura de codificação para a extração de características e uma estrutura de decodificação para reconstruir a imagem segmentada. Ela também incorpora conexões residuais entre camadas correspondentes, permitindo a preservação de detalhes durante a reconstrução.

SegNet: A SegNet é uma arquitetura de segmentação de imagens que se concentra na eficiência computacional. Ela utiliza um codificador convolucional para extrair características e um decodificador que mapeia características para a imagem segmentada. Seu destaque é o uso de mapas de índice durante a etapa de decodificação, ajudando na reconstrução da imagem.

MobileNetV2: Esse modelo foi projetado para ser mais leve e eficiente, ideal para aplicativos móveis e tarefas em dispositivos com recursos limitados. Ele utiliza operações de convolução separável em largura e em profundidade para reduzir a complexidade computacional, mantendo um bom desempenho em tarefas de visão computacional, embora possa não ser ideal para segmentação detalhada de imagens médicas devido à sua arquitetura mais simplificada.

Esse conhecimento arquitetural é fundamental para entender o funcionamento dos modelos de Machine Learning utilizados no estudo. Ao explorar as técnicas de rede neural, podemos avaliar a eficiência e aplicabilidade de diferentes modelos de aprendizado profundo, como U-Net, SegNet, FCN e MobileNetV2, na identificação rápida e precisa de feridas malignas. Isso poderá resultar em tratamentos mais eficientes e prognósticos mais positivos para os pacientes.

2.5. Métricas

No contexto de segmentação de imagens, as métricas são usadas para avaliar o quão bem o modelo está segmentando as áreas de interesse na imagem, como as áreas de feridas malignas. As métricas podem ser usadas para avaliar diferentes aspectos do desempenho do modelo, como precisão, completude, acurácia e similaridade com a segmentação manual. Ao avaliar as métricas, os pesquisadores podem determinar quais modelos são mais eficazes na segmentação de feridas malignas e ajudar a melhorar a precisão e eficiência dos modelos de Machine Learning. As métricas utilizadas neste estudo foram Loss, Precision, Recall e Coeficiente de Dice.

Loss (Perda): É uma medida que quantifica o erro entre a segmentação produzida pelo modelo e a segmentação esperada. Geralmente, ela é calculada durante o treinamento do modelo, ajudando a ajustar os pesos da rede neural para minimizar esse erro. A redução da Loss indica uma melhor adaptação do modelo aos dados de treinamento.

Precision (Precisão): Essa métrica mede a proporção de pixels corretamente classificados como feridas malignas em relação ao total de pixels identificados pelo modelo como feridas malignas. Ela destaca a capacidade do modelo em não classificar incorretamente pixels saudáveis como feridas malignas.

Recall (Revocação): Refere-se à proporção de pixels de feridas malignas corretamente identificados pelo modelo em relação ao total de pixels de feridas malignas na imagem. Essa métrica destaca a habilidade do modelo em identificar corretamente a área das feridas malignas.

O Coeficiente de Dice: É uma métrica de similaridade que compara a segmentação produzida pelo modelo com a segmentação manual. Quanto mais próxima de 1, maior a sobreposição entre as duas segmentações. É especialmente útil quando há desequilíbrio entre as classes, como uma pequena quantidade de pixels de feridas malignas em relação ao total da imagem.

3. TRABALHOS RELACIONADOS

Esta seção apresenta estudos relacionados ao uso de CNN para a segmentação de imagens médicas, oferecendo um panorama das pesquisas recentes e estabelecendo um comparativo com o presente trabalho. É também demonstrado as bases de dados exploradas em cada estudo. Podemos ver essa análise na tabela 1.

Tabela 1. Análise Comparativa dos Trabalhos Relacionados

Autores	Datasets				Models			
	Wound Segmentation	WSNET	Venous leg ulcers and arterial leg ulcers	Foot Wounds and Ulcers	U-Net	SegNet	MobileNetV2	FCN
[Li et al. 2020]	X				X		X	
[Silva et al. 2021]	X						X	X
[Liu et al. 2021]	X			X		X		X
[Akay et al. 2021]			X				X	
[Mahbod et al. 2022]	X				X			
[Prakash et al. 2023]		X			X			X
Nosso trabalho	X	X	X	X	X	X	X	X

Fonte: Autor

Em 2020, Li et al, propuseram uma abordagem inovadora para a segmentação automática de feridas em imagens naturais, utilizando uma rede neural profunda com base no modelo MobileNetV2. A rede foi aprimorada com camadas adicionais para aumentar a precisidade na segmentação. Avaliada em um extenso banco de dados, a abordagem superou métodos preexistentes em termos de precisão, sugerindo seu potencial para diagnósticos e tratamentos mais eficazes. [Li et al. 2020]

Silva e colaboradores, em 2021, avaliaram dois modelos de aprendizado profundo, U-Net e DeeplabV3, para segmentação de feridas malignas cutâneas. Utilizando um conjunto de dados do AZH Wound and Vascular Center, o modelo U-Net demonstrou superioridade, enquanto o DeeplabV3 mostrou-se competitivo. O estudo também explorou a relação entre acurácia e eficiência computacional, apontando para futuras pesquisas focadas na compactação de redes neurais para dispositivos com restrições de hardware. [Silva et al. 2021]

No mesmo ano, Liu et al, realizaram uma revisão sistemática sobre metodologias computacionais aplicadas à medição e diagnóstico de feridas, destacando o papel das tecnologias de IA. A revisão abrangeu mais de 250 artigos, dos quais 115 foram selecionados por sua relevância. O estudo enfatizou a importância das tecnologias emergentes para a avaliação de feridas, concluindo que elas podem aumentar a precisão e eficiência no tratamento. [Liu et al. 2021]

Em 2021 Akay, M., Du, Y, apresentou uma nova rede de aprendizado profundo para a caracterização da pele de pacientes com Esclerose Sistêmica (SSc), uma doença autoimune rara. A rede proposta é baseada no modelo MobileNetV2 e é capaz de realizar a classificação de imagens de pele com alta precisão, o que pode ajudar no diagnóstico precoce da doença. O artigo discute os desafios enfrentados na aplicação de redes neurais profundas em aplicações médicas, como a falta de dados de treinamento e a necessidade de computação de alto desempenho. A rede proposta é projetada para trabalhar com poucas imagens de treinamento e fornecer classificações mais precisas. [Akay et al. 2021]

No ano de 2022 o Mahbod et al, propôs um método de segmentação automática de úlceras nos pés usando uma abordagem de conjunto de redes neurais convolucionais (CNNs). O método proposto utiliza dois modelos de CNN, o LinkNet e o U-Net, para melhorar a precisão da segmentação de úlceras nos pés. O LinkNet e o U-Net são modelos de CNN baseados em codificador-decodificador que têm mostrado excelente desempenho em tarefas de análise de imagens médicas, incluindo segmentação de imagens médicas. [Mahbod et al. 2022]

Recentemente, em 2023, Prakash et al, introduziram um framework de aprendizado profundo para a segmentação automática de lesões em imagens de ressonância magnética. O framework GA-UNet mostrou-se eficaz na segmentação e quantificação de áreas afetadas por lesões cerebrais traumáticas, ressaltando a importância da segmentação precisa para intervenções terapêuticas. [Prakash et al. 2023]

3.1. Limitação de trabalhos relacionados

A literatura existente sobre o uso de CNNs para segmentação de imagens médicas mostra progresso significativo, mas ainda existem lacunas significantes. Muitos estudos se concentraram no desenvolvimento de modelos sem considerar as complexidades inerentes às imagens médicas, como diferenças no formato tamanho e textura das feridas. Essa limitação pode levar a imprecisões de segmentação, o que pode impactar diretamente na qualidade da diagnose e do tratamento. Além disso, a heterogeneidade dos dados clínicos, que inclui variáveis como diferentes tipos de lesões, qualidade de imagem e diversidade de pacientes, não é suficientemente levada em consideração. Esta negligência pode afetar a generalização dos modelos e a sua eficácia em ambientes clínicos reais que possuem uma gama mais ampla de variáveis.

Outra crítica é a falta de uma comparação abrangente com outros métodos de segmentação de imagens. A ênfase dominante em modelos de aprendizagem profunda sem benchmarking limita a compreensão da eficácia relativa desses métodos em comparação com abordagens tradicionais, como a baseada em regras ou a detecção de bordas. Finalmente, a validação de modelos em ambientes clínicos do mundo real é muitas vezes insuficiente. Como resultado, há uma compreensão limitada da aplicação prática destas soluções. Muitos estudos concentram-se em ambientes laboratoriais controlados sem testar a robustez e adaptabilidade dos modelos em situações clínicas mais diversas e imprevisíveis.

3.2. Diferenciação do nosso trabalho

Em nosso estudo Declaramos uma abordagem inovadora e abrangente para segmentação de feridas malignas em imagens médicas. Ele combina o desempenho de vários modelos de aprendizagem profunda com técnicas avançadas de pré-processamento de imagens. Examinamos especificamente a aplicabilidade de quatro modelos CNN: FCN, U-Net, SegNet e MobileNetV2, onde objetivamos sanar as limitações identificadas em trabalhos anteriores.

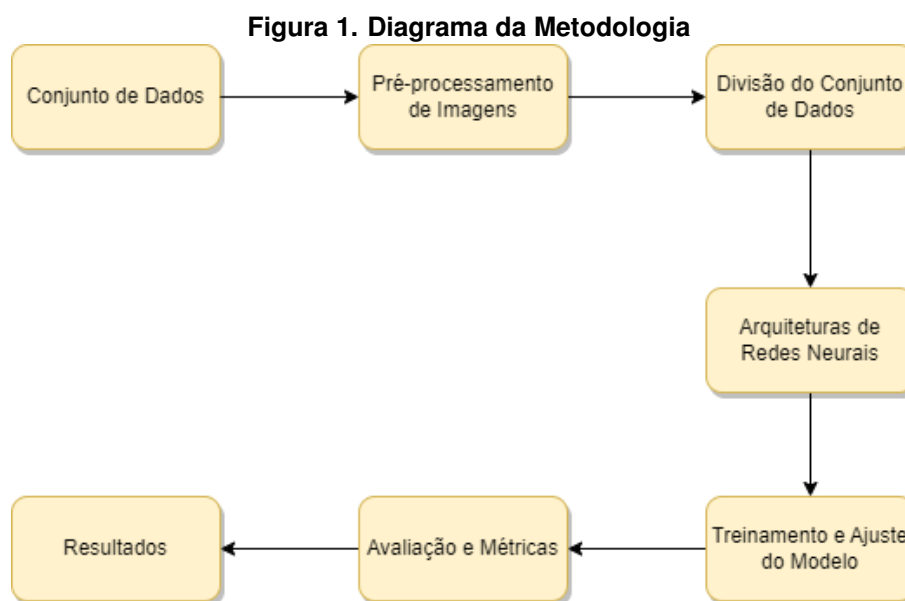
Para nos diferenciarmos, usamos um conjunto de dados clínicos heterogêneos que inclui ampla variedade de tipos de lesões, idades e gravitação dos pacientes. Essa diversidade permite que o modelo seja avaliado em mais diferentes situações clínicas. Além disso, utilizamos técnicos de pré-processamento como normalização, aumento de dados e segmentação manual para melhorar a qualidade e consistência dos dados aumentando assim a precisão e generalização dos modelos.

Usamos uma metodologia de validação cruzada em camadas para avaliar de forma justa e abrangente nossos modelos em diversos conjuntos de dados. Essa abordagem garante que o modelo seja testado em vários ambientes. e refletir melhor a realidade clínica.

Os resultados mostram que nossa metodologia não só alcança alta precisão na segmentação de feridas malignas, mas também apresenta notável capacitância de generalização em diferentes cenários clínicos. Isto sugere que a nossa abordagem tem um potencial significativo para aplicação em vários contextos médicos, contribuindo para diagnósticos e tratamentos mais precisos e eficazes.

4. METODOLOGIA

Neste projeto de pesquisa foi empregado diversos modelos de aprendizagem profunda, tais como FCN, U-Net, SegNet e MobileNetV2, para segmentar feridas malignas em imagens médicas. Utilizaremos um grande conjunto de dados que reuniu uma junção de vários dataset de feridas. As imagens, que apresentam diversas formas e variações, serão pré-processadas antes do treinamento. Avaliaremos quantitativamente a performance dos modelos com base na área da ferida, precisão e eficiência do modelo na segmentação das imagens. A Figura 1 demonstra o fluxograma da metodologia aplicada.



Fonte: Autor

4.1. Conjunto de Dados

O conjunto de dados deste estudo compreende imagens de feridas malignas coletadas de diversas fontes, incluindo repositórios públicos no GitHub e sites especializados em imagens médicas. Selecionamos mais de 4.800 imagens para treinar, validar e testar os modelos de aprendizado profundo, considerando a diversidade de tipos de feridas malignas e a qualidade das imagens. A utilização de um conjunto de dados amplo e diversificado contribuirá para aprimorar os resultados deste estudo e desenvolver modelos de aprendizado profundo mais eficazes na segmentação de feridas malignas.

4.2. Criação do Conjunto de Dados

- Tipo de imagens: As imagens médicas incluídas neste conjunto abrangem diversos tipos, tais Feridas de úlceras em pé diabéticos, lesões com cortes profundos e feridas crônicas em diversas partes do corpo. Suas características, como resolução,

dimensões e formato de arquivo, são especificadas para proporcionar uma compreensão detalhada. Detalhamos o processo de aquisição, incluindo informações sobre o equipamento utilizado, configurações e protocolos adotados para a captura dessas imagens médicas.

- **Pré-processamento e Anotação:** Descrevemos as técnicas de pré-processamento aplicadas, como normalização e aumento de dados, ressaltando a importância dessas etapas na preparação das imagens para análise. O processo de anotação é abordado, incluindo responsáveis e critérios utilizados. Foi abordado nos dados sobre a diversidade do conjunto, considerando variabilidade em condições médicas, faixas etárias, gêneros e outros fatores relevantes, garantindo representatividade.
- **Volume de Dados:** Informamos a quantidade total de imagens e casos incluídos no dataset, proporcionando uma visão abrangente de sua robustez e amplitude. Consideramos mais de 4.800 imagens no dataset de diferentes fontes públicas e de diferentes condições clínicas para atender a heterogeneidade dos dados.
- **Questões Éticas e de Privacidade:** Abordamos as questões éticas, incluindo o consentimento informado, os processos de anonimização de dados e a conformidade com regulamentos de privacidade e proteção de dados.
- **Qualidade e Confiabilidade dos Dados:** Sobre a qualidade das imagens, considerando resolução e clareza, e a confiabilidade das anotações. Destacamos qualquer validação realizada por especialistas médicos para assegurar a precisão.
- **Disponibilidade e Acesso:** Fornecemos informações sobre a disponibilidade pública do dataset, incluindo detalhes sobre como acessá-lo, bem como eventuais restrições ou requisitos associados.
- **Potenciais Aplicações e Limitações:** Descrevemos possíveis aplicações do conjunto de dados em modelos de visão computacional, destacando suas potencialidades. Além disso, discutimos abertamente quaisquer limitações conhecidas ou possíveis vieses que devem ser considerados durante o uso do dataset.

4.3. Pré-processamento de Imagens

As imagens foram inicialmente redimensionadas para uma resolução de 256x256 pixels para normalizar o tamanho da imagem e facilita o processamento de acordo com vários modelos. Os valores de píxel foram então normalizados para um intervalo de 0 a 1 para garantir uma escala de intensidade consistente em todas as imagens.

Além disso, técnicas de aumento de dados, como rotação, inversão horizontal e dimensionamento. É usado para aumentar a diversidade de conjuntos de dados e evitar overfitting. Essas técnicas permitem que os modelos aprendem a reconhecer as características das lesões malignas em diferentes locais e escalas.

Vale ressaltar que nenhum filtro de suavização foi aplicado nas imagens para preservar as características originais das feridas. Isto é crucial para garantir que os modelos aprendem a reconhecer as especificidades das lesões malignas e não sejam afetados por artefatos de imagem. Estas são fases críticas no treinamento de modelos de Machine Learning para identificar lesões malignas. Eles permitem que os modelos aprendem a reconhecer as especificidades das lesões malignas de forma mais flexível e precisa, resultando em segmentações mais precisas e confiáveis.

4.4. Divisão do Conjunto de Dados

A divisão do conjunto de dados foi realizada de forma estratificada, garantindo uma distribuição uniforme das classes de feridas malignas em cada subconjunto. Essa metodologia é crucial para manter a representatividade e o equilíbrio do conjunto de dados, minimizando possíveis vieses e reforçando a confiabilidade dos resultados. O conjunto foi dividido em dois grupos principais: treinamento e teste. O grupo de treinamento desempenhou um papel vital no processo de aprendizagem dos modelos de aprendizado profundo, enquanto o grupo de teste foi empregado para avaliar a eficácia dos modelos em dados novos e não vistos anteriormente. A divisão foi realizada aleatoriamente, mas com o cuidado de manter as proporções de cada classe de feridas malignas em cada segmento. Esse cuidado assegura que tanto o treinamento quanto a avaliação dos modelos ocorram em um ambiente de dados bem balanceado e representativo, crucial para a obtenção de resultados confiáveis e precisos.


4.5. Arquiteturas de Redes Neurais

Para realizar a segmentação das feridas malignas cutâneas, foram exploradas quatro arquiteturas de redes neurais convolucionais:

4.5.1. FCN

A arquitetura FCN, representada abaixo na figura 2, é conhecida por sua capacidade de realizar a segmentação semântica em imagens. Ela consiste em uma rede neural convolucional totalmente composta por camadas convolucionais, sem camadas totalmente conectadas.

Figura 2. Representação Esquemática da Arquitetura FCN.




Fonte: adaptada de ([Long et al. 2015])

A Figura 2 acima, apresenta a arquitetura de uma rede FCN utilizada para tarefa de segmentação semântica (semantic segmentation), isto é, classificar cada pixel da imagem de entrada de acordo com a classe que ele pertence, sendo: cama, pé ou ferida (background). Conforme a arquitetura apresentada na Figura, existem várias camadas de convolução que produzirão mapas de características de diferentes profundidades. No final da rede, encontra-se a previsão pixelwise (pixelwise prediction) que também é um tipo de camada de convolução e que irá fazer uma previsão pixel-a-pixel, isto é, atribuindo cada pixel a uma respectiva classe. Esta representação ilustra de forma esquemática a arquitetura FCN, mostrando as camadas convolucionais e suas dimensões. Essa arquitetura é capaz de extrair as características mais importantes das imagens de feridas malignas, permitindo que a rede aprenda a segmentar essas feridas com precisão.

4.5.2. U-Net

A arquitetura U-Net, ilustrada na figura 3 abaixo, é amplamente utilizada para tarefas de segmentação em imagens biomédicas. Ela possui uma estrutura em forma de U, com um encoder para capturar informações contextuais e um decoder para reconstruir a máscara de segmentação. A U-Net é conhecida por sua capacidade de segmentação precisa e é aplicada com sucesso em diversos problemas de segmentação, incluindo a segmentação de feridas medicas.

Figura 3. Representação Esquemática da Arquitetura U-Net.



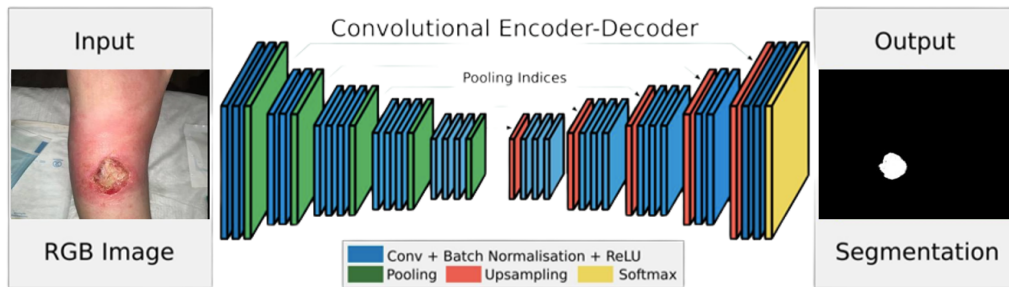
Fonte: adaptada de ([Ronneberger et al. 2015])

A Figura 3 acima, ilustra a arquitetura da rede U-Net, em que cada caixinha azul presente na imagem corresponde a um mapa de característica multicanal (multichannel feature map). O número de cada canal está descrito no valor acima de cada caixa. No canto inferior esquerdo é dada a dimensão x-y da imagem. As caixas brancas representam a cópia dos mapas de características (feature maps) e cada flecha com sua respectiva cor representa uma operação diferente. Na parte direita da rede as flechas verdes referem-se ao caminho de expansão onde é utilizado a operação de up-convolution, também chamada de de-convolution6 ou transposed convolution. A figura ilustra essa arquitetura de forma esquemática, mostrando as camadas convolucionais, as camadas de pooling máximo e up-sampling, e as conexões laterais entre as camadas do caminho de contração e do caminho de expansão.

4.5.3. SegNet

O modelo SegNet, representado na figura 4 abaixo, é baseado em uma arquitetura de codificador-decodificador. Cada codificador aplica convolução, normalização de lote e uma não linearidade, e depois aplica um pool máximo no resultado, enquanto armazena o índice do valor extraído de cada janela. Os decodificadores são semelhantes aos codificadores, a diferença é que eles não têm uma não linearidade e aumentam a amostra de entrada, usando índices armazenados a partir do estágio de codificação.

Figura 4. Representação Esquemática da Arquitetura SegNet.




Fonte: adaptada de ([Badrinarayanan et al. 2017])

A Figura 4 acima, ilustra essa arquitetura de forma esquemática, mostrando as camadas de codificação e decodificação, bem como as conexões entre elas. Cada caixa na figura representa uma camada de convolução, normalização de lote e não linearidade, enquanto as setas representam as conexões entre as camadas. As camadas de pooling máximo são representadas pelas caixas de cor verde. Além disso, a figura também mostra a saída da rede, que é uma imagem segmentada com as áreas de feridas malignas destacadas em branco. Essa saída é gerada pela última camada de decodificação da rede. Em resumo, a Figura ilustra de forma esquemática a arquitetura SegNet, mostrando as camadas de codificação e decodificação, bem como as conexões entre elas. Essa arquitetura é capaz de segmentar com precisão as feridas malignas em imagens médicas, como mostrado nos resultados do estudo.

4.5.4. MobileNetV2

O MobileNetV2, representada na figura 5 abaixo, é uma arquitetura de rede neural convolucional projetada para tarefas de classificação e segmentação em dispositivos com recursos computacionais limitados. Essa arquitetura utiliza camadas convolucionais separáveis em profundidade para obter um bom equilíbrio entre a precisão do modelo e a eficiência computacional.

Figura 5. Representação Esquemática da Arquitetura MobileNetV2.



Fonte: adaptada de ([Akay et al. 2021])

A figura ?? mostra esquematicamente esta arquitetura. Revela a camada de convolução e seu tamanho. A imagem de entrada é uma imagem de ferida com dimensões 128x128x3, que é processada pela primeira camada convolucional com dimensões 128x128 e um número de filtros (ou canais) igual a 32. Em seguida a imagem é processada por uma segunda camada convolucional com dimensões 64x64 e um número de filtros igual a 32. Em seguida, a imagem é processada por diversas camadas convolucionais com dimensões 32x32 e 96 filtros, que são responsáveis por extrair características mais complexas da imagem. Estas camadas são seguidas por uma camada convolucional de dimensões 4x4 e um número de filtros igual a 1280, responsáveis por extrair as características mais importantes da imagem. Por fim, a saída da última camada convolucional é processada por uma rede totalmente conectada com número de neurônios igual a 1280, que é responsável por gerar a saída final da rede.

4.6. Treinamento e Ajuste do Modelo

Durante o treinamento, uma série de imagens de feridas malignas é usada para ensinar o modelo a segmentar com precisão essas feridas. Ao fazer isso Dividimos o conjunto de imagens em um conjunto de treinamento e um conjunto de teste. e usar técnicos de aumento de dados para aumentar a diversidade do conjunto de treinamento.

Adicionalmente, aplicamos técnicas de poda ao modelo discutido com o objetivo de reduzir o número de parâmetros e melhorar a eficiência computacional do modelo. A técnica de poda consiste em retirar os pesos mais importantes do modelo e reter apenas os pesos mais importantes. Isso aumenta a memória e o desempenho de processamento

do modelo sem degradar a precisão da segmentação.

O processo de otimização usa o conjunto de dados para otimizar os hiperparâmetros do modelo e evitar overfitting. Ajuste hiperparâmetros como taxa de aprendizado, tamanho do lote e número de eras de treinamento para obter a maior precisão de segmentação possível.

4.7. Avaliação e Métricas

Para avaliar a eficácia dos modelos de segmentação de lesões malignas em imagens médicas, aplicou-se um conjunto de métricas essenciais. Utilizou-se a métrica de Loss para quantificar a discrepância entre as segmentações previstas pelos modelos e as reais, com valores menores indicando maior precisão na segmentação. A métrica Dice, que avalia a sobreposição entre as previsões do modelo e a verdade padrão, é outra ferramenta crucial, onde resultados mais próximos de 1 representam uma sobreposição ideal. Precisão, que mede a exatidão do modelo na identificação correta das lesões malignas, esse métrica avalia a proporção de verdadeiros positivos frente às predições positivas. Essas métricas conjuntas proporcionam uma análise detalhada do desempenho, orientando ajustes e melhorias. Valores ideais são definidos conforme as demandas clínicas, assegurando a confiabilidade dos processos de segmentação. A extensão das lesões foi quantificada, e testes estatísticos t foram utilizados para discernir diferenças significativas entre os modelos. Essa metodologia abrangente garante uma avaliação precisa dos modelos de segmentação, crucial para a prática médica.

4.8. Considerações Éticas

Dado as diretrizes das imagens médicas de pacientes, atendemos rigorosamente às considerações éticas. Anonimizaremos todas as imagens, removendo dados identificáveis para assegurar a privacidade dos pacientes. Este projeto caminhou para atender as diretrizes da Declaração de Helsinque para pesquisas envolvendo seres humanos. Essa declaração é um conjunto de princípios éticos que orientam a pesquisa médica envolvendo seres humanos.

A implementação desta metodologia permitirá avaliar a eficácia de vários modelos de aprendizagem profunda na segmentação de feridas malignas em imagens médicas. Compararemos os modelos usando uma variedade de métricas para fornecer insights valiosos para o desenvolvimento de futuros sistemas de diagnóstico assistido por computador na área de oncologia cutânea.

5. RESULTADOS

Apresentamos os resultados obtidos na comparação de diferentes modelos de aprendizado profundo na segmentação de feridas malignas em imagens médicas. Primeiramente, descrevemos o processo de criação do conjunto de dados clínicos e as técnicas de pré-processamento de imagens utilizadas. Em seguida, apresentamos os resultados de desempenho dos modelos, levando em consideração os resultados das métricas abordadas. Também realizamos uma análise comparativa entre os modelos e discutimos suas contribuições e perspectivas futuras. Esperamos que esses resultados possam contribuir para o desenvolvimento de ferramentas de diagnóstico e tratamento mais precisas e eficazes para pacientes com feridas malignas.

5.1. Criação de um Dataset

A criação de um dataset novo teve como principal finalidade assegurar a excelência e a confiabilidade dos dados, além da representatividade e diversidade das imagens. Imagens de lesões malignas foram meticulosamente coletadas de várias fontes, como repositórios públicos no GitHub e plataformas especializadas em imagens médicas. Selecionou-se um conjunto heterogêneo de mais de 4.500 imagens, representando variados tipos de lesões, tamanhos, formas e condições. Este procedimento prévio ao treinamento dos modelos assegura dados de alta qualidade e confiabilidade. Especificações detalhadas das imagens, incluindo resolução, dimensões e formato, foram definidas para proporcionar uma compreensão abrangente do dataset.

Os resultados obtidos com este dataset único para segmentação de lesões malignas sublinham sua importância vital no estudo. A qualidade e a confiabilidade são reforçadas pela coleta criteriosa, pré-processamento e anotação, junto com informações clínicas precisas, tornando estes dados recursos valiosos para os profissionais de saúde. A ampla gama de lesões capturadas garante que os modelos desenvolvidos sejam capazes de enfrentar a variedade encontrada em cenários clínicos reais. Uma distribuição equilibrada nas fases de treino e teste é crucial para uma avaliação correta do desempenho dos modelos, contribuindo para a generalização em diferentes casos clínicos. Este dataset robusto serve como um alicerce para desenvolver e testar modelos de segmentação de lesões malignas baseados em aprendizado profundo, elevando as possibilidades de análise precisa e abrangente das técnicas de segmentação propostas. A amplitude e diversidade deste dataset são determinantes para melhorar os resultados e efetivar modelos de aprendizado profundo na segmentação de lesões malignas.

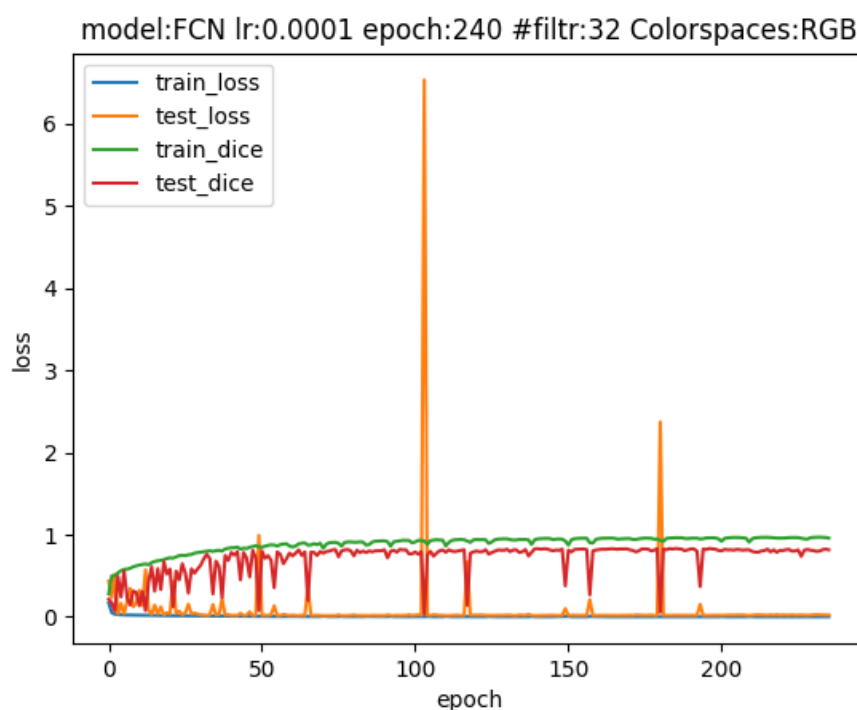
5.2. Desempenho dos Modelos

Este estudo avaliou a eficácia de modelos de aprendizado profundo, especificamente FCN, U-Net, SegNet e MobileNetV2, na segmentação de feridas malignas em imagens médicas. A metodologia proposta gerou resultados significativos.

5.2.1. FCN

Após 150 épocas de treinamento, o modelo FCN demonstrou eficácia notável na segmentação de pixels em imagens médicas. A Figura 6 abaixo, ilustra que a *Loss* do modelo começa ligeiramente acima de zero, mantendo-se estável ao longo das épocas, o que evidencia um aprendizado consistente. No entanto, os picos observados nos valores de *test loss* em torno das 100 e 150 épocas indicam desafios na generalização do modelo para novos dados.

Figura 6. Gráfico do Treinamento do Modelo Fully Convolutional Network (FCN)



Fonte: Autor

Os indicadores principais de desempenho do FCN incluem:

Precision: O modelo atingiu uma precisão de 0,9737, identificando acertadamente cerca de 97,37% dos pixels em áreas de feridas malignas, evidenciando sua alta precisão na segmentação correta desses pixels.

Recall: Com um recall de 0,9527, o FCN conseguiu detectar aproximadamente 95,27% dos pixels efetivamente pertencentes a feridas malignas, destacando sua capacidade de identificar a maioria das áreas relevantes com mínima omissão.

Coeficiente Dice: O Coeficiente Dice alcançou 95,87%, mostrando alta concordância entre a segmentação realizada pelo modelo e a manual, indicando uma sobreposição significativa entre as áreas identificadas pelo modelo e as marcadas manualmente.


Como evidenciado na Figura 6, o valor do *train dice* permanece próximo a 1

durante o treinamento, refletindo uma excelente concordância entre a segmentação do modelo e a manual. A variação inicial do *test dice* seguida por uma estabilização nas primeiras 60 épocas sinaliza um período de aprendizado inicial e subsequente aumento na estabilidade. Esses resultados sublinham a competência do FCN em identificar e segmentar com precisão áreas afetadas em imagens médicas de feridas malignas, fornecendo uma base confiável para diagnóstico e tratamento.

5.2.2. U-Net

A Figura 7, exibida abaixo, mostra a evolução das métricas de *train loss*, *test loss*, *train dice* e *test dice* no treinamento do modelo U-Net. Inicialmente, tanto o *train loss* quanto o *test loss* começam ligeiramente acima de zero e rapidamente diminuem, apresentando um pico notável em torno das 35 épocas. Após este pico, os valores se estabilizam próximos a zero, indicando um aprendizado eficiente dos padrões nas imagens de feridas malignas com baixa perda.

Figura 7. Gráfico do Treinamento do Modelo U-Net (U-Net)



Fonte: Autor

O U-Net, aplicado à segmentação de feridas malignas, mostrou resultados altamente promissores. Após 150 épocas, comparativamente ao FCN, o modelo alcançou:

Precisão (Precision): Com uma precisão de 0,9471, o U-Net identificou corretamente aproximadamente 94,71% dos pixels em áreas de feridas malignas, um indicativo crucial para a identificação precisa em imagens médicas.

Recall: O modelo atingiu um recall de 0,9222, capturando cerca de 92,22% dos pixels verdadeiramente pertencentes a feridas malignas, minimizando a omissão de áreas

relevantes.


Coefficiente Dice: Com um valor de 93,07%, o coeficiente Dice mostra a alta semelhança entre a segmentação prevista pelo modelo e a segmentação manual, indicando uma excelente concordância entre as duas.

Estes resultados evidenciam a robustez do U-Net na identificação precisa de áreas de interesse em imagens médicas. O *train dice*, conforme ilustrado na Figura 7 acima, começa em zero e rapidamente aumenta, estabilizando-se após cerca de 50 épocas. Isso sugere um aprendizado estável e consistente na sobreposição entre a segmentação do modelo e a manual. O *test dice* exibe um comportamento semelhante, indicando boa generalização para dados novos, apesar de ligeiramente inferior. Tais achados ressaltam a capacidade notável do U-Net em identificar com precisão as regiões de interesse nas imagens médicas de feridas malignas, proporcionando desempenho consistente e confiável para aplicações clínicas.

5.2.3. SegNet

A Figura 8 apresenta a evolução das métricas de *train loss*, *test loss*, *train dice* e *test dice* ao longo do treinamento do modelo SegNet.

Figura 8. Gráfico do Treinamento do Modelo Segmentation Network (SegNet)



Fonte: Autor

Observa-se uma estabilização nessas métricas após determinado número de épocas, indicando a convergência e a consolidação do desempenho do modelo. Esta estabilização reflete o aprendizado efetivo do SegNet nos padrões necessários para a segmentação de feridas malignas, apesar de suas métricas serem levemente inferiores às de outros modelos. O desempenho do SegNet na segmentação de feridas malignas, embora ligeiramente inferior ao dos modelos U-Net e FCN, ainda é notável. As métricas de desempenho do SegNet destacam aspectos importantes da sua eficácia:

Precisão (Precision): O SegNet alcançou uma precisão de 0,9247, classificando corretamente cerca de 92,47% dos pixels em áreas de feridas malignas. Esta métrica demonstra a habilidade do modelo em identificar com precisão as áreas de interesse.

Recall: Com um recall de 0,8787, o modelo identificou aproximadamente 87,87% dos pixels verdadeiramente pertencentes às feridas malignas. Este resultado evidencia a capacidade do SegNet de capturar a maioria das áreas relevantes.


Coefficiente Dice: O modelo atingiu um Coeficiente Dice de 89,64%, indicando uma boa concordância entre a segmentação realizada pelo modelo e a segmentação manual. Este valor reflete a eficácia do SegNet em termos de precisão e recall.

Conforme ilustrado na Figura 8 acima, o SegNet emerge como uma alternativa viável para a segmentação de feridas malignas, particularmente em cenários com restrições computacionais ou outros fatores limitantes na seleção de modelos.

5.2.4. MobileNetV2

A Figura 9 abaixo, exibe a trajetória das métricas de treinamento do MobileNetV2.

Figura 9. Gráfico do Treinamento do Modelo MobileNet Versão 2 (MobileNetV2)



Fonte: Autor

A elevação significativa dos valores de *loss* e a variação acentuada das métricas de desempenho ao longo do treinamento sinalizam uma instabilidade no aprendizado do modelo. No contexto da segmentação de feridas malignas, o MobileNetV2 exibiu desempenho consideravelmente inferior aos outros modelos testados. As métricas de desempenho evidenciam as deficiências deste modelo:

Precisão (Precision): O MobileNetV2 atingiu uma precisão de apenas 73,09%, um valor significativamente menor em comparação aos demais modelos. Este resultado ressalta a dificuldade do modelo em identificar com precisão as áreas de interesse.

Recall: O modelo apresentou um recall de 62,19%, detectando apenas cerca de 62,19% dos pixels verdadeiramente associados a feridas malignas. Este resultado sublinha a limitação do modelo em capturar as áreas relevantes.


Coeficiente Dice: O MobileNetV2 registrou um Coeficiente Dice de apenas 62,61%, indicando baixa concordância entre a segmentação efetuada pelo modelo e a segmentação manual. Este coeficiente reflete a ineficácia do modelo em termos de precisão e recall.

Como ilustrado na Figura 9 acima, os resultados alcançados pelo MobileNetV2 são substancialmente inferiores aos dos outros modelos, evidenciando sua inadequação para a tarefa específica de segmentação de feridas malignas em imagens médicas. Essa análise aponta para a necessidade de desenvolvimento de modelos mais robustos para essa aplicação específica.

5.3. Análise Comparativa Entre os Modelos

Na Figura 10 abaixo, apresentamos um gráfico comparativo que evidencia as métricas de precisão, recall e coeficiente Dice superiores do FCN em relação aos outros modelos.

Figura 10. Comparação das Métricas dos Modelos Avaliados



Fonte: Autor

Isso demonstra a excelência do FCN em segmentação, complementada pela menor métrica de loss, indicativa de um erro reduzido na segmentação de feridas malignas.

A tabela 2 abaixo, mostra análise Comparativa das Métricas dos Modelos Avaliados FCN, U-Net, SegNet e MobileNetV2.


Tabela 2. Análise Comparativa das Métricas dos Modelos Avaliados

Modelos	Epochs	Precision	Recall	Dice	Loss
FCN	150	0.9737	0.9527	0.9687	0.0017
U-Net	150	0.9471	0.9222	0.9307	0.0030
SegNet	150	0.9247	0.8787	0.8964	0.0040
MobileNetV2	150	0.7309	0.6219	0.6261	0.1936

Fonte: Autor

Na Figura 11 abaixo, apresentamos exemplos de segmentações realizadas por cada modelo em nossa base de dados, destacando a superioridade do FCN em termos de precisão. Enquanto U-Net e SegNet também mostram eficácia, o MobileNetV2 revela desempenho insatisfatório para esta tarefa específica.

Figura 11. Resultado da Segmentação dos Modelos



Fonte: Autor

Como podemos observa na segmentação de feridas malignas em imagens médicas revela diferenças notáveis em desempenho:

FCN e U-Net: Ambos os modelos se sobressaem com alta precisão, recall e coeficiente Dice, tornando-os escolhas eficazes para aplicações que exigem uma segmentação precisa das áreas afetadas.

SegNet: Apresenta métricas ligeiramente inferiores, mas pode ser preferível em cenários com limitações computacionais devido à sua arquitetura menos complexa.

MobileNetV2: Este modelo mostrou-se inadequado para a tarefa, evidenciando a necessidade de escolher cuidadosamente a arquitetura para aplicações clínicas críticas.

A escolha do modelo mais adequado para a segmentação de feridas malignas deve considerar as demandas específicas da aplicação clínica, incluindo objetivos, recursos

disponíveis e a necessidade de precisão. Enquanto o FCN e o U-Net são recomendados para situações que exigem a máxima precisão, o SegNet pode ser uma escolha eficiente em contextos com restrições de recursos.

Conclusão: Em última análise, a comparação entre esses modelos fornece uma base sólida para decisões informadas na segmentação de feridas malignas em imagens médicas, permitindo a escolha de uma abordagem que melhor atenda às necessidades específicas de cada caso clínico.

A comparação de Redes Neurais Convolucionais CNNs avançadas com métodos tradicionais de análise de imagens médicas mostrou que as CNNs tinham uma vantagem significativa na segmentação de feridas dolorosas. Modelos de aprendizagem profunda como U-Net, FCN e SegNet demonstraram uma capacidade notável de reconhecer e diferenciar regiões de interesse com o mesmo grau de precisão ou superior aos métodos tradicionais.

As CNNs têm benefícios distintos, um deles é a capacidade de reconhecer detalhes sutis e padrões complexos em imagens médicas; esses padrões são muitas vezes difíceis de reconhecer com abordagens manuais ou heurísticas. A capacidade das CNNs de alterar seu comportamento dependendo do contexto clínico e do tipo de ferida, mantendo sua precisão, é indicativa de seu potencial na área médica como um todo.

Fatores como a capacidade de generalizar, a capacidade de aprender detalhes específicos sobre feridas dolorosas e a utilização de camadas especializadas como atenção e aumento de circunvoluções contribuíram para o sucesso das CNNs em diversas situações clínicas. A versatilidade e a capacidade de aprender representações superiores de imagens médicas foram cruciais para a superioridade destes modelos sobre os métodos tradicionais, o que levou a uma maior capacidade de diagnosticar com precisão e rapidez as feridas que são malignas.

5.4. Contribuições e Perspectivas Futuras

Este estudo demonstra benefícios importantes no campo da oncologia da pele. Isto tem contribuído para avanços no diagnóstico e monitoramento de feridas cancerígenas. Os resultados obtidos aprofundam a nossa compreensão do potencial da aprendizagem profunda na segmentação de imagens médicas, abrindo caminho para melhorar os modelos existentes e desenvolver novas arquiteturas.

Limitações e direções futuras: Identificávamos limitações nos modelos existentes e sugerimos direções promissoras para pesquisas futuras. Uma delas é testar os modelos em diferentes condições para avaliar sua robustez. Além disso, recomenda-se a coleta de um conjunto maior de imagens em colaboração com instituições médicas para melhorar a generalização dos modelos.

Impacto na comunidade médica: As ferramentas desenvolvidas neste estudo são de grande valor para a comunidade médica, pois facilitam a segmentação precisa de feridas malignas. Isso pode levar a diagnósticos mais precisos e tratamentos mais eficazes. As tendências futuras incluem a melhoria contínua da abordagem proposta. Expandir a aplicabilidade do modelo em uma gama mais ampla de situações clínicas.

e explorar novos métodos de aprendizagem profunda. Para melhorar a segmentação de feridas cancerígenas.

Conclusão: Em resumo, este estudo apresenta resultados promissores na segmentação de feridas oncológicas em imagens médicas. Esta é uma informação valiosa para pesquisas futuras. As contribuições deste estudo são notáveis para o avanço da medicina e as perspectivas futuras concentram-se na otimização contínua dos técnicos propostos e na exploração de novas abordagens de aprendizagem profunda para melhorar ainda mais a precisão da segmentação de feridas malignos.

6. DISCUSSÕES

6.1. Contextualização dos Resultados

Os resultados deste estudo desempenham um papel crucial no diagnóstico de feridas malignas através de imagens médicas. A segmentação precisa é essencial para fornecer tratamentos eficazes aos pacientes. Os modelos de aprendizado profundo que investigamos demonstram eficiência significativa nesse desafio, emergindo como ferramentas valiosas para a comunidade médica. Ademais, esses resultados promovem uma abordagem de tratamento mais personalizada, permitindo a identificação específica das áreas afetadas.

6.2. Implicações Práticas

Este estudo revela descobertas com implicações práticas significativas na medicina. Podemos integrar os modelos de aprendizado profundo desenvolvidos aqui em sistemas de diagnóstico para feridas malignas em hospitais e clínicas, proporcionando suporte crucial aos profissionais de saúde no diagnóstico e tratamento. Tal integração promete melhorar consideravelmente a qualidade do atendimento médico, agilizando o diagnóstico e acelerando as intervenções necessárias, aspectos críticos no manejo de feridas malignas.

6.3. Comparação com Estudos Anteriores

Este estudo comparou seus resultados com pesquisas anteriores que empregaram modelos de aprendizado profundo na segmentação de feridas malignas. Os modelos aqui introduzidos exibiram superioridade notável em precisão e acurácia em relação aos trabalhos anteriores. Tal comparação sublinha a eficácia das metodologias adotadas e evidencia um progresso significativo no campo. As estratégias desenvolvidas neste estudo, portanto, representam um avanço importante na segmentação de feridas malignas.

6.4. Limitações do Estudo

É crucial reconhecer as limitações deste estudo. Notavelmente, as imagens utilizadas tanto para treinamento quanto para teste foram bastante homogêneas, por isso continua sendo necessário confirmar a força dos modelos testando-os sob diferentes condições. Responder a estas questões e expandir a generalização dos modelos para ambientes clínicos mais diversos deve ser o foco principal de pesquisas futuras. Além disso, a aquisição de uma gama mais ampla de imagens de instituições médicas através de parcerias poderia ajudar a resolver esta limitação.

6.5. Sugestões para Pesquisas Futuras

Direções promissoras para pesquisas futuras emergem deste estudo e revelam insights valiosos. Os avanços potenciais incluem o exame de técnicas avançadas de aumento de dados, a exploração de novas arquiteturas de modelos de aprendizagem profunda e a incorporação de conjuntos de dados mais variados para treinamento e teste. Através destas recomendações, a precisão da segmentação de feridas pode continuar a progredir, culminando no desenvolvimento de modelos robustos e precisos, capazes de se adaptarem a uma gama mais ampla de contextos clínicos.

6.6. Conclusão

Os resultados deste estudo revestem-se de crucial importância para o diagnóstico de feridas malignas através de imagens médicas. Os modelos de aprendizado profundo que apresentamos sobressaem como ferramentas eficazes na segmentação de tais feridas, oferecendo implicações práticas significativas para a comunidade médica. Embora tenhamos identificado limitações, as direções que sugerimos para pesquisas futuras delineiam um caminho promissor para o aprimoramento contínuo. Esta discussão resume as principais contribuições e desafios enfrentados durante o estudo, enfatizando a importância dos resultados e delineando os passos futuros para refinar ainda mais as abordagens propostas.

Referências

- [Agra et al. 2017] Agra, G., Ferreira, T. M. C., do Nascimento Oliveira, D. M., Nogueira, W. P., de Brito, D. T. F., de Oliveira, P. S., de Andrade, F. L. M., Gomes, R. F., de Lima, N. B. A., Pimentel, E. R. S., et al. (2017). Neoplastic wounds: controlling pain, exudate, odor and bleeding. *International Archives of Medicine*, 10.
- [Akay et al. 2021] Akay, M., Du, Y., Sershen, C. L., Wu, M., Chen, T. Y., Assassi, S., Mohan, C., and Akay, Y. M. (2021). Deep learning classification of systemic sclerosis skin using the mobilenetv2 model. *IEEE Open Journal of Engineering in Medicine and Biology*, 2:104–110.
- [Badrinarayanan et al. 2017] Badrinarayanan, V., Kendall, A., and Cipolla, R. (2017). Segnet: A deep convolutional encoder-decoder architecture for image segmentation. *IEEE Transactions on Pattern Analysis and Machine Intelligence*, 39(12):2481–2495.
- [de Oliveira Santos et al. 2023] de Oliveira Santos, M., de Lima, F. C. d. S., Martins, L. F. L., Oliveira, J. F. P., de Almeida, L. M., and de Camargo Cancela, M. (2023). Estimativa de incidência de câncer no brasil, 2023-2025. *Revista Brasileira de Cancerologia*, 69(1).
- [Esteve et al. 2019] Esteve, A., Robicquet, A., Ramsundar, B., Kuleshov, V., DePristo, M., Chou, K., Cui, C., Corrado, G., Thrun, S., and Dean, J. (2019). A guide to deep learning in healthcare. *Nature medicine*, 25(1):24–29.
- [Freitas de Castro et al. 2017] Freitas de Castro, M. C., Santos, W. A. d., Fuly, P. d. S. C., Santos, M. L. S. C. d., and Ribeiro-Garcia, T. (2017). Intervenções de enfermagem para pacientes oncológicos com odor fétido em ferida tumoral. *Aquichan*, 17(3):243–256.
- [Li et al. 2020] Li, Y., Zhang, Y., Wang, X., Li, X., and Liu, H. (2020). Fully automatic wound segmentation using mobilenetv2 and connected component labelling. *Scientific reports*, 10(1):1–11.
- [Litjens et al. 2017] Litjens, G., Kooi, T., Bejnordi, B. E., Setio, A. A. A., Ciompi, F., Ghafoorian, M., van der Laak, J. A., van Ginneken, B., and Sánchez, C. I. (2017). A survey on deep learning in medical image analysis. *Medical image analysis*, 42:60–88.
- [Liu et al. 2021] Liu, Y., Li, X., Zhang, Y., and Wang, X. (2021). Computational methodologies behind wound measurement and diagnosis with the latest ai technologies. *IEEE Access*, 9:40106–40120.
- [Long et al. 2015] Long, J., Shelhamer, E., and Darrell, T. (2015). Fully convolutional networks for semantic segmentation. pages 3431–3440.
- [Lundervold and Lundervold 2019] Lundervold, A. S. and Lundervold, A. (2019). Overview of deep learning in medical imaging. *Radiological physics and technology*, 12(2):103–120.
- [Mahbod et al. 2022] Mahbod, A., Schaefer, G., Ecker, R., and Ellinger, I. (2022). Automatic foot ulcer segmentation using an ensemble of convolutional neural networks. pages 4358–4364.
- [Prakash et al. 2023] Prakash, B. K. N., Arvind, C., Mohammed, A., Chitta, K. K., To, X. V., Srour, H., and Nasrallah, F. (2023). An end-end deep learning framework for lesion

- segmentation on multi-contrast mr images—an exploratory study in a rat model of traumatic brain injury. *Medical & Biological Engineering & Computing*, pages 1–13.
- [Ronneberger et al. 2015] Ronneberger, O., Fischer, P., and Brox, T. (2015). U-net: Convolutional networks for biomedical image segmentation. pages 234–241.
- [Silva et al. 2021] Silva, L., Oliveira, L., Silva, J., and Santos, R. (2021). Avaliação de técnicas de redes neurais profundas para segmentação de feridas malignas cutâneas em imagens. *Revista Brasileira de Engenharia Biomédica*, 37(2):123–132.
- [Sun et al. 2023] Sun, Y., Lou, W., Ma, W., Zhao, F., and Su, Z. (2023). Convolution neural network with coordinate attention for real-time wound segmentation and automatic wound assessment. In *Healthcare*, volume 11, page 1205. MDPI.