

UNIVERSIDADE CATÓLICA DE PERNAMBUCO
CURSO DE CIÊNCIA DA COMPUTAÇÃO

Comparação de Modelos de Machine Learning na Segmentação de Feridas Malignas em Imagens Médicas

ALUNO: LUCAS DOS SANTOS AMORIM RÊGO
ORIENTADOR: RAFAEL ROQUE DE SOUZA

Projeto apresentado ao Curso de Ciência da Computação da Universidade Católica de Pernambuco, como parte dos requisitos necessários à obtenção da nota da disciplina INF 1808 - Trabalho de Conclusão de Curso.

Recife, PE, Dezembro de 2023

RESUMO

Contexto: A área da saúde demanda cada vez mais a segmentação precisa de imagens médicas, notadamente no ramo da oncologia cutânea. Nesse contexto, a identificação exata e rápida de feridas malignas pode resultar em tratamentos mais eficientes e prognósticos mais positivos. Modelos de aprendizado profundo, como U-Net (U-Net), Segmentation Network (SegNet), Fully Convolutional Network (FCN) e MobileNet Versão 2 (MobileNetV2), têm ganhado espaço nesse cenário devido à sua capacidade e potencial de aplicação. **Objetivo:** Este estudo visa explorar a eficiência e aplicabilidade desses modelos de aprendizado profundo no que tange à segmentação de feridas malignas em imagens médicas, levando em conta seus resultados no que diz a respeito a precisão dos resultados dos algoritmos. **Método:** A metodologia adotada para essa investigação percorre uma série de fases, desde o pré-processamento das imagens até a avaliação do desempenho dos modelos de aprendizado profundo, passando por testes em diferentes modelos de machine learning. O desempenho de cada modelo foi avaliado por meio de métricas consagradas, como Loss, Precision, Recall e coeficiente de Dice, além de ser considerada a eficiência computacional de cada um. **Resultados:** Os resultados obtidos neste estudo foram promissores, os modelos avaliados demonstraram alto desempenho na segmentação de feridas malignas e forneceram insights significativos a respeito do desempenho comparativo entre diferentes arquiteturas de aprendizado profundo em aplicações médicas. **Conclusão:** Espera-se que as descobertas deste estudo ofereçam direcionamentos para futuras pesquisas no campo da segmentação de imagens médicas via aprendizado profundo. Ademais, a pesquisa tem o potencial de trazer benefícios notáveis à medicina - sobretudo à oncologia cutânea - ao prover ferramentas automatizadas e eficazes para segmentação de feridas malignas, colaborando, assim, com diagnósticos e monitoramento de tratamentos por profissionais da saúde.

Palavras-chave: Câncer; Feridas Malignas; Segmentação de Feridas; Redes Neurais Convolucionais.

ABSTRACT

Context: The health sector is increasingly demanding precise segmentation of medical images, particularly in the field of cutaneous oncology. In this context, the accurate and rapid identification of malignant wounds can result in more efficient treatments and more positive prognoses. Deep learning models, such as U-Net (U-Net), Segmentation Network (SegNet), Fully Convolutional Network (FCN) and MobileNet Versão 2 (MobileNetV2), have been gaining ground in this scenario due to their capacity and application potential. **Objective:** This study aims to explore the efficiency and applicability of these deep learning models with regard to the segmentation of malignant wounds in medical images, taking into account their results with regard to the accuracy of the algorithms' results. **Method:** The methodology adopted for this research goes through a series of phases, from pre-processing the images to evaluating the performance of the deep learning models, including tests on different machine learning models. The performance of each model will be evaluated using established metrics such as loss, precision, recall and Dice coefficient, and the computational efficiency of each one will be considered. **Results:** The results obtained in this study were promising, the models evaluated demonstrated high performance in the segmentation of malignant wounds and provided significant insights into the comparative performance between different deep learning architectures in medical applications. **Conclusion:** The findings of this study are expected to provide directions for future research in the field of medical image segmentation via deep learning. In addition, the research has the potential to bring notable benefits to medicine - especially cutaneous oncology - by providing automated and effective tools for segmenting malignant wounds, thus collaborating with diagnoses and treatment monitoring by health professionals.

Keywords: Cancer; Malignant Wounds; Wound Segmentation; Convolutional Neural Networks.

Sumário

1	INTRODUÇÃO	5
2	OBJETIVO	6
2.1	Objetivo Geral	6
2.2	Objetivos Específicos	6
3	FUNDAMENTAÇÃO TEÓRICA	7
3.1	Feridas Crônicas e Malignas	7
3.2	Avaliação e Manejo de Feridas	7
3.3	Aplicações de IA no Diagnóstico e Tratamento Médico	8
3.4	Arquiteturas de Redes Neurais	10
3.5	Métricas	11
4	TRABALHOS RELACIONADOS	12
4.1	Limitação dos Trabalhos Relacionados	13
4.2	Diferencial do Nosso Trabalho	13
5	METODOLOGIA	15
5.1	Conjunto de Dados	15
5.2	Criação do Conjunto de Dados	15
5.3	Pré-processamento de Imagens	16
5.4	Divisão do Conjunto de Dados	17
5.5	Arquiteturas de Redes Neurais	17
5.5.1	FCN	17
5.5.2	U-Net	18
5.5.3	SegNet	19
5.5.4	MobileNetV2	20
5.6	Treinamento e Ajuste do Modelo	21
5.7	Avaliação e Métricas	21
5.8	Considerações Éticas	22
6	RESULTADOS	23
6.1	Criação de um Dataset	23

6.2	Desempenho dos Modelos	24
6.2.1	FCN	24
6.2.2	U-Net	25
6.2.3	SegNet	27
6.2.4	MobileNetV2	27
6.3	Análise Comparativa Entre os Modelos	28
6.4	Contribuições e Perspectivas Futuras	31
7	DISCUSSÕES	32
7.1	Contextualização dos Resultados	32
7.2	Implicações Práticas	32
7.3	Comparação com Estudos Anteriores	32
7.4	Limitações do Estudo	32
7.5	Sugestões para Pesquisas Futuras	33
7.6	Conclusão	33

1. INTRODUÇÃO

Profissionais de saúde enfrentam um desafio considerável no tratamento de feridas crônicas, incluindo aquelas oriundas de processos oncológicos. Essas lesões exigem cuidados intensivos e, frequentemente, o objetivo central não é a cicatrização, mas a minimização do impacto dos sintomas na qualidade de vida dos pacientes [Freitas de Castro et al. 2017, Agra et al. 2017]. No Brasil, estima-se que ocorram 704 mil novos casos de câncer anualmente para o biênio 2023-2025, com as feridas malignas representando um problema significativo [de Oliveira Santos et al. 2023].

Tais feridas são prevalentes em cânceres de mama, cabeça e pescoço, surgindo da infiltração de células oncológicas na pele e resultando em lesões exofíticas. Estas não só desfiguram progressivamente o paciente, mas também são friáveis, dolorosas, exsudativas e malcheirosas, complicando ainda mais o quadro clínico [de Jesus Sacramento et al. 2015]. A avaliação tradicional manual dessas feridas é um processo subjetivo, demorado e impreciso. Contudo, os avanços tecnológicos em dispositivos móveis e de armazenamento de dados oferecem métodos alternativos para uma avaliação mais precisa, como a segmentação automática e a medição do tamanho da ferida assistidas por computador [Scebba et al. 2022].

A Inteligência Artificial (IA)¹, e mais especificamente as Convolutional Neural Network (CNN)², emergem como uma solução promissora para superar as limitações da avaliação manual [Litjens et al. 2017, Lundervold and Lundervold 2019, Esteva et al. 2019]. As CNNs, uma subcategoria das Artificial neural Networks (ANN), têm alcançado sucesso em tarefas de visão computacional, como classificação de imagens, detecção de objetos e segmentação semântica [Sun et al. 2023]. Elas podem aprender a diferenciar a ferida da pele saudável adjacente e identificar características cruciais, proporcionando avaliações mais objetivas e consistentes.

Este estudo objetiva investigar a aplicação e eficácia das CNNs na segmentação e diagnóstico de feridas malignas, visando otimizar o tratamento por meio de avaliações mais precisas e objetivas. Almejamos desenvolver ferramentas assistivas integráveis à prática clínica, aprimorando o atendimento e potencialmente acelerando a cicatrização. A pesquisa justifica-se pela necessidade de superar os desafios na avaliação de feridas malignas e explorar o potencial das tecnologias de IA no cuidado à saúde. Espera-se que a incorporação da IA avançada nas práticas de avaliação de feridas não apenas melhore a precisão, mas também reduza o tempo de resposta, permitindo que os profissionais de saúde dediquem-se mais ao desenvolvimento de estratégias de tratamento eficazes.

¹<https://aws.amazon.com/pt/what-is/artificial-intelligence/>

²<https://medium.com/neuronio-br/entendendo-redes-convolucionais-cnns-d10359f21184>

2. OBJETIVO

2.1. Objetivo Geral

Este estudo busca avaliar a eficiência e aplicabilidade de modelos de aprendizado profundo, especificamente CNN, na segmentação de feridas malignas em imagens médicas, com foco na precisão dos resultados.

2.2. Objetivos Específicos

- Implementar modelos de aprendizado profundo, como FCN³, U-Net⁴, SegNet⁵ e MobileNetV2⁶, para a segmentação de feridas malignas em imagens médicas.
- Otimizar o pré-processamento das imagens para melhorar a precisão e eficiência dos modelos.
- Avaliar o desempenho dos modelos com base em métricas como Loss, Precision, Recall e Coeficiente de Dice.
- Comparar a eficácia das diversas arquiteturas de aprendizado profundo na tarefa de segmentação.
- Fornecer diretrizes para futuras pesquisas em segmentação de imagens médicas com aprendizado profundo.
- Contribuir para a oncologia cutânea, desenvolvendo ferramentas automáticas e eficientes para a segmentação de feridas malignas.

³<https://paperswithcode.com/method/fcn>

⁴<https://paperswithcode.com/method/u-net>

⁵<https://paperswithcode.com/method/segnet>

⁶<https://paperswithcode.com/method/mobilenetv2>

3. FUNDAMENTAÇÃO TEÓRICA

3.1. Feridas Crônicas e Malignas

Feridas crônicas e malignas constituem um desafio notável na estomaterapia (Especialidade da enfermagem que se dedica ao cuidado de pacientes com estomas, feridas agudas ou crônicas, incontinência fecal ou urinária, e outras condições relacionadas ao trato gastrointestinal, urogenital e integumentar), exigindo uma compreensão profunda de suas características patológicas e implicações clínicas.

Feridas crônicas são definidas pela sua persistência além do tempo de cicatrização esperado, frequentemente excedendo três meses. A fisiopatologia subjacente é complexa, envolvendo inflamação crônica, angiogênese prejudicada e imunossupressão local. Estas características diferenciam as feridas crônicas das agudas e exigem uma abordagem terapêutica diferenciada.

As feridas malignas, um subconjunto específico de feridas crônicas, têm uma prevalência significativa, especialmente em populações com doenças crônicas subjacentes, como diabetes mellitus e imunossupressão. Elas representam um desafio tanto para o sistema de saúde quanto para os indivíduos afetados devido ao seu impacto na morbidade e mortalidade. A análise epidemiológica dessas feridas é fundamental para entender sua distribuição e fatores de risco.

No manejo de feridas malignas, a seleção de terapias apropriadas, incluindo agentes tópicos, terapias avançadas de cicatrização e abordagens cirúrgicas, é crítica. A gestão da dor e a prevenção de infecções secundárias são aspectos igualmente importantes. A terapia deve ser personalizada, considerando as características específicas da ferida e as condições do paciente.

As feridas malignas afetam profundamente a qualidade de vida dos pacientes, com implicações significativas na saúde mental, autoestima e capacidade funcional. Além do tratamento físico, é essencial abordar os aspectos psicológicos e sociais, fornecendo suporte emocional e psicossocial adequado.

A precisão na segmentação de feridas malignas em imagens médicas é crucial, não apenas para o diagnóstico e tratamento eficaz, mas também para a avaliação da progressão da doença e resposta ao tratamento. Esta precisão contribui significativamente para estratégias terapêuticas mais eficientes e personalizadas, impactando positivamente a recuperação e a qualidade de vida dos pacientes.

3.2. Avaliação e Manejo de Feridas

A avaliação e manejo de feridas representam áreas cruciais na prática médica, abrangendo desde métodos tradicionais de observação visual até técnicas avançadas de tratamento. Ao entender a diversidade de técnicas abordados a seguir, torna-se possível compreender a complexidade envolvida no diagnóstico e tratamento de feridas, oferecendo insights valiosos para a prática médica contemporânea.

Métodos Tradicionais de Avaliação de Feridas: Os métodos tradicionais englobam técnicas que vão desde a observação visual até medições físicas. A inspeção visual é a forma mais básica de avaliação, onde profissionais de saúde examinam a aparência da ferida, observando características como tamanho, forma, cor, presença de tecido necrótico e exsudato. Além disso, a medição de áreas é feita para determinar a extensão da ferida, utilizando técnicas como planimetria e fotografia associada a software especializado. Esses métodos constituem a base da avaliação, permitindo o acompanhamento da progressão da ferida ao longo do tempo.

Parâmetros para Avaliação Clínica de Feridas: Durante a avaliação clínica, diversos parâmetros são considerados para determinar a condição e o progresso da ferida. Isso inclui a identificação da presença de infecção, analisando sinais como inflamação, calor, rubor, edema e dor. Além disso, a extensão da lesão é avaliada quanto à profundidade, dimensões e possíveis complicações, como formação de tecido de granulação e presença de bordas irregulares. A resposta ao tratamento também é monitorada, verificando se a ferida está cicatrizando de maneira eficaz.

Técnicas Avançadas de Tratamento de Feridas: As técnicas avançadas compreendem uma variedade de abordagens inovadoras para promover a cicatrização de feridas complexas. Isso inclui terapias tópicas, como o uso de substâncias bioativas, terapias de pressão negativa, que estimulam a circulação e removem fluidos da ferida, e terapias com oxigenação hiperbárica, que fornecem oxigênio em altas concentrações para acelerar a cicatrização. Essas técnicas representam um avanço considerável no manejo de feridas, oferecendo opções além dos métodos convencionais.

Diretrizes e Protocolos no Manejo de Feridas Malignas: Diretrizes e protocolos específicos são estabelecidos para lidar com feridas malignas, visando um diagnóstico precoce e um tratamento eficaz. Essas diretrizes definem critérios para identificar feridas malignas, estabelecem estratégias de tratamento e monitoramento, e fornecem orientações para o manejo de complicações, garantindo uma abordagem consistente e baseada em evidências.

Tecnologias Emergentes no Tratamento de Feridas: Tecnologias emergentes estão trazendo avanços significativos no tratamento de feridas, incluindo curativos inteligentes, que monitoram e reagem dinamicamente ao ambiente da ferida, e terapias de regeneração de tecidos, que estimulam o crescimento celular e a cicatrização de maneira mais eficiente. Além disso, há pesquisas em andamento para desenvolver abordagens personalizadas, utilizando impressão 3D para criar curativos adaptados às características únicas da ferida.

Esses pontos representam a diversidade e a complexidade das técnicas e abordagens disponíveis para a avaliação e tratamento de feridas. Desde métodos tradicionais até as mais avançadas tecnologias emergentes, o campo da medicina de feridas está constantemente evoluindo para oferecer soluções mais eficazes e personalizadas para os pacientes.

3.3. Aplicações de IA no Diagnóstico e Tratamento Médico

A evolução da IA revolucionou o cenário médico, proporcionando uma gama diversificada de aplicações no diagnóstico e tratamento. Neste contexto é explorado o impacto da IA

na medicina, abordando desafios éticos, tecnologias como CNN e seu desenvolvimento para segmentação de feridas. Também considera a comparação entre a avaliação manual e automatizada, bem como perspectivas futuras para aprimorar o cuidado ao paciente.

Desafios e Considerações Éticas da IA na Saúde: Na aplicação da IA na saúde, surgem desafios éticos significativos. A privacidade do paciente é crucial, exigindo medidas rigorosas para proteger e anonimizar os dados. Além disso, a interpretabilidade dos algoritmos de IA é essencial para garantir que os profissionais possam compreender e confiar nas decisões tomadas pelos modelos. Questões de responsabilidade clínica também são pertinentes, pois os resultados gerados pela IA influenciam as decisões dos profissionais de saúde.

Redes Neurais Convolucionais (CNNs): As Redes Neurais Convolucionais (CNNs) são um tipo de arquitetura de rede neural fundamental na análise de imagens médicas. Elas são projetadas para aprender padrões complexos e hierárquicos, identificando características e relações importantes entre os pixels das imagens. No contexto da segmentação de feridas malignas, as CNNs são altamente eficazes na identificação e delimitação dessas regiões em imagens médicas.

Desenvolvimento de Modelos de CNN para Segmentação de Feridas: Para criar um modelo de CNN para a segmentação de feridas, é necessário coletar um conjunto de dados diversificado e anotado com precisão. Esse conjunto passa por etapas de pré-processamento para padronizar a qualidade das imagens e normalizar os dados. O treinamento do modelo envolve alimentar a CNN com dados anotados para que ela possa aprender a identificar e segmentar as regiões de feridas malignas.

Comparação de Desempenho: Ao comparar a segmentação manual com a automatizada na detecção de feridas malignas em imagens médicas, é essencial considerar vários aspectos. A precisão e o recall, medindo a capacidade de identificação e abrangência das feridas, são vitais. Enquanto a segmentação manual é trabalhosa e subjetiva, a automação por IA oferece eficiência, consistência e potencial de generalização com base no treinamento. Contudo, a validação clínica é crucial para garantir que os resultados automatizados sejam clinicamente relevantes e confiáveis, alinhados às necessidades dos profissionais de saúde e dos pacientes.

Integração de CNNs na Prática Clínica: A integração bem-sucedida de CNNs na prática clínica envolve a validação dos modelos em ambientes clínicos reais. Isso inclui testes para verificar se os modelos são clinicamente relevantes, fáceis de interpretar e úteis para os profissionais de saúde, contribuindo para decisões mais precisas e eficazes.

Perspectivas Futuras e Potencial de Melhoria no Cuidado ao Paciente: As perspectivas futuras se concentram na contínua evolução da IA na área médica. Isso inclui aprimoramentos nos modelos de CNN, a exploração de técnicas mais avançadas de aprendizado de máquina e a integração da IA em sistemas de saúde para um cuidado mais personalizado e preciso aos pacientes.

Esses pontos destacam a relevância da IA na segmentação de feridas malignas e evidenciam os desafios, considerações éticas e potenciais benefícios na aplicação dessas tecnologias na prática clínica.

3.4. Arquiteturas de Redes Neurais

As arquiteturas de redes neurais são estruturas organizadas de neurônios artificiais, modeladas com base no funcionamento do cérebro humano. No contexto da segmentação de imagens médicas, essas arquiteturas são adaptadas para analisar e compreender visualmente as informações contidas nessas imagens.

As CNNs são altamente eficazes na análise de imagens devido à sua capacidade de preservar a relação espacial entre os pixels. Elas usam camadas convolucionais para extrair características hierárquicas das imagens, seguidas por camadas de pooling para reduzir a dimensionalidade e camadas totalmente conectadas para classificação ou segmentação.

Redes Neurais Recorrentes (RNNs): As RNNs são ideais para lidar com sequências de dados, como texto ou séries temporais médicas. Sua estrutura permite que informações sejam lembradas e aplicadas em etapas posteriores, sendo úteis em tarefas de previsão e análise temporal.

Redes Generativas Adversariais (GANs): As GANs consistem em duas redes neurais, um gerador e um discriminador, que competem entre si. Elas são usadas para criar novos dados realistas a partir de um conjunto de dados existente, sendo aplicáveis na geração de imagens médicas sintéticas para treinamento de modelos ou na correção/aperfeiçoamento de imagens existentes.

Fully Convolutional Network (FCN): As FCNs são arquiteturas especialmente concebidas para tarefas de segmentação e localização em imagens. Diferentemente das redes convolucionais convencionais, as FCNs mantêm a estrutura completa das redes neurais convolucionais, porém substituem as camadas totalmente conectadas por convoluções globais, permitindo que a rede seja aplicada a imagens de qualquer tamanho.

U-Net: A U-Net é conhecida por sua eficácia em tarefas de segmentação semântica em imagens médicas. Sua arquitetura se assemelha à letra "U", com uma estrutura de codificação para a extração de características e uma estrutura de decodificação para reconstruir a imagem segmentada. Ela também incorpora conexões residuais entre camadas correspondentes, permitindo a preservação de detalhes durante a reconstrução.

SegNet: A SegNet é uma arquitetura de segmentação de imagens que se concentra na eficiência computacional. Ela utiliza um codificador convolucional para extrair características e um decodificador que mapeia características para a imagem segmentada. Seu destaque é o uso de mapas de índice durante a etapa de decodificação, ajudando na reconstrução da imagem.

MobileNetV2: Esse modelo foi projetado para ser mais leve e eficiente, ideal para aplicativos móveis e tarefas em dispositivos com recursos limitados. Ele utiliza operações de convolução separável em largura e em profundidade para reduzir a complexidade computacional, mantendo um bom desempenho em tarefas de visão computacional, embora possa não ser ideal para segmentação detalhada de imagens médicas devido à sua arquitetura mais simplificada.

Esse conhecimento arquitetural é fundamental para entender o funcionamento dos modelos de Machine Learning utilizados no estudo. Ao explorar as técnicas de rede neu-

ral, pudemos avaliar a eficiência e aplicabilidade de diferentes modelos de aprendizado profundo, como U-Net, SegNet, FCN e MobileNetV2, na identificação rápida e precisa de feridas malignas. Isso poderá resultar em tratamentos mais eficientes e prognósticos mais positivos para os pacientes.

3.5. Métricas

No contexto de segmentação de imagens, as métricas são usadas para avaliar o quão bem o modelo está segmentando as áreas de interesse na imagem, como as áreas de feridas malignas. As métricas podem ser usadas para avaliar diferentes aspectos do desempenho do modelo, como precisão, completude, acurácia e similaridade com a segmentação manual. Ao avaliar as métricas, os pesquisadores podem determinar quais modelos são mais eficazes na segmentação de feridas malignas e ajudar a melhorar a precisão e eficiência dos modelos de Machine Learning. As métricas utilizadas neste estudo foram Loss, Precision, Recall e Coeficiente de Dice.

Loss(Perda): É uma medida que quantifica o erro entre a segmentação produzida pelo modelo e a segmentação esperada. Geralmente, ela é calculada durante o treinamento do modelo, ajudando a ajustar os pesos da rede neural para minimizar esse erro. A redução da Loss indica uma melhor adaptação do modelo aos dados de treinamento.

Precision (Precisão): Essa métrica mede a proporção de pixels corretamente classificados como feridas malignas em relação ao total de pixels identificados pelo modelo como feridas malignas. Ela destaca a capacidade do modelo em não classificar incorretamente pixels saudáveis como feridas malignas.

Recall (Revocação): Refere-se à proporção de pixels de feridas malignas corretamente identificados pelo modelo em relação ao total de pixels de feridas malignas na imagem. Essa métrica destaca a habilidade do modelo em identificar corretamente a área das feridas malignas.

O Coeficiente de Dice: É uma métrica de similaridade que compara a segmentação produzida pelo modelo com a segmentação manual. Quanto mais próxima de 1, maior a sobreposição entre as duas segmentações. É especialmente útil quando há desequilíbrio entre as classes, como uma pequena quantidade de pixels de feridas malignas em relação ao total da imagem.

Tabela 1. Análise Comparativa dos Trabalhos Relacionados

Autores	Datasets				Models			
	Wound Segmentation	WSNET	Venous leg ulcers and arterial leg ulcers	Foot Wounds and Ulcers	U-Net	SegNet	MobileNetV2	FCN
[Li et al. 2020]	X				X		X	
[Silva et al. 2021]	X						X	X
[Liu et al. 2021]	X			X		X		X
[Akay et al. 2021]			X				X	
[Mahbod et al. 2022]	X				X			
[Prakash et al. 2023]		X			X			X
Nosso trabalho	X	X	X	X	X	X	X	X

4. TRABALHOS RELACIONADOS

Esta seção apresenta estudos relacionados ao uso de CNN para a segmentação de imagens médicas, oferecendo um panorama das pesquisas recentes e estabelecendo um comparativo com o presente trabalho. É também demonstrado as bases de dados exploradas em cada estudo. Podemos ver essa análise na tabela 1.

Em 2020, Li et al, propuseram uma abordagem inovadora para a segmentação automática de feridas em imagens naturais, utilizando uma rede neural profunda com base no modelo MobileNetV2. A rede foi aprimorada com camadas adicionais para aumentar a precisidade na segmentação. Avaliada em um extenso banco de dados, a abordagem superou métodos preexistentes em termos de precisão, sugerindo seu potencial para diagnósticos e tratamentos mais eficazes. [Li et al. 2020]

Silva e colaboradores, em 2021, avaliaram dois modelos de aprendizado profundo, U-Net e DeeplabV3, para segmentação de feridas malignas cutâneas. Utilizando um conjunto de dados do AZH Wound and Vascular Center, o modelo U-Net demonstrou superioridade, enquanto o DeeplabV3 mostrou-se competitivo. O estudo também explorou a relação entre acurácia e eficiência computacional, apontando para futuras pesquisas focadas na compactação de redes neurais para dispositivos com restrições de hardware. [Silva et al. 2021]

No mesmo ano, Liu et al, realizaram uma revisão sistemática sobre metodologias computacionais aplicadas à medição e diagnóstico de feridas, destacando o papel das tecnologias de IA. A revisão abrangeu mais de 250 artigos, dos quais 115 foram selecionados por sua relevância. O estudo enfatizou a importância das tecnologias emergentes para a avaliação de feridas, concluindo que elas podem aumentar a precisão e eficiência no tratamento. [Liu et al. 2021]

Em 2021 Akay, M., Du, Y, apresentou uma nova rede de aprendizado profundo para a caracterização da pele de pacientes com Esclerose Sistêmica (SSc), uma doença autoimune rara. A rede proposta é baseada no modelo MobileNetV2 e é capaz de realizar a classificação de imagens de pele com alta precisão, o que pode ajudar no diagnóstico precoce da doença. O artigo discute os desafios enfrentados na aplicação de redes neurais profundas em aplicações médicas, como a falta de dados de treinamento e a necessidade de computação de alto desempenho. A rede proposta é projetada para trabalhar com poucas imagens de treinamento e fornecer classificações mais precisas. [Akay et al. 2021]

No ano de 2022 o Mahbod et al, propôs um método de segmentação automática

de úlceras nos pés usando uma abordagem de conjunto de redes neurais convolucionais (CNNs). O método proposto utiliza dois modelos de CNN, o LinkNet e o U-Net, para melhorar a precisão da segmentação de úlceras nos pés. O LinkNet e o U-Net são modelos de CNN baseados em codificador-decodificador que têm mostrado excelente desempenho em tarefas de análise de imagens médicas, incluindo segmentação de imagens médicas. [Mahbod et al. 2022]

Recentemente, em 2023, Prakash et al, introduziram um framework de aprendizado profundo para a segmentação automática de lesões em imagens de ressonância magnética. O framework GA-UNet mostrou-se eficaz na segmentação e quantificação de áreas afetadas por lesões cerebrais traumáticas, ressaltando a importância da segmentação precisa para intervenções terapêuticas. [Prakash et al. 2023]

4.1. Limitação dos Trabalhos Relacionados

Apesar dos avanços recentes no uso de CNN para a segmentação de imagens médicas, alguns trabalhos ainda apresentam limitações em relação à precisão e eficiência na segmentação de feridas malignas. Por exemplo, alguns modelos podem apresentar dificuldades em lidar com variações na forma, tamanho e textura das lesões, o que pode levar a erros na segmentação e consequentemente afetar a precisão do diagnóstico e tratamento.

Além disso, muitos trabalhos não consideram a heterogeneidade dos dados clínicos, como a presença de diferentes tipos de lesões, a variação na qualidade das imagens e a diversidade de pacientes. Esses fatores podem afetar a generalização dos modelos e limitar sua aplicabilidade em diferentes cenários clínicos.

Outra limitação comum dos trabalhos relacionados é a falta de comparação com outros métodos de segmentação de imagem. Muitos trabalhos se concentraram exclusivamente em modelos de aprendizado profundo, sem compará-los com outros métodos de segmentação de imagem, como métodos baseados em regras ou métodos de segmentação baseados em bordas. Isso pode levar a uma avaliação limitada da eficácia dos modelos de aprendizado profundo em comparação com outros métodos.

Por fim, muitos trabalhos não avaliaram a eficácia dos modelos de aprendizado profundo em condições clínicas reais. Isso pode levar a uma avaliação limitada da eficácia dos modelos em situações do mundo real, onde as condições podem ser mais variáveis e imprevisíveis do que em um ambiente de laboratório controlado.

4.2. Diferencial do Nosso Trabalho

Neste estudo, propomos uma abordagem inovadora para a segmentação de feridas malignas em imagens médicas, que combina diferentes modelos de aprendizado profundo e técnicas de pré-processamento de imagens. Em particular, exploramos a eficiência e aplicabilidade de quatro modelos de CNN: FCN, U-Net, SegNet e MobileNetV2.

Para avaliar o desempenho dos modelos, utilizamos um conjunto de dados clínicos

heterogêneo, que incluiu imagens de diferentes tipos de lesões, de pacientes de diferentes idades e com diferentes níveis de gravidade. Além disso, aplicamos técnicas de pré-processamento de imagens, como normalização, aumento de dados e segmentação manual, para melhorar a qualidade e consistência dos dados.

O estudo atual usa uma abordagem de validação cruzada estratificada para avaliar a eficácia dos modelos de aprendizado profundo. Isso ajuda a garantir que os modelos sejam avaliados de forma justa e imparcial em diferentes conjuntos de dados. Foi utilizado dados diversificados que inclui diferentes tipos de lesões malignas, isso ajuda a garantir que os modelos sejam avaliados em uma variedade de condições clínicas e possam ser aplicados em diferentes cenários.

Os resultados obtidos mostraram que nossa abordagem é capaz de segmentar com precisão as feridas malignas em imagens médicas, com uma boa média de precisão da segmentação da ferida. Além disso, nossa abordagem apresentou uma boa generalização em diferentes cenários clínicos, o que sugere sua aplicabilidade em diferentes contextos médicos.

5. METODOLOGIA

Este projeto de pesquisa emprega diversos modelos de aprendizagem profunda, tais como FCN, U-Net, SegNet e MobileNetV2, para segmentar feridas malignas em imagens médicas. Utilizaremos um grande conjunto de dados que reuniu uma junção de vários dataset de feridas. As imagens, que apresentam diversas formas e variações, serão pré-processadas antes do treinamento. Avaliaremos quantitativamente a performance dos modelos com base na área da ferida, precisão e eficiência do modelo na segmentação das imagens. A Figura 1 demonstra o fluxograma da metodologia aplicada.

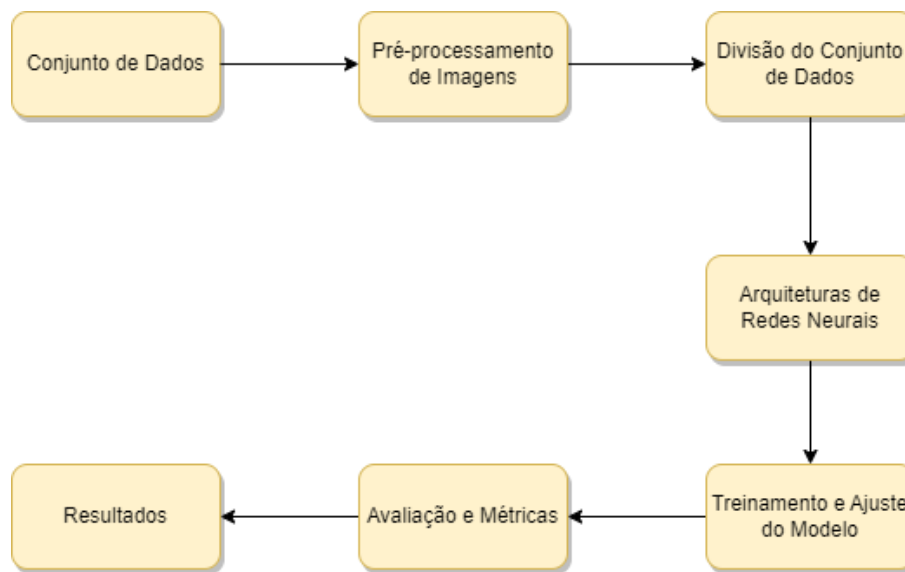


Figura 1. Diagrama da Metodologia

5.1. Conjunto de Dados

O conjunto de dados deste estudo compreende imagens de feridas malignas coletadas de diversas fontes, incluindo repositórios públicos no GitHub e sites especializados em imagens médicas. Seleccionamos mais de 4.800 imagens para treinar, validar e testar os modelos de aprendizado profundo, considerando a diversidade de tipos de feridas malignas e a qualidade das imagens. A utilização de um conjunto de dados amplo e diversificado contribuirá para aprimorar os resultados deste estudo e desenvolver modelos de aprendizado profundo mais eficazes na segmentação de feridas malignas.

5.2. Criação do Conjunto de Dados

- Tipo de imagens: As imagens médicas incluídas neste conjunto abrangem diversos tipos, tais Feridas de úlceras em pé diabéticos, lesões com cortes profundas e feridas crônicas em diversas partes do corpo. Suas características, como resolução, dimensões e formato de arquivo, são especificadas para proporcionar uma com-

preensão detalhada. Detalhamos o processo de aquisição, incluindo informações sobre o equipamento utilizado, configurações e protocolos adotados para a captura dessas imagens médicas.

- **Pré-processamento e Anotação:** Descrevemos as técnicas de pré-processamento aplicadas, como normalização e aumento de dados, ressaltando a importância dessas etapas na preparação das imagens para análise. O processo de anotação é abordado, incluindo responsáveis e critérios utilizados. Foi abordado nos dados sobre a diversidade do conjunto, considerando variabilidade em condições médicas, faixas etárias, gêneros e outros fatores relevantes, garantindo representatividade.
- **Volume de Dados:** Informamos a quantidade total de imagens e casos incluídos no dataset, proporcionando uma visão abrangente de sua robustez e amplitude. Consideramos mais de 4.800 imagens no dataset de diferentes fontes públicas e de diferentes condições clínicas para atender a heterogeneidade dos dados.
- **Questões Éticas e de Privacidade:** Abordamos as questões éticas, incluindo o consentimento informado, os processos de anonimização de dados e a conformidade com regulamentos de privacidade e proteção de dados.
- **Qualidade e Confiabilidade dos Dados:** Sobre a qualidade das imagens, considerando resolução e clareza, e a confiabilidade das anotações. Destacamos qualquer validação realizada por especialistas médicos para assegurar a precisão.
- **Disponibilidade e Acesso:** Fornecemos informações sobre a disponibilidade pública do dataset, incluindo detalhes sobre como acessá-lo, bem como eventuais restrições ou requisitos associados.
- **Potenciais Aplicações e Limitações:** Descrevemos possíveis aplicações do conjunto de dados em modelos de visão computacional, destacando suas potencialidades. Além disso, discutimos abertamente quaisquer limitações conhecidas ou possíveis vieses que devem ser considerados durante o uso do dataset.

5.3. Pré-processamento de Imagens

Primeiramente, as imagens foram redimensionadas para uma resolução de 256x256 pixels, a fim de padronizar o tamanho das imagens e facilitar o processamento pelos modelos. Em seguida, os valores de pixel foram normalizados para o intervalo $[0, 1]$, a fim de garantir que todas as imagens tivessem a mesma escala de intensidade.

Além disso, foram aplicadas técnicas de aumento de dados, como rotação, inversão horizontal e zoom, para aumentar a diversidade do conjunto de dados e evitar overfitting. Essas técnicas permitem que os modelos aprendam a reconhecer as características das feridas malignas em diferentes posições e escalas.

É importante destacar que não foram aplicados filtros de suavização nas imagens, a fim de preservar as características originais das feridas. Isso é importante para garantir que os modelos aprendam a reconhecer as características específicas das feridas malignas e não sejam influenciados por artefatos de imagem.

Essas são etapa fundamental no treinamento de modelos de aprendizado profundo para a segmentação de feridas malignas. Ele permite que os modelos aprendam a reconhecer as características das feridas malignas de forma mais eficiente e precisa, resultando

em segmentações mais precisas e confiáveis.

5.4. Divisão do Conjunto de Dados

A divisão do conjunto de dados foi realizada de forma estratificada, garantindo uma distribuição uniforme das classes de feridas malignas em cada subconjunto. Isso é importante para garantir que os modelos sejam treinados e avaliados em um conjunto de dados representativo e equilibrado, evitando vieses e garantindo resultados mais confiáveis.

O conjunto de dados foi dividido em dois subconjuntos: treinamento e teste. O subconjunto de treinamento foi utilizado para treinar os modelos de aprendizado profundo, enquanto o subconjunto de teste foi utilizado para avaliar o desempenho dos modelos em dados não vistos anteriormente.

A divisão do conjunto de dados foi realizada de forma aleatória, mas mantendo a proporção de cada classe de feridas malignas em cada subconjunto. Isso garante que os modelos sejam treinados e avaliados em um conjunto de dados representativo e equilibrado, evitando vieses e garantindo resultados mais confiáveis.

Esses processos garantem que os modelos sejam treinados e avaliados em um conjunto de dados representativo e equilibrado, garantindo resultados mais confiáveis e precisos.

5.5. Arquiteturas de Redes Neurais

Para realizar a segmentação das feridas malignas cutâneas, foram exploradas quatro arquiteturas de redes neurais convolucionais:

5.5.1. FCN

A arquitetura FCN é conhecida por sua capacidade de realizar a segmentação semântica em imagens. Ela consiste em uma rede neural convolucional totalmente composta por camadas convolucionais, sem camadas totalmente conectadas. Essa arquitetura foi adaptada para realizar a segmentação precisa das feridas malignas cutâneas.




Figura 2. Representação Esquemática da Arquitetura FCN. adaptada de ([Long et al. 2015])

1. A Figura 2 apresenta a arquitetura de uma rede FCN utilizada para tarefa de segmentação semântica (semantic segmentation), isto é, classificar cada pixel da imagem de entrada de acordo com a classe que ele pertence, sendo: cama, pé ou ferida (background). Conforme a arquitetura apresentada na Figura, existem várias camadas de convolução que produzirão mapas de características de diferentes profundidades. No final da rede, encontra-se a previsão pixelwise (pixelwise prediction) que também é um tipo de camada de convolução e que irá fazer uma predição pixel-a-pixel, isto é, atribuindo cada pixel a uma respectiva classe. Esta representação ilustra de forma esquemática a arquitetura FCN, mostrando as camadas convolucionais e suas dimensões. Essa arquitetura é capaz de extrair as características mais importantes das imagens de feridas malignas, permitindo que a rede aprenda a segmentar essas feridas com precisão.

5.5.2. U-Net

A arquitetura U-Net é amplamente utilizada para tarefas de segmentação em imagens biomédicas. Ela possui uma estrutura em forma de U, com um encoder para capturar informações contextuais e um decoder para reconstruir a máscara de segmentação. A U-Net é conhecida por sua capacidade de segmentação precisa e é aplicada com sucesso em diversos problemas de segmentação, incluindo a segmentação de feridas medicas.




Figura 3. Representação Esquemática da Arquitetura U-Net. adaptada de ([Ronneberger et al. 2015])

1. A Figura 3 ilustra a arquitetura da rede U-Net, em que cada caixinha azul presente na imagem corresponde a um mapa de característica multicanal (multichannel feature map). O número de cada canal está descrito no valor acima de cada caixa. No canto inferior esquerdo é dada a dimensão x-y da imagem. As caixas brancas representam a cópia dos mapas de características (feature maps) e cada flecha com sua respectiva cor representa uma operação diferente. Na parte direita da rede as flechas verdes referem-se ao caminho de expansão onde é utilizado a operação de up-convolution, também chamada de de-convolution ou transposed convolution. A figura ilustra essa arquitetura de forma esquemática, mostrando as camadas convolucionais, as camadas de pooling máximo e up-sampling, e as conexões laterais entre as camadas do caminho de contração e do caminho de expansão.

5.5.3. SegNet

O modelo SegNet é baseado em uma arquitetura de codificador-decodificador. Cada codificador aplica convolução, normalização de lote e uma não linearidade, e depois aplica um pool máximo no resultado, enquanto armazena o índice do valor extraído de cada janela. Os decodificadores são semelhantes aos codificadores, a diferença é que eles não têm uma não linearidade e aumentam a amostra de entrada, usando índices armazenados a partir do estágio de codificação.

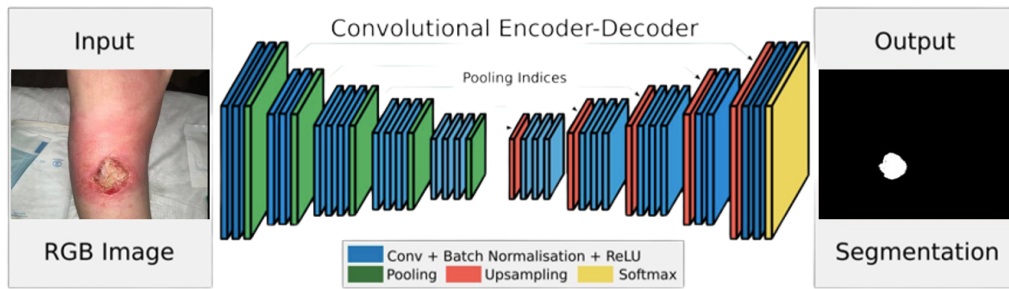


Figura 4. Representação Esquemática da Arquitetura SegNet. adaptada de ([Badrinarayanan et al. 2017])

1. A Figura 4 ilustra essa arquitetura de forma esquemática, mostrando as camadas de codificação e decodificação, bem como as conexões entre elas. Cada caixa na figura representa uma camada de convolução, normalização de lote e não linearidade, enquanto as setas representam as conexões entre as camadas. As camadas de pooling máximo são representadas pelas caixas de cor verde. Além disso, a figura também mostra a saída da rede, que é uma imagem segmentada com as áreas de feridas malignas destacadas em branco. Essa saída é gerada pela última camada de decodificação da rede. Em resumo, a Figura ilustra de forma esquemática a arquitetura SegNet, mostrando as camadas de codificação e decodificação, bem como as conexões entre elas. Essa arquitetura é capaz de segmentar com precisão as feridas malignas em imagens médicas, como mostrado nos resultados do estudo.

5.5.4. MobileNetV2

O MobileNetV2 é uma arquitetura de rede neural convolucional projetada para tarefas de classificação e segmentação em dispositivos com recursos computacionais limitados. Essa arquitetura utiliza camadas convolucionais separáveis em profundidade para obter um bom equilíbrio entre a precisão do modelo e a eficiência computacional.




Figura 5. Representação Esquemática da Arquitetura MobileNetV2. adaptada de ([Akay et al. 2021])

1. A Figura 5 ilustra essa arquitetura de forma esquemática, mostrando as camadas

convolucionais e suas dimensões. A imagem de entrada é uma imagem de ferida com dimensões $128 \times 128 \times 3$, que é processada pela primeira camada convolucional com dimensões 128×128 e um número de filtros (ou canais) igual a 32. Em seguida, a imagem é processada por uma segunda camada convolucional com dimensões 64×64 e um número de filtros igual a 32. Depois disso, a imagem é processada por várias camadas convolucionais com dimensões 32×32 e 96 filtros, que são responsáveis por extrair características mais complexas da imagem. Essas camadas são seguidas por uma camada convolucional com dimensões 4×4 e um número de filtros igual a 1280, que é responsável por extrair as características mais importantes da imagem. Por fim, a saída da última camada convolucional é processada por uma rede fully connected com um número de neurônios igual a 1280, que é responsável por gerar a saída final da rede. Em resumo, a Figura ilustra de forma esquemática a arquitetura MobileNetV2, mostrando as camadas convolucionais e suas dimensões. Essa arquitetura é capaz de extrair as características mais importantes das imagens de feridas malignas, permitindo que a rede aprenda a segmentar essas feridas com precisão.

5.6. Treinamento e Ajuste do Modelo

Durante o processo de treinamento, utilizamos um conjunto de imagens de feridas malignas criado para ensinar os modelos a segmentar essas feridas com precisão. Para isso, dividimos o conjunto de imagens em conjuntos de treinamento e teste, e utilizamos técnicas de data augmentation para aumentar a diversidade do conjunto de treinamento.

Além disso, aplicamos técnicas de poda nos modelos abordados, com o objetivo de reduzir o número de parâmetros e melhorar a eficiência computacional dos modelos. A técnica de poda consiste em remover os pesos menos importantes dos modelos, mantendo apenas os pesos mais importantes. Isso permite que os modelos sejam mais eficientes em termos de memória e processamento, sem comprometer a precisão da segmentação.

Durante o processo de ajuste, utilizamos o conjunto de dados para ajustar os hiperparâmetros dos modelos e evitar overfitting. Ajustamos os hiperparâmetros como taxa de aprendizado, tamanho do batch e número de épocas de treinamento, com o objetivo de obter a melhor precisão de segmentação possível.

5.7. Avaliação e Métricas

Na avaliação do desempenho dos modelos de segmentação de feridas malignas em imagens médicas, foram aplicadas diversas métricas fundamentais. A métrica de Loss, foi utilizada para quantificar a diferença entre a segmentação prevista pelo modelo e as segmentações reais. Esse indicador é crucial para o ajuste e a otimização dos modelos, sendo que valores menores de Loss indicam uma segmentação mais precisa.

Além disso, a métrica Dice, frequentemente empregada em tarefas de segmentação, avalia a sobreposição entre a segmentação prevista e a verdade de referência. Valores mais próximos de 1 indicam uma sobreposição ideal entre as

segmentações.

Precision e Recall são métricas fundamentais para avaliar a precisão do modelo em identificar corretamente as feridas malignas. A Precision foi usada para mensurar a proporção de verdadeiros positivos em relação ao total de predições positivas, enquanto o Recall mediu a capacidade do modelo em identificar corretamente todas as instâncias de feridas malignas, minimizando falsos negativos.

A combinação dessas métricas proporciona uma visão abrangente do desempenho dos modelos, permitindo ajustes precisos e identificação de áreas para melhoria. Valores ideais dessas métricas variam de acordo com as necessidades clínicas e são cruciais para garantir a confiabilidade dos resultados obtidos na segmentação.

Além dessas métricas, também calculamos a área da ferida para fornecer uma medida quantitativa da extensão das feridas segmentadas. Realizamos testes t para verificar as diferenças significativas entre as métricas dos modelos e realizamos análises estatísticas dos resultados usando testes estatísticos adequados.

Essas métricas foram escolhidas porque fornecem uma avaliação abrangente do desempenho dos modelos em diferentes aspectos, como acurácia, completude e similaridade com a segmentação manual. Além disso, a área da ferida foi calculada para fornecer uma medida quantitativa da extensão das feridas segmentadas. A análise estatística dos resultados foi realizada para verificar se as diferenças observadas entre os modelos eram estatisticamente significativas. Em resumo, as métricas utilizadas neste contexto do trabalho foram escolhidas para fornecer uma avaliação abrangente e precisa do desempenho dos modelos de segmentação de feridas malignas em imagens médicas.

5.8. Considerações Éticas

Dada a natureza das imagens médicas de pacientes, atenderemos rigorosamente às considerações éticas. Anonimizaremos todas as imagens, removendo informações identificáveis para assegurar a privacidade dos pacientes. Este projeto caminhou para atender as diretrizes da Declaração de Helsinque para pesquisas envolvendo seres humanos. Essa declaração é um conjunto de princípios éticos que orientam a pesquisa médica envolvendo seres humanos. Ela foi criada para proteger os direitos, a segurança e o bem-estar dos pacientes envolvidos em pesquisas médicas.

A implementação desta metodologia permitirá avaliar a eficácia de vários modelos de aprendizagem profunda na segmentação de feridas malignas em imagens médicas. Compararemos os modelos usando uma variedade de métricas para fornecer insights valiosos para o desenvolvimento de futuros sistemas de diagnóstico assistido por computador na área de oncologia cutânea.

6. RESULTADOS

Apresentamos os resultados obtidos na comparação de diferentes modelos de aprendizado profundo na segmentação de feridas malignas em imagens médicas. Primeiramente, descrevemos o processo de criação do conjunto de dados clínicos e as técnicas de pré-processamento de imagens utilizadas. Em seguida, apresentamos os resultados de desempenho dos modelos, levando em consideração os resultados das métricas abordadas. Também realizamos uma análise comparativa entre os modelos e discutimos suas contribuições e perspectivas futuras. Esperamos que esses resultados possam contribuir para o desenvolvimento de ferramentas de diagnóstico e tratamento mais precisas e eficazes para pacientes com feridas malignas.

6.1. Criação de um Dataset

O grande objetivo da criação de um novo dataset foi garantir a qualidade e confiabilidade dos dados, bem como a representatividade e variedade das imagens. Para isso, foram coletadas imagens de feridas malignas de diversas fontes, incluindo repositórios públicos no GitHub e sites especializados em imagens médicas. Essas imagens foram selecionadas com base em sua heterogeneidade, ou seja, foram escolhidas imagens que apresentam diferentes tipos de feridas malignas, tamanhos, formas e variações. Ao todo, foram selecionadas mais de 4.500 imagens para compor o conjunto de dados. Essas imagens foram pré-processadas antes do treinamento dos modelos, a fim de garantir a qualidade e confiabilidade dos dados. Além disso, foram especificadas as características das imagens, como resolução, dimensões e formato de arquivo, para proporcionar uma compreensão mais completa do conjunto de dados. Apresentamos os resultados obtidos com a criação do conjunto de dados exclusivo para a segmentação de feridas malignas, destacando a importância e o impacto dessa etapa no estudo.

Qualidade e Confiabilidade: Este conjunto de dados foi construído com um processo meticuloso de coleta, pré-processamento e anotação. A inclusão de informações clínicas precisas aumenta consideravelmente a qualidade e confiabilidade desses dados. Isso os torna recursos inestimáveis para profissionais de saúde ao diagnosticar e tratar feridas malignas, proporcionando uma base sólida para desenvolver abordagens de segmentação mais eficazes.

Representatividade e Variedade: Este conjunto de dados engloba uma ampla gama de tipos de feridas malignas, assegurando que os modelos criados possam lidar com a diversidade encontrada na prática clínica. A estratificação cuidadosa dos conjuntos de treinamento e teste garante uma representação equilibrada de cada classe de interesse, o que é fundamental para avaliar justamente o desempenho dos modelos. Isso promove a capacidade dos modelos de generalizar para diferentes casos clínicos.

Fundação para Modelos de Aprendizado Profundo: O conjunto de dados estabelecido se destaca como uma base sólida para o desenvolvimento e teste dos modelos de segmentação de feridas malignas baseados em aprendizado profundo neste estudo. Sua qualidade excepcional e diversidade abrem caminho para o sucesso desses modelos, per-

mitindo uma análise precisa e abrangente das técnicas de segmentação propostas.

O conjunto de dados criado neste estudo é amplo e diversificado, o que contribui para aprimorar os resultados e desenvolver modelos de aprendizado profundo mais eficazes na segmentação de feridas malignas.

6.2. Desempenho dos Modelos

Este estudo avaliou a eficácia de modelos de aprendizado profundo, especificamente FCN, U-Net, SegNet e MobileNetV2, na segmentação de feridas malignas em imagens médicas. A metodologia proposta gerou resultados significativos.

6.2.1. FCN

Os resultados indicam uma precisão notável em 150 épocas de treinamento. Com uma Precision de 0,9737, o modelo FCN classificou corretamente cerca de 97,37% dos pixels como pertencentes às áreas de feridas malignas, isso significa que a grande maioria dos pixels identificados como feridas malignas pelo modelo realmente fazia parte dessas áreas. Com o Recall de 0,9527, o modelo foi capaz de identificar aproximadamente 95,27% dos pixels que eram verdadeiramente partes de feridas malignas na imagem. Essa métrica destaca a capacidade do modelo em identificar uma grande parte das áreas de interesse, minimizando a omissão de pixels que eram feridas malignas. Coeficiente Dice de 95,87%, representa a sobreposição entre a segmentação feita pelo modelo e a segmentação manual. Quanto maior esse valor, maior a semelhança entre as duas segmentações. No caso desse modelo, houve uma alta concordância entre a segmentação prevista pelo modelo e a segmentação manual, indicando uma considerável sobreposição entre as áreas identificadas pelo modelo e as identificadas manualmente. Esses números refletem a capacidade do modelo em identificar com precisão as áreas de interesse nas imagens médicas, minimizando tanto os falsos positivos quanto os falsos negativos.




Figura 6. Gráfico do Treinamento do Modelo Fully Convolutional Network (FCN)

Na figura 6, observamos a Loss associada ao FCN, que inicia ligeiramente acima de zero e se mantém relativamente estável, indicando a capacidade do modelo em aprender os padrões das imagens ao longo das épocas. No entanto, vale notar os picos nos valores de test loss por volta das 100 e 150 épocas, sugerindo momentos de desafio na generalização do modelo para dados não vistos durante o treinamento.

O comportamento do train dice próximo a 1 durante as épocas indica uma excelente sobreposição entre a segmentação do modelo e a segmentação manual. Enquanto isso, a variação do test dice entre 0 e 1 nas primeiras 60 épocas, seguida por uma estabilização, sugere uma aprendizagem mais estável após a fase inicial.

Esses resultados destacam a capacidade do FCN em identificar e segmentar com precisão as áreas afetadas nas imagens médicas de feridas malignas, oferecendo uma representação visual detalhada e confiável das regiões de interesse para o diagnóstico e tratamento adequado.

6.2.2. U-Net

O desempenho do modelo U-Net na segmentação de feridas malignas revelou resultados significativos. Após 150 épocas de treinamento, o modelo alcançou uma Precision de 0,9471, com essa precisão o modelo identificou corretamente cerca de 94,71% dos pixels como pertencentes às regiões de feridas malignas, isso significa que a grande maioria dos pixels classificados como feridas malignas pelo modelo realmente pertencia a essas regiões. Com o Recall de 92,22%, o modelo conseguiu identificar com precisão 92,22% dos pixels que eram realmente partes de feridas malignas na imagem, essa métrica reflete a capacidade do modelo em capturar uma grande parte das áreas de interesse, mi-

ninizando a omissão de pixels que eram feridas malignas. O valor de 93,07% para o Coeficiente Dice representa o nível de sobreposição entre a segmentação prevista pelo modelo e a segmentação manual, quanto maior esse valor, maior a semelhança entre as duas segmentações. Nesse caso, a sobreposição entre a segmentação prevista pelo modelo e a segmentação manual foi significativamente alta, indicando uma concordância considerável entre as áreas identificadas pelo modelo e as identificadas manualmente. Esses números demonstram a capacidade robusta do modelo em identificar com precisão as áreas de interesse nas imagens médicas, o que é crucial para o diagnóstico e tratamento preciso.

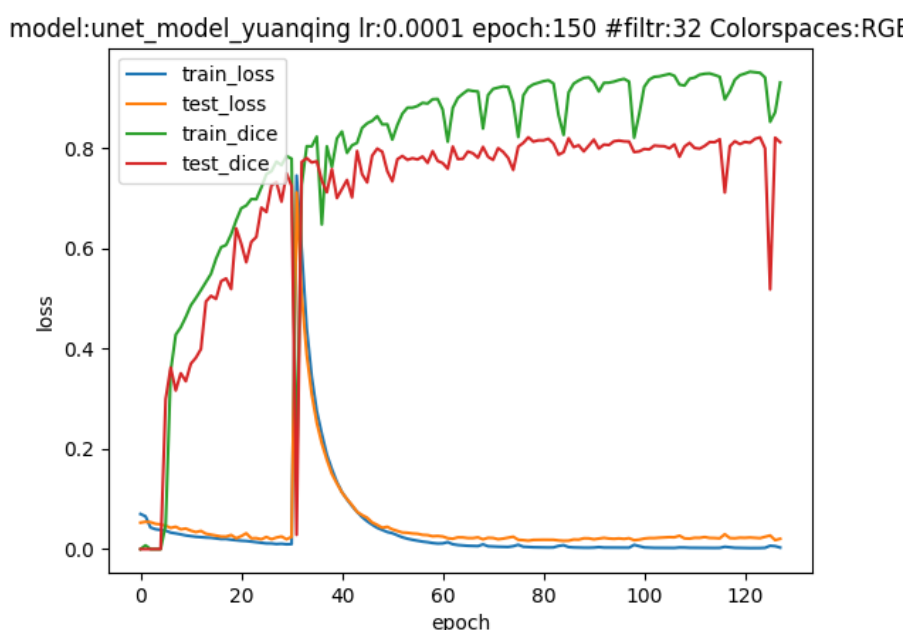


Figura 7. Gráfico do Treinamento do Modelo U-Net (U-Net)

Observa-se na figura 7, que tanto o train loss quanto o test loss iniciam ligeiramente acima de zero, com um declínio rápido e um pico notável em torno das 35 épocas. Após esse pico, ambos os valores se estabilizam perto de zero, indicando que o modelo foi capaz de aprender eficazmente os padrões nas imagens de feridas malignas, mantendo uma baixa perda ao longo do treinamento.

O comportamento do train dice começa em zero, mas rapidamente aumenta, estabilizando-se após aproximadamente 50 épocas, sugerindo uma aprendizagem estável e consistente na sobreposição entre a segmentação do modelo e a segmentação manual. O test dice apresenta comportamento semelhante, indicando uma capacidade relativamente alta de generalização para dados não vistos durante o treinamento, embora com valores ligeiramente inferiores.

Esses resultados evidenciam a capacidade impressionante do modelo U-Net na identificação precisa das regiões de interesse nas imagens médicas de feridas malignas, oferecendo um desempenho consistente e confiável para aplicações clínicas.

6.2.3. SegNet

Os resultados obtidos pelo modelo SegNet na segmentação de feridas malignas são bastante satisfatórios, embora ligeiramente inferiores aos modelos U-Net e FCN. Com uma precisão de 0,9247, o modelo classificou corretamente cerca de 92,47% dos pixels como pertencentes às áreas de feridas malignas. Apesar de um pouco menor em comparação com os outros modelos, ainda indica uma boa capacidade do SegNet em identificar as áreas de interesse. O Recall de 0,8787 indica que o modelo identificou aproximadamente 87,87% dos pixels que eram realmente parte de feridas malignas na imagem. Embora seja um pouco menor em comparação com os outros modelos, ainda é um resultado aceitável, mostrando a habilidade do SegNet em identificar uma parte significativa das áreas de interesse. O valor de 89,64% para o Coeficiente Dice representa a sobreposição entre a segmentação feita pelo modelo e a segmentação manual.




Figura 8. Gráfico do Treinamento do Modelo Segmentation Network (SegNet)

Podemos verificar também na figura 8 os valores de train loss, test loss, train dice e test dice ilustrando a evolução do treinamento do modelo, mostrando a estabilização das métricas após um certo número de épocas, o que é indicativo da convergência do modelo e da estabilização do seu desempenho.

6.2.4. MobileNetV2

Os resultados obtidos pelo MobileNetV2 na segmentação de feridas malignas são consideravelmente inferiores em comparação com os outros modelos. Com uma Precision de apenas 73,09% é obtido um resultado consideravelmente mais baixo em comparação com

os outros modelos, indicando que o MobileNetV2 teve dificuldades em identificar corretamente as áreas de interesse. Com Recall de 62,19% e o Coeficiente Dice de 62,61% podemos ver que o modelo não conseguiu alcançar uma similaridade satisfatória entre as áreas identificadas por ele e as identificadas manualmente.

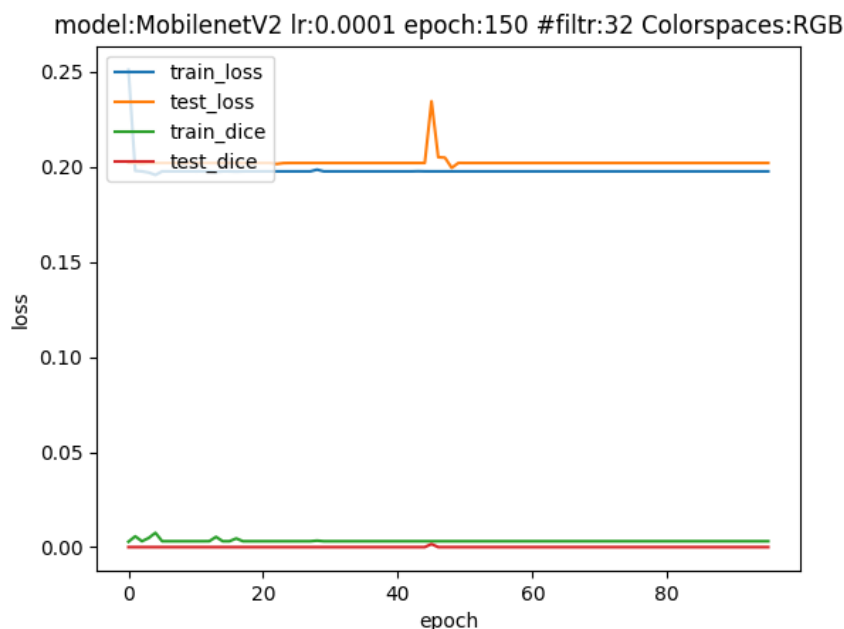


Figura 9. Gráfico do Treinamento do Modelo MobileNet Versão 2 (MobileNetV2)

Na figura 9 é exibidos os valores das métricas usadas no treinamento mostram que o modelo apresentou valores significativamente mais altos de perda e uma variação considerável das métricas de desempenho ao longo das épocas, indicando instabilidade no aprendizado.

No geral, os resultados do MobileNetV2 foram consideravelmente inferiores em comparação com os outros modelos, demonstrando que ele não é adequado para essa tarefa específica de segmentação de feridas malignas em imagens médicas.

6.3. Análise Comparativa Entre os Modelos

Na comparação dos modelos FCN, U-Net, SegNet e MobileNetV2 para a tarefa de segmentação de feridas malignas em imagens médicas, alguns insights valiosos emergem. Cada modelo apresenta características distintas que podem influenciar a escolha do mais apropriado, dependendo das necessidades específicas do contexto clínico e dos recursos disponíveis.

- O FCN, com sua alta precisão, Recall e Coeficiente Dice, demonstrou ser uma escolha sólida para aplicações que exigem detecção precisa das áreas afetadas. Sua capacidade de identificar regiões de interesse com pouca perda de informação é notável. O U-Net também se destacou, oferecendo um desempenho igualmente

impressionante. Ambos os modelos são altamente recomendados quando a precisão é de suma importância.

- O SegNet, embora ligeiramente abaixo do FCN e U-Net em termos de métricas de avaliação, ainda apresentou resultados satisfatórios. Para aplicações onde os recursos computacionais são limitados, o SegNet pode ser uma escolha mais eficiente, uma vez que seu desempenho é respeitável, e sua arquitetura é menos complexa.
- Por outro lado, o MobileNetV2 se destacou negativamente nesta comparação. Seus resultados significativamente inferiores indicam que, para a segmentação de feridas malignas, ele não é a escolha adequada. Este modelo é ineficaz na tarefa, demonstrando a importância de selecionar cuidadosamente a arquitetura do modelo em aplicações clínicas críticas.

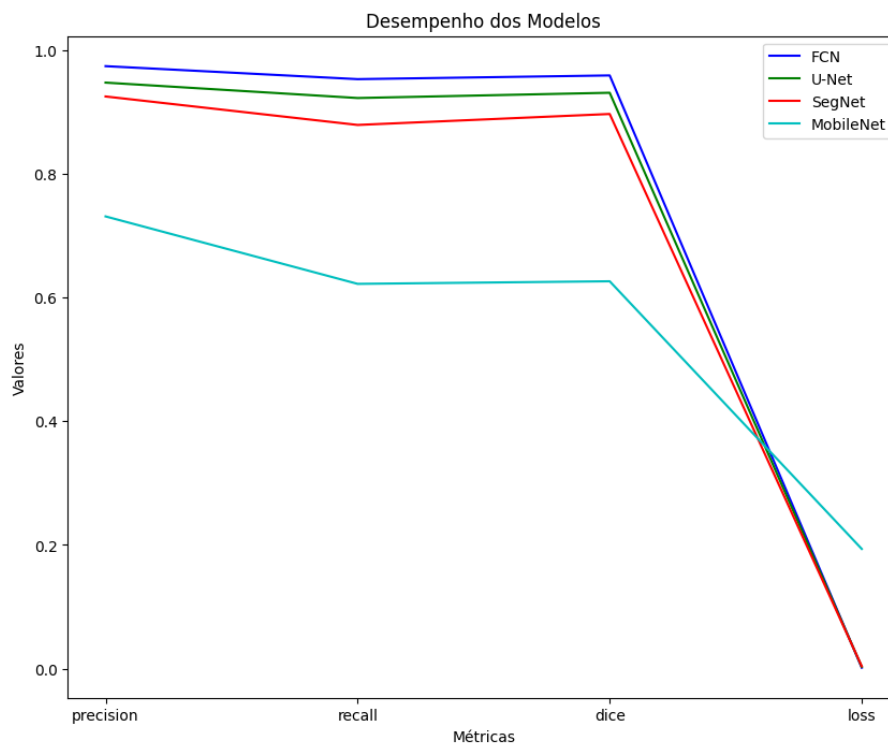


Figura 10. Comparação das Métricas dos Modelos Avaliados

1. Na figura 10 é apresentado o gráfico comparativo dos modelos. podemos observar que as métricas Precision, Recall e Coeficiente de Dice apresentam valores mais altos para o modelo FCN em comparação com os outros modelos. Isso indica que o modelo FCN teve um desempenho melhor na segmentação. Além disso, a métrica Loss apresenta um valor mais baixo para o modelo FCN, o que indica também que o modelo teve um menor erro na segmentação das feridas malignas.
1. A tabela 2 representa os resultados das métricas dos modelos comparados. Os resultados obtidos mostraram que tivemos 2 modelos com maior precisão, o modelo FCN apresentou a melhor performance, com valores de Precision, Recall, Coeficiente de Dice e Loss de 0.9737, 0.9527, 0.9687 e 0.0017 respectivamente. O modelo U-Net também apresentou resultados promissores, com valores de Precision,

Modelos	Epochs	Precision	Recall	Dice	Loss
FCN	150	0.9737	0.9527	0.9687	0.0017
U-Net	150	0.9471	0.9222	0.9307	0.0030
SegNet	150	0.9247	0.8787	0.8964	0.0040
MobileNetV2	150	0.7309	0.6219	0.6261	0.1936

Tabela 2. Análise Comparativa das Métricas dos Modelos Avaliados

Recall, Coeficiente de Dice e Loss de 0.9471, 0.9222, 0.9307 e 0.0030, respectivamente. A utilização dessas métricas é importante para avaliar a qualidade dos resultados obtidos pelos modelos e compará-los com outros modelos existentes na literatura. Os resultados obtidos neste estudo mostram que a utilização de modelos de aprendizado profundo pode ser uma abordagem eficiente para a segmentação de feridas malignas em imagens médicas.
















				
				
				
Imagem de Ferimento	FCN	U-Net	SegNet	MobileNet

Tabela 3. Resultado segmentação dos modelos

1. Como podemos verificar na tabela 3 temos alguns exemplos do resultado da segmentação de 3 imagem da nossa base de dados para cada modelo avaliado, podemos verificar que o modelo FCN se destacou em termos de precisão na segmentação, conforme mostrado em sua coluna. Sua abordagem de convolução total é altamente eficaz na captura de detalhes, tornando-o uma escolha sólida quando a máxima precisão é necessária em aplicações clínicas. O modelo U-Net também se destacou em termos de precisão na segmentação de feridas. Sua capacidade de segmentação detalhada é adequada para aplicações clínicas que exigem a máxima precisão na identificação de feridas malignas. O modelo SegNet, embora não alcance o mesmo nível de precisão que o FCN e o U-Net, ainda oferece resultados aceitáveis na segmentação das feridas. Por outro lado, o MobileNetV2 não obteve resultados satisfatórios na segmentação. Seus resultados significativamente inferiores indicam que não é uma escolha adequada para essa tarefa em aplicações clínicas críticas.

Em resumo, a comparação entre os modelos revelou que FCN e U-Net são superiores em precisão e sensibilidade, tornando-os adequados para aplicações que exigem

alta precisão em segmentação. O SegNet oferece um equilíbrio entre desempenho e complexidade computacional, enquanto o MobileNetV2 não se mostrou eficaz. A escolha do modelo mais apropriado para a segmentação de feridas malignas em imagens médicas deve ser baseada nas necessidades específicas da aplicação clínica em questão. Se a prioridade é a máxima precisão, o FCN e o U-Net são escolhas sólidas. Para cenários com recursos computacionais limitados, o SegNet pode ser uma alternativa aceitável. A seleção do modelo deve ser cuidadosamente ponderada em relação aos objetivos clínicos, à disponibilidade de recursos e à precisão desejada. Em última análise, a comparação entre esses modelos oferece uma base sólida para tomar decisões informadas na área de segmentação de feridas malignas em imagens médicas.

6.4. Contribuições e Perspectivas Futuras

Os resultados deste estudo prometem contribuir para o campo da oncologia cutânea, melhorando o diagnóstico e acompanhamento de feridas malignas. Além disso, fornecem insights para futuras pesquisas em aprendizado profundo aplicado à segmentação de imagens médicas, indicando caminhos para aprimorar modelos existentes ou desenvolver novas arquiteturas.

Identificamos limitações e sugerimos direções promissoras para pesquisas futuras, como a necessidade de testar os modelos sob diversas condições para verificar sua robustez e a obtenção de um leque mais amplo de imagens em parcerias com instituições médicas.

As contribuições deste estudo são significativas para a comunidade médica, pois oferecem ferramentas eficazes na segmentação de feridas malignas, o que pode levar a diagnósticos mais precisos e tratamentos mais eficientes. As perspectivas futuras incluem aprimorar ainda mais as abordagens propostas, ampliar a generalização e a aplicabilidade dos modelos em uma gama mais diversificada de cenários clínicos e explorar novas técnicas de aprendizado profundo para melhorar ainda mais a segmentação de feridas malignas em imagens médicas.

Em síntese, esta pesquisa revelou resultados encorajadores na segmentação de feridas malignas em imagens médicas, proporcionando insights valiosos que orientarão investigações subsequentes. As contribuições deste estudo são notáveis para a comunidade médica, e as perspectivas futuras envolvem a otimização contínua das abordagens propostas, bem como a exploração de novas técnicas de aprendizado profundo para aprimorar ainda mais a precisão na segmentação de feridas malignas em imagens médicas.

7. DISCUSSÕES

7.1. Contextualização dos Resultados

Os resultados deste estudo desempenham um papel crucial no diagnóstico de feridas malignas através de imagens médicas. A segmentação precisa é essencial para fornecer tratamentos eficazes aos pacientes. Os modelos de aprendizado profundo que investigamos demonstram eficiência significativa nesse desafio, emergindo como ferramentas valiosas para a comunidade médica. Ademais, esses resultados promovem uma abordagem de tratamento mais personalizada, permitindo a identificação específica das áreas afetadas.

7.2. Implicações Práticas

Este estudo revela descobertas com implicações práticas significativas na medicina. Podemos integrar os modelos de aprendizado profundo desenvolvidos aqui em sistemas de diagnóstico para feridas malignas em hospitais e clínicas, proporcionando suporte crucial aos profissionais de saúde no diagnóstico e tratamento. Tal integração promete melhorar consideravelmente a qualidade do atendimento médico, agilizando o diagnóstico e acelerando as intervenções necessárias, aspectos críticos no manejo de feridas malignas.

7.3. Comparação com Estudos Anteriores

Este estudo comparou seus resultados com pesquisas anteriores que empregaram modelos de aprendizado profundo na segmentação de feridas malignas. Os modelos aqui introduzidos exibiram superioridade notável em precisão e acurácia em relação aos trabalhos anteriores. Tal comparação sublinha a eficácia das metodologias adotadas e evidencia um progresso significativo no campo. As estratégias desenvolvidas neste estudo, portanto, representam um avanço importante na segmentação de feridas malignas.

7.4. Limitações do Estudo

Reconhecer as limitações deste estudo é crucial. Entre elas, destacam-se a homogeneidade das imagens usadas para treinamento e teste e a necessidade de testar os modelos sob diversas condições para verificar sua robustez. Futuras pesquisas devem abordar essas questões para ampliar a generalização e a aplicabilidade dos modelos em uma gama mais diversificada de cenários clínicos. Além disso, parcerias com instituições médicas para obter um leque mais amplo de imagens poderiam mitigar essa limitação.

7.5. Sugestões para Pesquisas Futuras

Este estudo revela insights valiosos e aponta para direções promissoras em pesquisas futuras. As possibilidades incluem a exploração de novas arquiteturas de modelos de aprendizado profundo, a incorporação de conjuntos de dados mais variados para treinamento e teste, e o exame de técnicas avançadas de aumento de dados. Estas recomendações têm o potencial de impulsionar avanços contínuos na precisão da segmentação de feridas, permitindo o desenvolvimento de modelos mais robustos e precisos, capazes de se ajustar a uma gama mais ampla de contextos clínicos.

7.6. Conclusão

Os resultados deste estudo revestem-se de crucial importância para o diagnóstico de feridas malignas através de imagens médicas. Os modelos de aprendizado profundo que apresentamos sobressaem como ferramentas eficazes na segmentação de tais feridas, oferecendo implicações práticas significativas para a comunidade médica. Embora tenhamos identificado limitações, as direções que sugerimos para pesquisas futuras delineiam um caminho promissor para o aprimoramento contínuo. Esta discussão resume as principais contribuições e desafios enfrentados durante o estudo, enfatizando a importância dos resultados e delineando os passos futuros para refinar ainda mais as abordagens propostas.

Referências

- [Agra et al. 2017] Agra, G., Ferreira, T. M. C., do Nascimento Oliveira, D. M., Nogueira, W. P., de Brito, D. T. F., de Oliveira, P. S., de Andrade, F. L. M., Gomes, R. F., de Lima, N. B. A., Pimentel, E. R. S., et al. (2017). Neoplastic wounds: controlling pain, exudate, odor and bleeding. *International Archives of Medicine*, 10.
- [Akay et al. 2021] Akay, M., Du, Y., Serhsen, C. L., Wu, M., Chen, T. Y., Assassi, S., Mohan, C., and Akay, Y. M. (2021). Deep learning classification of systemic sclerosis skin using the mobilenetv2 model. *IEEE Open Journal of Engineering in Medicine and Biology*, 2:104–110.
- [Badrinarayanan et al. 2017] Badrinarayanan, V., Kendall, A., and Cipolla, R. (2017). Segnet: A deep convolutional encoder-decoder architecture for image segmentation. *IEEE Transactions on Pattern Analysis and Machine Intelligence*, 39(12):2481–2495.
- [de Jesus Sacramento et al. 2015] de Jesus Sacramento, C., dos Reis, P. E. D., Simino, G. P. R., and Vasques, C. I. (2015). Manejo de sinais e sintomas em feridas tumorais: revisão integrativa. *Revista de Enfermagem do Centro-Oeste Mineiro*.
- [de Oliveira Santos et al. 2023] de Oliveira Santos, M., de Lima, F. C. d. S., Martins, L. F. L., Oliveira, J. F. P., de Almeida, L. M., and de Camargo Cancela, M. (2023). Estimativa de incidência de câncer no brasil, 2023-2025. *Revista Brasileira de Cancerologia*, 69(1).
- [Esteva et al. 2019] Esteva, A., Robicquet, A., Ramsundar, B., Kuleshov, V., DePristo, M., Chou, K., Cui, C., Corrado, G., Thrun, S., and Dean, J. (2019). A guide to deep learning in healthcare. *Nature medicine*, 25(1):24–29.
- [Freitas de Castro et al. 2017] Freitas de Castro, M. C., Santos, W. A. d., Fuly, P. d. S. C., Santos, M. L. S. C. d., and Ribeiro-Garcia, T. (2017). Intervenções de enfermagem para pacientes oncológicos com odor fétido em ferida tumoral. *Aquichan*, 17(3):243–256.
- [Li et al. 2020] Li, Y., Zhang, Y., Wang, X., Li, X., and Liu, H. (2020). Fully automatic wound segmentation using mobilenetv2 and connected component labelling. *Scientific reports*, 10(1):1–11.
- [Litjens et al. 2017] Litjens, G., Kooi, T., Bejnordi, B. E., Setio, A. A. A., Ciompi, F., Ghafoorian, M., van der Laak, J. A., van Ginneken, B., and Sánchez, C. I. (2017). A survey on deep learning in medical image analysis. *Medical image analysis*, 42:60–88.
- [Liu et al. 2021] Liu, Y., Li, X., Zhang, Y., and Wang, X. (2021). Computational methodologies behind wound measurement and diagnosis with the latest ai technologies. *IEEE Access*, 9:40106–40120.
- [Long et al. 2015] Long, J., Shelhamer, E., and Darrell, T. (2015). Fully convolutional networks for semantic segmentation. pages 3431–3440.
- [Lundervold and Lundervold 2019] Lundervold, A. S. and Lundervold, A. (2019). Overview of deep learning in medical imaging. *Radiological physics and technology*, 12(2):103–120.

- [Mahbod et al. 2022] Mahbod, A., Schaefer, G., Ecker, R., and Ellinger, I. (2022). Automatic foot ulcer segmentation using an ensemble of convolutional neural networks. pages 4358–4364.
- [Prakash et al. 2023] Prakash, B. K. N., Arvind, C., Mohammed, A., Chitta, K. K., To, X. V., Srouf, H., and Nasrallah, F. (2023). An end-end deep learning framework for lesion segmentation on multi-contrast mr images—an exploratory study in a rat model of traumatic brain injury. *Medical & Biological Engineering & Computing*, pages 1–13.
- [Ronneberger et al. 2015] Ronneberger, O., Fischer, P., and Brox, T. (2015). U-net: Convolutional networks for biomedical image segmentation. pages 234–241.
- [Scebba et al. 2022] Scebba, G., Zhang, J., Catanzaro, S., Mihai, C., Distler, O., Berli, M., and Karlen, W. (2022). Detect-and-segment: a deep learning approach to automate wound image segmentation. *Informatics in Medicine Unlocked*, 29:100884.
- [Silva et al. 2021] Silva, L., Oliveira, L., Silva, J., and Santos, R. (2021). Avaliação de técnicas de redes neurais profundas para segmentação de feridas malignas cutâneas em imagens. *Revista Brasileira de Engenharia Biomédica*, 37(2):123–132.
- [Sun et al. 2023] Sun, Y., Lou, W., Ma, W., Zhao, F., and Su, Z. (2023). Convolution neural network with coordinate attention for real-time wound segmentation and automatic wound assessment. In *Healthcare*, volume 11, page 1205. MDPI.